재난 대응 상황의 연결성 제약 드론 배송을 위한 기하 및 학습 기반 중계 제어

고광종[a], 정태수[a,*]

[a]고려대학교 산업경영공학부, 서울특별시 성북구 안암로 145, 서울, 02841, 대한민국

Abstract

재난 구호에서 배송 드론은 편대 스스로 구성하는 다중 홉 중계 사슬을 통해 제어 센터와 연결을 유지한 채, 제한된 적재량으로 물자를 나르고 재적재를 위해 복귀해야 한다. 본 연구는 이를 모든 드론이 배송과 중계를 겸할 수 있고 연결성이 매 스텝 강제되는 makespan 최소화 문제로 모형화한다. 같은 연결성 보존 투영을 공유하는 두 제어기를 제안한다. 교착 탈출 장치를 갖춘 기하 사슬 중계 휴리스틱과, 집합 기반 자기회귀 상위 정책을 이산 soft actor-critic 으로 한 번 학습한 편대 크기 불변 정책이다. 두 제어기를 드론 3–12대, 목적지 20–400곳의 동일 인스턴스에서 쌍별로 비교하고, 무학습 베이스라인 넷과 작은 인스턴스의 시간 확장 혼합정수 참조 모형에 대조한다. 학습 정책은 모든 구성의 모든 인스턴스를 완주하고, 휴리스틱은 탈출 장치가 있을 때 98–100%, 없을 때 62%를 완주한다. 두 제어기는 구성 공간을 나눈다. 드론 3대에서는 휴리스틱이 쌍별 중앙값으로 30–39스텝 빠르고, 4대에서는 480 롤아웃에서 동률이며, 5대 이상에서는 학습 정책이 38–178스텝 빠르다. 이 정책은 드론 3·4대로만 학습했고 재학습 없이 그보다 큰 모든 편대로 일반화된다. 3대 구성의 열세는 어느 드론이 중계할지라는 한 결정에 국소화되며, 정보·크레딧 할당·결정 구조·초기화·보상 설계에 걸친 정책 쪽 개입 열 가지가 모두 이를 제거하지 못한다. 연결성 투영을 같은 방향 축소에서 접선 보존으로 바꾸면 열세의 절반이 사라져, 이 열세가 학습기만이 아니라 제약을 강제하는 방식의 성질이기도 함을 보인다. 두 제어기 모두 결정당 밀리초에 동작하며, 이는 목적지 10곳에서 90분 안에 계획을 내지 못하는 정확 최적화보다 세 자릿수 빠르다.

Keywords: 드론 배송, 중계 네트워크, 연결성 제약, 다중 에이전트 강화학습, 휴리스틱, 재난 물류

1. 서론

통신·물류·도로 기반이 파괴되면 드론 편대가 임시 제어 센터에서 여러 목적지로 긴급 물자를 나를 수 있다. 이것이 택배 배송과 다른 점은 둘이다. 첫째, 상·하역이 원격으로 감독되고 배송 상태가 추적되어야 하므로 모든 드론이 항상 제어 센터와 통신 가능해야 하며, 지상망이 사라진 상황에서 그 통신은 드론들이 스스로 다중 홉 사슬의 중계 노드가 되어야만 성립한다. 둘째, 편대는 작고 드론 한 대의 적재량은 몇 단위에 불과해 드론은 센터와 목적지 사이를 왕복하며, 중계로 서 있는 드론은 그만큼 배송하지 않는 드론이다. 따라서 운영상의 질문은, 사슬을 한 번도 끊지 않으면서 마지막 목적지를 가능한 한 빨리 배송하도록 배송 역할과 중계 역할을 시간에 따라 어떻게 배정하느냐다.

이 문제가 어려운 이유는 세 가지다. 하드 연결성 제약은 교착을 만든다. 모든 드론을 가장 가까운 목적지로 보내는 탐욕 배정은 본 연구의 표준 인스턴스를 한 건도 완주하지 못하는데, 편대가 스스로를 잡아당기다가 어떤 드론도 움직일 수 없게 되기 때문이다. 중계는 처리량과 직접 경쟁하므로 적정한 중계 대수와 중계 드론은 남은 목적지의 기하와 적재가 남은 드론 수에 따라 달라진다. 그리고 정확 최적화는 규모가 커지지 않는다. 98 m 격자 위의 시간 확장 혼합정수 모형은 목적지 4곳과 6곳의 계획은 내지만 10곳에서는 90분 안에 실행 가능한 계획을 찾지 못한다.

제안. 이 문제에 대해 두 제어기를 제안하고 나란히 연구한다.

1. 기하 사슬 중계 휴리스틱. 적재가 남은 드론 중 센터에서 가장 먼 드론이 선두이고, 중계 대수는 선두의 목표가 필요로 하는 통신 홉 수이며, 중계 드론은 그 다음으로 먼 드론들로서 센터에서 선두까지의 선분 위에 $0.9R$ 간격으로 선다. 규칙이 결정론적이라 교착된 배정을 무한히 반복할 수 있으므로, 편대가 정해진 스텝 수만큼 정체하면 선두를 교대하는 교착 탈출 장치를 더했다. 탈출 장치만으로 표준 구성 완주율이 62%에서 98%로 오른다.
2. 편대 크기에 불변인 학습 정책. 상위 정책이 20스텝마다 드론별로 일곱 개 이산 옵션 중 하나를 배정한다. 드론·후보 목적지·중계 슬롯을 집합으로 부호화하고 어텐션으로 풀링하며, 선두 하나와 중계 k대의 대형을 의도적으로 구성할 수 있도록 자기회귀로 결정한다. 드론 3·4대 편대로 이산 soft actor-critic 으로 한 번 학습한 뒤 재학습 없이 최대 12대 편대에서 돌린다.

두 제어기 모두 같은 연결성 보존 투영을 거쳐 행동한다. 명령된 이동은 편대의 연결이 유지되는 최대 비율로 축소된다. 따라서 연결성은 두 제어기 모두에 구조적으로 보장되며, 실험의 질문은 제약을 위반하는가가 아니라 제약 아래에서 진척을 내는가다.

연구 질문. 연구를 네 질문으로 조직한다.

RQ1 제안 제어기들은 매 스텝 연결성이 강제된 채 항상 완주하는가, 못 한다면 왜인가?

RQ2 작은 인스턴스에서 제안 제어기들은 격자 모형의 정확 최적화로 얻은 참조 계획에 얼마나 가까운가?

RQ3 두 제어기의 성능은 편대 크기·목적지 수·거점 위치·통신

*교신저자.
Email addresses: koptimizer@korea.ac.kr (고광종), tcheong@korea.ac.kr (정태수)

반경에 따라 어떻게 다르고, 작은 편대로 학습한 정책이 큰 편대로 일반화되는가, 그 차이는 어디서 오는가?

RQ4 각 제어기의 구성 요소는 필수적인가?

발견. 학습 정책은 시험한 모든 구성의 모든 인스턴스를 완주하고, 휴리스틱은 탈출 장치와 함께 98–100%를 완주한다(RQ1). 격자 모형이 다룰 만큼 작은 인스턴스에서 두 제어기는 참조 계획의 수 퍼센트 안에 있고, 참조 계획 자체는 연속 문제의 하한이 아니라 제한이다(RQ2). 두 제어기는 편대 크기로 구성 공간을 나눈다. 3대에서는 휴리스틱이 빠르고, 4대에서는 동률이며, 5대 이상에서는 학습 정책이 10대까지 62–178스텝, 12대에서 76스텝 빠르며 학습에서는 4대 이상을 본 적이 없다. 3대 열세는 어느 드론이 중계할지라는 한 결정이며 정책 쪽 개입 열 가지에 저항하지만 연결성 투영을 바꾸면 절반으로 줄어든다(RQ3). 학습 정책에서 규칙 정규화·구성 무작위화·엔트로피 감쇠를 빼면 수백 스텝 또는 완주를 잃고, 휴리스틱에서 탈출 장치를 빼면 완주의 3분의 1을 잃는다(RQ4).

기여. (i) 제약이 구조적으로 성립하는 투영 위에 세운, 교착 탈출을 갖춘 기하 사슬 중계 휴리스틱과 편대 크기 불변 학습 정책. (ii) 두 제어기가 상보적임을 보이는 편대 크기별 쌍별 평가와 그 경계의 기제. (iii) 학습기를 바꿔 드론 부족 영역의 열세를 좁히려는 열 가지 기록된 음성 결과와, 열세의 절반이 강제 모형에 귀속됨을 보이는 민감도 결과. (iv) 무엇을 제한하고 무엇을 제한하지 못하는지를 정직하게 밝힌 격자 MILP 참조.

2. 관련 연구

드론 배송 경로. 드론을 이용한 경로 문제는 flying-sidekick 외판원 문제 [1]와 그 다중 드론 확장 [2, 3, 4] 이래 연구되어 왔다. 이 모형들은 통신을 공짜로 본다. 드론이 도달 가능해야 한다는 요구가 없고, 어떤 차량도 중계를 위해 배송 역할을 내려놓지 않는다. min-max 다중 차량 경로의 학습 해법 [5, 6]은 집합 기반 정책이 문제 크기에 걸쳐 일반화함을 보이는데, 이는 편대 크기에 걸쳐 우리가 필요로 하는 성질이지만 역시 연결성 제약이 없다. 같은 드론이 배송과 감지를 겸하는 이중 임무 편대 [7]는 배송당 우회 예산을 정식화하지만 부차 임무가 통신이 아니라 감지다.

UAV 중계와 연결성 유지. 공중 중계 배치는 자체 문헌을 이루며 [8, 9, 10], 임무 UAV와 중계 UAV를 다중 에이전트 학습으로 공동 최적화하는 연구도 있다 [11, 12]. 이 연구들에서 중계는 임무 그 자체이거나 자체 보상을 가진 전용 하위 편대이며, 적재도 재적재도 없고 배송 makespan 을 최소화하지 않는다. 다중 로봇 항법의 연결성 유지는 학습 제어기로 접근된 바 있다 [13]. 임무 역할과 중계 역할 사이의 전환은 다중 로봇 탐사 [14, 15]에서 확립된 아이디어로, 중계 로봇이 착륙해 고정 노드가 된다.

본 연구의 위치. 저자들이 아는 범위에서 (i) 적재와 재적재가 있는 동질 편대가 물리적 화물을 다수 목적지로 나르고, (ii) 모든 드론이 매 스텝 다중 홉 사슬로 센터에 연결되어야 하며, (iii) makespan 을 목적으로 하는 설정을 함께 다룬 연구는 없다. 이 설정에서는 중계 의무가 화물 처리량과 경쟁하고 편대가 거점으로 반복 복귀해야 하므로, 역할 배정이 일회성 배치가 아니라 순차 결정이 된다.

학습 기법. 학습 측면에서는 soft actor-critic [16], 분산 실행을 위한 중앙 critic [17, 18], 가치 분해 [19, 20], 반 마르코프 결정 과정으로서의 옵션 [21], 무효 행동 마스킹 [22], 안전 행동 투영 [23]에 기반한다. 6.3절의 음성 결과는 이 아이디어 중 여럿을 직접 시험한다. 드론별 크레딧, 결합 행동 critic, 단조 가치 혼합, 잠재 함수형 보상 설계 [24]를 드론 부족 영역의 열세에 대한 처방으로 시도했고 어느 것도 열세를 제거하지 못했다.

3. 문제 정의

제어 센터는 $c \in [0, 1000]^2$ m에 있고 M개 목적지 $d_1, \ldots, d_M$는 센터로부터 $0.9\,NR$ 안에 놓인다. N은 드론 수, $R = 300$ m는 통신 반경이다. 각 드론은 $v = 13.89$ m/s로 비행하고 $Q = 5$단위를 싣는다. 모든 배송과 재적재에는 서비스 지연이 따른다. 목적지에서 한 단위를 내리는 데 $S = 10$스텝, 센터에서 Q까지 재적재하는 데 S스텝이 들며 그동안 드론은 정지한다. 목적지나 센터는 25 m 안에 들어오면 도달한 것으로 보며 한 스텝은 1초다. 서비스 지연은 아래의 연결성 제약과 맞물린다. 정지한 드론은 링크를 지키려 움직일 수 없으므로 동료들이 그 주위에서 사슬을 유지해야 한다. 모든 목적지는 정확히 한 단위를 필요로 한다. 드론 간 충돌·바람·배터리는 모형화하지 않는다.

연결성. G_t를 센터와 N대 드론을 정점으로, 서로 R 안에 있는 정점 쌍을 간선으로 하는 그래프라 하자. G_t가 연결되어 있으면 스텝 t에 편대가 연결된 것이고, 이는 모든 드론이 센터까지 다중 홉 경로를 가진다는 말과 같다. 제약은 모든 t에서 G_t가 연결되는 것이며, 벌점이 아니라 강제로 지킨다(4.1절).

목적. makespan 은 마지막 목적지가 배송되는 스텝이다. 제어기가 10,000스텝 예산 안에 모든 목적지를 배송하면 그 인스턴스를 완주한 것으로 본다. 완주율과, 완주한 인스턴스에서의 makespan 을 보고한다.

구성. 구성은 편대 크기 N, 목적지 수 M, 거점 배치(지도 중앙 고정 또는 균일 무작위)의 세 쌍이다. 표준 구성은 고정 거점의 $N = 4$, $M = 50$이다. 학습 정책은 $N \in \{3, 4\}$, $M \in [20, 80]$, 무작위 거점으로 학습하며 그 외 구성은 본 적이 없다. 휴리스틱에는 학습이 없다.

3.1. 이산화 위에서 정확한 시공간 네트워크 모형

두 제어기 외에 제안하는 세 번째 요소는 이 문제의 최적화 모형이다. 모형은 두 역할을 한다. 문제를 모호함 없이 서술하고, 작은 인스턴스에서는 정확 최적화로 얻은 계획을 제공해 두 제어기를 그에 재게 한다.

모형이 이 형태를 취하는 이유. 드론 배송의 차량 경로 정식화 [1, 3]는 차량에 경로를 배정할 뿐 특정 순간에 차량이 어디 있는지 알 필요가 없다. 3절의 연결성 요구는 종류가 다르다. 통신 그래프 G_t가 드론 위치로부터 만들어지므로 이는 매 스텝 모든 드론의 위치에 대한 제약이다. 따라서 모형은 모든 드론의 위치를 시간에 따라 실어야 하고, 그에 자연스러운 대상이 시간 확장 네트워크 [25]다. 위치 집합을 기간마다 복제하고 한 기간의 위치에서 다음 기간에 도달 가능한 위치로 호를 잇는다. 평면 위의 위치는 비가산이므로 공간도 격자로 이산화하며, 그 결과가 드론을 단위 흐름으로 다루는 시공간 네트워크이고

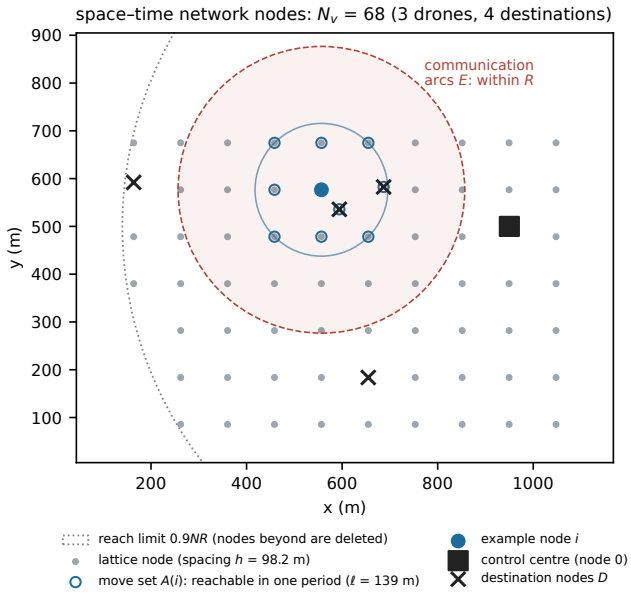


그림 1: 드론 3대, 목적지 4곳의 참조 인스턴스에 대한 시공간 네트워크의 노드. 센터(노드 0), 목적지 노드 D, 도달 한계 $0.9NR$로 자른 간격 $h = 98.2$ m의 격자 G. 예시 노드 i 하나에 대해 이동 집합 $A(i)$(한 기간에 닿는 노드, $\ell = 138.9$ m)와 E의 호를 정하는 반경 R의 통신 원판을 표시했다.

이 위의 시간 색인 MILP는 이산화된 문제에 대해 정확하다. 연결성은 매 기간 어느 격자 노드가 점유되었는지의 성질이 되고, 점유 노드들이 센터까지 다중 홉 사슬을 이룰 때 그리고 그때만 실행 가능한 기간별 단일 상품 흐름으로 부호화한다. 모형이 정확하다는 것은 그 최적값이 이산화된 문제의 참 최적값이라는 뜻이며, 연속 문제와의 관계는 이 절 끝에 적는다.

이산화. 한 기간은 $\kappa = S = 10$스텝이다. 따라서 서비스 한 번이 정확히 한 기간이고 학습 정책의 상위 결정 한 번은 두 기간이며, 기간당 비행 거리는 $\ell = v\kappa = 138.9$ m다. 공간은 인스턴스의 경계 상자 위에 간격 $h = \ell/\sqrt{2} = 98.2$ m로 놓은 정사각 격자 G에서 센터로부터 $0.9NR$보다 먼 노드(어떤 사슬도 닿을 수 없는 노드)를 지운 것이고, 센터와 모든 목적지는 정확한 노드로 추가해 그곳의 상호작용 판정이 정확하도록 한다. 그림 1가 참조 인스턴스의 노드 집합이다. 이 간격에서 여덟 방향 이동이 모두 한 기간에 가능하다. 이동 집합과 통신 집합은

$$A(i) = \{j \in N_{\mathrm{v}} : \|p_i - p_j\| \le \ell\} \ni i, \tag{1}$$

$$E = \{(i,j) \in N_{\mathrm{v}}^2 : i \neq j,\ \|p_i - p_j\| \le R\} \tag{2}$$

이다. 축 방향 이동은 기간당 ℓ이 아니라 h만 가므로 격자는 그 방향에서 드론을 최대 29% 늦추며, 이 이산화 오차는 항상 모형에 불리하게 작용한다. 격자는 중계 사슬을 담을 만큼 촘촘해야 한다. 거리 d의 목적지를 배송하려면 중간 드론들이 사슬의 여유 $NR - d$ 안에 놓여야 하므로 대략 $h \lesssim (NR - d_{\max})/(N-1)$이 필요하다. 196 m 격자는 평면에서 실행 가능한 참조 인스턴스를 실행 불가능하게 만들고 98 m는 그렇지 않다.

기호. 표 1에 집합·파라미터·결정변수를 정리했다. 드론은 동일하므로 드론 첨자는 개체를 구별할 뿐이며, 모형 끝의 대칭 제거 절단이 이를 이용한다. 모형은 (3)–(16)이다.

$$\min \quad C + \varepsilon \sum_{i \in N_{\mathrm{v}} \setminus \{0\}} \sum_{k \in K} \sum_{t \in T} y_{ikt} \tag{3}$$

$$\text{s.t.} \quad \sum_{i \in N_{\mathrm{v}}} y_{ikt} = 1 \qquad \forall k \in K,\ t \in T \tag{4}$$

$$y_{0k0} = 1 \qquad \forall k \in K \tag{5}$$

$$y_{i,k,t+1} \le \sum_{j \in A(i)} y_{jkt} \qquad \forall i \in N_{\mathrm{v}},\ k \in K,\ t < \bar{T} \tag{6}$$

$$\sum_{k \in K} \sum_{t < \bar{T}} s_{jkt} = 1 \qquad \forall j \in D \tag{7}$$

$$s_{jkt} \le y_{jkt}, \qquad s_{jkt} \le y_{j,k,t+1} \qquad \forall j \in D,\ k \in K,\ t < \bar{T} \tag{8}$$

$$r_{kt} \le y_{0kt}, \qquad r_{kt} \le y_{0,k,t+1} \qquad \forall k \in K,\ t < \bar{T} \tag{9}$$

$$\sum_{j \in D} s_{jkt} + r_{kt} \le 1, \qquad \sum_{j \in D} s_{jkt} \le q_{kt} \qquad \forall k \in K,\ t < \bar{T} \tag{10}$$

$$q_{k,t+1} = q_{kt} - \sum_{j \in D} s_{jkt} + \rho_{kt}, \qquad q_{k0} = Q \qquad \forall k \in K,\ t < \bar{T} \tag{11}$$

$$\rho_{kt} \le Q\, r_{kt}, \qquad q_{k,t+1} \ge Q\, r_{kt} \qquad \forall k \in K,\ t < \bar{T} \tag{12}$$

$$\sum_{j:(i,j) \in E} g_{ijt} - \sum_{j:(j,i) \in E} g_{jit} = u_{it} \qquad \forall i \in N_{\mathrm{v}} \setminus \{0\},\ t \in T \tag{13}$$

$$g_{ijt} \le N\, u_{it} \qquad \forall (i,j) \in E,\ t \in T \tag{14}$$

$$C \ge t\, s_{jkt} \qquad \forall j \in D,\ k \in K,\ t < \bar{T} \tag{15}$$

$$s_{jkt} = 0 \qquad \forall k \in K,\ j \in D \text{ with } \mathrm{idx}(j) < k,\ t < \bar{T} \tag{16}$$

표 1: 시공간 네트워크 모형의 기호.

기호	정의역	뜻
집합		
$N_{\mathrm{v}} = \{0\} \cup D \cup G$		노드: 제어 센터(첨자 0), 목적지 노드 D, 격자 노드 G
K	$\lvert K\rvert = N$	드론
$T = \{0, 1, \ldots, \bar{T}\}$		기간 경계; 기간 t는 경계 t에서 $t+1$까지
$A(i) \subseteq N_{\mathrm{v}}$		i에서 한 기간 안에 닿는 노드, i 자신 포함(이동 집합)
$E \subseteq N_{\mathrm{v}}^2$		통신 반경 R 안의 서로 다른 노드 순서쌍(통신 호)
파라미터		
Q	5	적재 용량(단위)
R	300 m	통신 반경
κ, ℓ, h	10스텝, 138.9 m, 98.2 m	기간 길이, 기간당 비행 거리, 격자 간격
$\bar{T}$		기간 단위 지평, 휴리스틱 makespan 의 1.15배
ε	10^{-5}	동점 처리 가중치
$\mathrm{idx}(j)$		D의 고정 순서에서 목적지 j의 번호
결정변수		
y_{ikt}	$\{0,1\}$	드론 k가 경계 t에 노드 i에 있으면 1
s_{jkt}	$\{0,1\}$	드론 k가 기간 t에 목적지 j에 배송하면 1
r_{kt}	$\{0,1\}$	드론 k가 기간 t에 센터에서 재적재하면 1
q_{kt}	$\{0, \ldots, Q\}$	경계 t에 드론 k의 적재량
ρ_{kt}	$[0, Q]$	기간 t에 드론 k가 실은 양
g_{ijt}	$[0, N]$	기간 t에 호 (i, j) 위의 연결성 흐름
u_{it}	$\{0, \ldots, N\}$	경계 t에 노드 i의 점유, $u_{it} = \sum_k y_{ikt}$, 단 $u_{0t} := 1$
C	$[0, \bar{T}]$	기간 단위 makespan

모형 읽기. 목적함수 (3)는 makespan C를 최소화한다. 둘째 항은 가중치 $\varepsilon \bar{T} N \ll 1$의 동점 처리 항으로, 놀고 있는 드론을 센터에 두는 계획을 선호하되 최적 makespan 을 바꾸지 못한다.

위치와 이동, (4)–(6). 모든 드론은 매 기간 경계에 정확히 한 노드에 있고 센터에서 출발한다. 드론이 경계 $t+1$에 노드 i에 있으려면 경계 t에 i 자신 또는 한 기간 안에 i에 닿는 노드에 있어야 한다. 모든 이동이 정확히 한 기간이므로 모든 드론의 위치가 모든 경계에서 정의되며, 아래 연결성 제약이 바로 그것을 필요로 한다.

배송, 적재, 재적재, (7)–(12). 각 목적지는 정확히 한 번 배송된다 (7). 기간 t의 배송은 드론이 그 기간의 양 끝 경계에서 목적지에 있을 것을 요구한다 (8). 이것이 3절의 서비스 지연으로, 드론은 한 기간 동안 정지한다. 재적재도 마찬가지로 센터에서 한 기간을 통째로 쓴다 (9). 드론은 기간당 서비스를 최대 하나만 하고 실은 것만 배송할 수 있으며 (10), 적재량은 가득 찬 상태에서 시작해 (11)로 추적되고, 재적재는 드론을 완전히 채운다 (12). ρ_{kt}는 재적재 기간에만 양수일 수 있고 그 다음 적재량은 Q여야 하기 때문이다.

다중 홉 연결성, (13)–(14). 이 두 제약족이 이 모형을 드론 경로 모형과 구별하는 부분이다. 매 기간 점유된 모든 노드가 한 단위의 흐름을 내보내고, 센터가 유일한 흡수원이며, 호는 점유된 노드에서 나갈 때만 흐름을 실을 수 있다. 이 체계는 모든 점유 노드가, 중간 노드가 모두 점유되고 연속 거리가 R 이하인 경로로 센터와 이어질 때 그리고 그때만 실행 가능하다. 즉 그 기간 경계에서 시뮬레이터의 다중 홉 연결성 판정이 통과할 때와 정확히 같다. 증명은 짧다. 그런 경로가 있으면 각 노드의 단위를 그 경로로 보내면 두 제약족이 만족된다. 거꾸로 점유되지 않은 노드 $i \neq 0$은 (14)에 의해 나가는 모든 호에서 $g_{ijt} = 0$이고 따라서 (13)에 의해 들어오는 흐름도 없으므로, 모든 흐름은 점유 집합 안에서만 움직이고, 보존 행이 없는 노드가 센터뿐이므로 흐름 분해가 필요한 경로를 준다. 거울상 용량 행 $g_{ijt} \le N u_{jt}$는 함의되므로 생략해 지배적인 행 수를 절반으로 줄였다. 이 제약이 문제에 무엇을 하는지 보자. 배송할 것이 없는 드론도 동료가 홉으로 필요로 하면 센터에서 그냥 기다릴 수 없고, 어떤 드론도 모든 점유 노드로부터 R보다 멀어지는 목적지로 날 수 없다. 따라서 중계는 별도의 임무가 아니라 편대가 어디 있는지의 귀결이다.

makespan 과 대칭, (15)–(16). makespan 은 모든 배송의 기간 이상이다. 드론이 동일하므로 어떤 계획이든 드론 k가 번호 k 미만의 목적지를 배송하지 않도록 재명명할 수 있다. (16)은 이 순서를 강제하며 어떤 목적값도 잃지 않는다.

최적값의 뜻. 모형의 최적값은 이산화된 문제에 대해 정확하다. 3절의 연속 문제에 대해서는 상한이다. 드론이 격자 노드에 묶이고 축 방향 이동이 짧아지므로 모든 격자 계획은 실행 가능한 연속 계획이지만 그 역은 아니며, 연속 제어기는 격자 최적값보다 빠를 수 있다. 솔버의 쌍대 하한은 격자 문제에 대한 하한일 뿐이다. 격자 노드를 칸으로 보고 칸 사이 최소 거리로 통신을 판정하는 칸 완화를 통한 증명된 하한은 시도했다가 포기했다. 3홉 사슬의 도달 거리를 900 m에서 1,317 m로 부풀려 자명한 해석적 하한보다 낮은 값을 내기 때문이다. 따라서 솔버의 값을 참조 계획이라 부르고, 모든 계획을 연속 시뮬레이터에서 재생해 재생된 makespan 을 보고한다.

4. 제안 제어기

그림 2에 설정과 두 제어기를 요약했다. 두 제어기는 목표 수준에서 결정한다. 매 결정 시점에 각 드론은 목표(목적지, 센터, 또는 중계 슬롯)를 받고 다음 결정 시점까지 그곳으로 전속

직진한다. 두 제어기는 목표를 고르는 방식만 다르다. 옵션 집합, 하위 비행, 중계 슬롯의 기하, 연결성 투영은 공유하며 이를 먼저 설명한다.

4.1. 공유 인터페이스: 옵션, 중계 슬롯, 투영

결정 시점과 옵션. 결정 시점은 20스텝마다 오고, 어떤 드론의 목표가 무효해지는 즉시도 온다. 목표가 무효해지는 경우는 다른 드론이 그 목적지를 배송했을 때, 목적지로 가는 중 적재가 떨어졌을 때, 센터로 가는 중 가득 찼을 때, 속한 사슬이 짧아져 중계 슬롯이 사라졌을 때다. 결정 시점에 모든 드론은 $K = 7$개 옵션 중 하나를 받는다. 다섯 후보 목적지(그 드론에서 가장 가까운 미배송 목적지 다섯 곳) 중 하나, 센터로 복귀, 또는 중계. 옵션은 그 순간 말이 될 때만 유효하다. 목적지 옵션은 적재와 후보가 있어야 하고, 복귀는 가득 차지 않았어야 하며, 중계는 빈 중계 슬롯(다음에 정의)과 자신이 중계 중이 아닌 동료가 적어도 하나 있어야 한다. 무효 옵션은 학습 정책에서는 마스크되고 휴리스틱은 애초에 내지 않으며, 유효 옵션이 없는 드론은 센터로 복귀한다.

중계 슬롯. 중계 드론이 서는 자리는 제어기가 아니라 환경이 정한다. 드론 i의 전선 f_i는 다른 드론들의 배송 목표와 중계 중이 아닌 다른 드론들의 현재 위치 중 센터에서 가장 먼 점이다(없으면 가장 먼 미배송 목적지). 거리 d의 f_i까지 사슬에는 $n = \min(\lceil d/(0.9R) \rceil - 1,\ N - 1)$개의 중계 슬롯이 필요하고, 슬롯은 센터에서 f_i까지의 선분 위 길이의 $1/(n+1), \ldots, n/(n+1)$ 지점에 놓인다. 계수 0.9는 슬롯에서 약간 벗어나 선 드론이 링크를 끊지 않도록 여유를 둔 것이다. 드론 i는 자신에게 가장 가까운 빈 슬롯을 차지한다. 슬롯이 사라진 드론은 다음 결정 시점까지 제자리에 머문다. 따라서 제어기는 드론이 중계할지 여부만 결정하며 슬롯은 편대의 기하에서 따라 나온다.

하위 비행과 연결성 투영. 매 스텝 각 드론은 목표 방향으로 길이 v의 변위를 명령한다(서비스 중에는 0). 연결성을 보상 벌점으로 강제하면 어떤 행동으로도 막을 수 없는 상황을 벌하게 된다. 예컨대 하역 중 정지한 드론은 동료가 떠나면 고립된다. 따라서 연결성은 투영으로 강제한다. 명령된 위치가 G_t를 연결 상태로 두면 그대로 적용한다. 아니면 투영은 움직이는 드론 하나를 고르고, 그 변위를 편대가 연결되는 $[0, 1]$ 안의 최대 배율로 줄이며(다른 드론들의 현재 배율을 고정한 채 이분 탐색), 편대가 연결되는 즉시 멈추는 과정을 반복한다. 매 회차 제한했을 때 연결된 드론이 가장 많이 남는 드론을 고르고, 특정 앵커 드론이 굶지 않도록 동점은 무작위로 깬다. 직전 위치는 항상 연결 상태이므로 배율 0은 유효한 대안이고 제약은 구조적으로 성립한다. 변위가 10% 아래로 축소된 드론은 그 스텝에 정체한 것이고, 움직이는 드론 중 최대 한 대를 뺀 나머지가 정체한 스텝을 부분 교착이라 하며, 연속 부분 교착 스텝 수 δ_t가 휴리스틱의 탈출 장치가 감시하는 양이다. 이 투영은 변위를 그 자체의 방향으로 줄인다. 접선 성분을 남기는 변형은 6.3절에서 다룬다.

4.2. 교착 탈출을 갖춘 기하 사슬 중계 휴리스틱

휴리스틱은 매 결정 시점에 평가되는 결정론적 규칙이다(절차 1). 먼저 모든 드론에 기본값을 준다. 적재가 있는 드론은 가장 가까운 미배송 목적지로, 없는 드론은 센터로. 그 다음 선두, 즉 적재가 있는 드론 중 센터에서 가장 먼 드론을 고르고, 선두의 목표에 몇 홉이 필요한지 계산한 뒤 나머지 드론 중 먼 것부터 그 수만큼을 중계로 돌린다. 중계 수는 적응적이고 중계는 사슬이 서야 할 곳에 이미 가장 가까운 드론들이라 규칙이 싸다. 결정당 비용은 $O(N \log N)$이고 구현에서 0.05–0.12 ms다.

교착 탈출. 규칙은 결정론적이라 어떤 기하가 편대를 정체시키면 매 결정 시점에 같은 배정을 다시 내고 정체가 지속된다. 탈출 장치가 없으면 규칙은 표준 인스턴스의 62%만 완주한다. 탈출 장치는 시간제 덮어쓰기다. 편대가 k_{stall}스텝 이상 연속 부분 교착이고 진행 중인 탈출이 없는 첫 결정 시점에 시작한다. h_{hold}회의 결정 시점, 즉 대략 $20\,h_{\text{hold}}$스텝(목표가 일찍 무효해지면 더 짧게) 동안 지속되며, 그 결정 시점들에서 규칙은 평소처럼 평가된 뒤 6단계처럼 덮어써진다. 횟수 e가 0이 되면 끝나고 평범한 규칙이 재개되며, 교착이 계속되면 다음 결정 시점에 다시 시작할 수 있다. 두 모드를 구현했다. 선두 교대에서는 현재 선두를 센터로 돌려보내고 선두 역할이 다른 드론에게 넘어간다. 한 에피소드의 m번째 탈출에서는 m번째로 먼 드론이 선두가 되어 반복 탈출이 같은 두 드론을 맞바꾸는 대신 편대를 순환한다. 후퇴에서는 선두를 제외한 전원이 센터 쪽으로 복귀해 사슬이 느슨해진다. 모드와 두 파라미터는 6.4절에서 튜닝 시드로 고르며, 모든 비교에 $k_{\text{stall}} = 120$, $h_{\text{hold}} = 20$의 선두 교대를 쓴다.

4.3. 계층형 학습 정책

학습 제어기는 계층형이다(그림 3). 상위 관리자는 결정 시점에만 행동해 드론마다 옵션 하나를 내고, 하위는 4.1절의 공유 직진 비행이다. 따라서 관리자의 선택은 20스텝 동안 유지되고 관리자가 푸는 문제는 옵션 위의 반 마르코프 결정 과정이다 [21]. 학습되는 것은 관리자뿐이다. 두 층의 분리는 나머지 설계가 기대는 두 귀결을 낳는다. 관리자는 대형을 유지할 수 있는 거친 시간 척도로 편대를 보고, 하위는 고정 규칙이라 학습 없이 추론하고 연결성에 대해 투영할 수 있다.

집합 기반 인코더. 관리자는 드론 i를 네 종류의 엔티티로 부호화하며 모든 거리는 R로 나눈다. 자기 상태(10개 특징: 적재 비율, 센터 거리, 홉 깊이, 미배송 비율, 시각, 실현 이동 비율, 정체 지표 둘, 서비스 타이머, G_t의 절단점 여부), 후보 목적지 다섯(각 6개 특징: 거리, 방향, 동료가 이미 겨냥했는지, 센터 거리, 필요 홉 수), 동료($N - 1$개 엔티티, 각 9개 특징: 상대 위치, 적재, 홉 깊이, 동료 현재 역할의 원핫), 중계 슬롯(4개 특징: 거리, 단위 방향 벡터의 두 성분, 현재 사슬의 슬롯 수). 엔티티 종류별로 폭 128의 2층 MLP를 통과시킨다. 드론 자신의 임베딩을 질의로 두 다중 헤드 어텐션 층(헤드 4)이 동료 집합과 후보 집합을 벡터 하나씩으로 풀링하고, 네 벡터를 이어 붙여 MLP로 융합해 드론 임베딩 h_i를 만든다. 포인터 헤드는 $[h_i;\ e_{\text{cand}}]$로 후보 각각을 점수 매기고 고정 헤드는 h_i로 복귀와 중계를 점수 매기며, 일곱 점수는 마스크 후 소프트맥스로 정규화한다. 네트워크 어디에도 N이나 M에 의존하는 것이 없어 한 가중치가 본 적 없는 편대에서 돈다.

자기회귀 결정. N개 옵션은 독립적으로 표본하지 않는다. 드론을 센터 거리 내림차순으로 정렬해 먼 드론부터, 관리자가 첫 드론의 옵션을 표본하고 그 새 역할을 남은 드론들이 보는 동료 특징의 역할 원핫에 써넣은 뒤 다시 부호화해 다음 드론을 표본하는 식으로 진행한다(절차 2). 선두 하나와 중계 k대의 대형은 독립 표본으로는 우연히만 나오지만 순차 결정에서는 의도적으로 구성할 수 있다. 대가는 결정 1회에 N번의 순차 네트워크 호출이다.

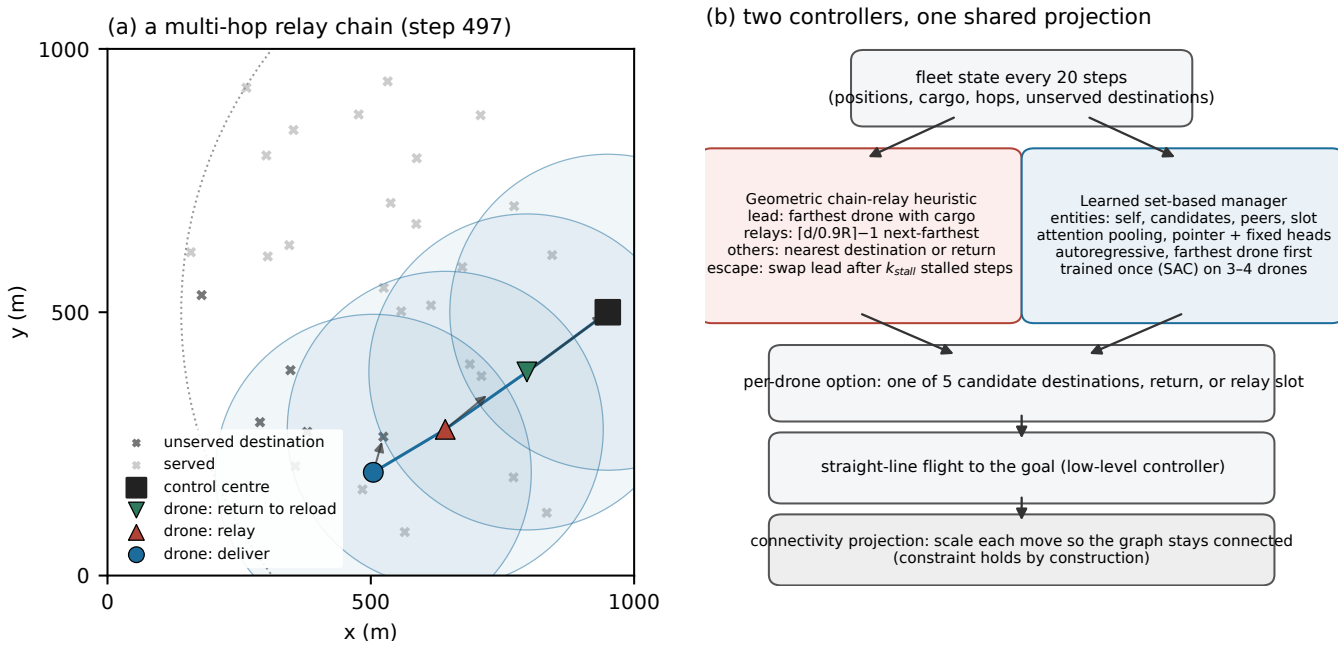


그림 2: (a) 드론 3대 인스턴스에서 휴리스틱으로 497스텝 진행한 상태. 선두 드론(파란 원)이 먼 목적지로 향하고, 한 대가 센터까지의 선분 위에서 중계하며(빨간 삼각형), 한 대는 재적재를 위해 센터로 복귀한다(초록 삼각형). 음영 원판은 통신 반경, 점선 원은 도달 영역 $0.9NR$이다. (b) 두 제어기는 같은 드론별 옵션을 내고 직진 하위 제어기와 연결성 투영을 공유한다.

절차 1. 교착 탈출을 갖춘 기하 사슬 중계 휴리스틱. 매 결정 시점에 실행한다. 호출 사이에 유지하는 상태: 남은 탈출 길이 e(초기 0)와 탈출 횟수 m(초기 0), 둘 다 에피소드 시작에 초기화. 파라미터: $k_{\text{stall}} = 120$, $h_{\text{hold}} = 20$, 모드 $\in$ {선두 교대, 후퇴}.

1. **탈출 발동.** 편대가 $\delta_t \geq k_{\text{stall}}$스텝 연속 부분 교착이고 $e = 0$이면 $e \leftarrow h_{\text{hold}}$, $m \leftarrow m + 1$.
2. **기본 배정.** 각 드론 i에 대해: 적재가 없으면 옵션 $\leftarrow$ 복귀; 미배송 후보가 없으면 옵션 $\leftarrow$ 중계; 아니면 옵션 $\leftarrow$ 가장 가까운 미배송 목적지.
3. **선두.** 미배송 목적지가 없으면 종료. 아니면 $r_i = \|p_i - c\|$라 하고, 적재가 있는 드론 중 r_i를 최대화하는 드론을 선두로(적재가 있는 드론이 없으면 r_i 최대 드론).
4. **중계 수.** d_{goal}을 선두의 가장 가까운 미배송 목적지라 하고 $d = \max(r_{\text{lead}}, \|d_{\text{goal}} - c\|)$, $n = \min(\max(1, \lceil d/(0.9R) \rceil) - 1,\ N - 1)$.
5. **중계 선정.** 선두 외 드론을 r_i 내림차순으로 정렬해 앞의 n대의 옵션을 중계로.
6. **탈출 기동**($e > 0$일 때만; 그러면 $e \leftarrow e - 1$). 선두 교대: 전체 드론을 r_i 내림차순으로 정렬해 그 순서의 $\min(m, N-1)$번째(0부터 셈) 드론을 새 선두로 하고, 이전 선두의 옵션을 복귀로, 새 선두가 적재와 미배송 후보가 있으면 그 옵션을 가장 가까운 미배송 목적지로. 후퇴: 선두를 제외한 모든 드론의 옵션을 복귀로.
7. 옵션을 반환; 환경이 이를 목표로 바꾸고 중계 슬롯을 배정.

학습. 관리자는 옵션 전이에 대해 이산 soft actor-critic [16]으로 학습한다. 전이 하나는 결정 시점의 편대 관측, N개 옵션, 다음 결정 시점까지의 스텝에 걸쳐 누적한 옵션 수익 $\sum_\tau \gamma^\tau r_\tau$, 그 시점의 관측, 그리고 스텝당 $\gamma = 0.997$의 할인 $\gamma^{\Delta t}$를 저장한다. 팀 보상은 배송당 $+10$, 재적재당 $+30$, 스텝당 $-0.01N$, 미배송 비율에 비례하는 잔여 벌점 $-0.1N$이다. 드론 임베딩 사이에 어텐션을 둔 twin-Q critic이 드론별 행동가치를 내고 그 드론 평균을 옵션 수익에 회귀하며, actor는 드론별로 표준 기대값 형태 $\mathbb{E}_{a\sim\pi}[\alpha \log \pi(a) - Q(a)]$를 자기회귀 순서의 교사 강제로 최소화한다. 조리법의 세 요소가 중요하며 6.4절에서 절제한다. (i) 엔트로피 목표를 처음 400 에피소드 동안 $0.6 \log n_{\text{valid}}$에서 $0.25 \log n_{\text{valid}}$로 선형 감쇠시킨다. 높은 목표는 학습 초기에 정책을 교착에서 벗어날 만큼 무작위하게 유지하고 낮은 목표는 후기에 여러 스텝의 대형을 지키게 한다. (ii) 가중치 2.0의 교차엔트로피 항이 휴리스틱의 배정 규칙(절차 1의 2–5단계, 탈출 없이)이 택할 옵션 쪽으로, 그 옵션이 유효한 곳에서, 정책을 당긴다. (iii) 모든 학습 에피소드는 $N \in \{3, 4\}$, $M \in [20, 80]$, 무작위 거점을 뽑는다. 최적화는 Adam 3×10^{-4}, 재생 버퍼 60,000에서 전이 256개 배치, 400개 전이의 워밍업 후 환경 4스텝마다 경사 1회, $\tau = 0.005$의 목표 critic Polyak 평균을 쓴다. 체크포인트는 50 에피소드마다 3,000스텝 예산의 홀드아웃 80개에서 $100f + 40(1 - \bar{t}/3000)$으로 고른다($f$는 완주율, $\bar{t}$는 평균 스텝). 학습은 8회 연속 평가에서 갱신이 없거나 1,000 에피소드에서 멈춘다. RTX 5080 하나를 네 실행이 나눠 쓸 때 한 실행에 약 13시간이 든다.

5. 실험 설계

인스턴스와 구성. 인스턴스는 정수 시드로 생성되며 시드·N·M·거점 모드가 인스턴스를 정확히 결정하므로 두 제어기를 동일 인스턴스에서 돌릴 수 있다. 평가 시드는 학습·체크포인트 선택·휴리스틱 튜닝에 쓴 시드와 겹치지 않는다. 표준 구성($N = 4$, $M = 50$, 고정 거점)과 무작위 거점의 미지 구성 여덟 개 $N/M \in \{3/20, 3/30, 4/80, 5/50, 6/80, 8/150, 10/300, 12/400\}$에서 평가한다.

베이스라인. 학습 없는 베이스라인 넷이 문제가 단순 배정으로 풀리지 않음을 보인다. 모두 4.1절의 공유 인터페이스를 쓰고 같은 결정 시점에 평가된다. 탐욕, 중계 없음은 절차 1의 2단계만이다. 적재가 있는 모든 드론은 가장 가까운 미배송 목적지로 날고 빈 드론은 복귀하며 아무도 중계하지 않으므로

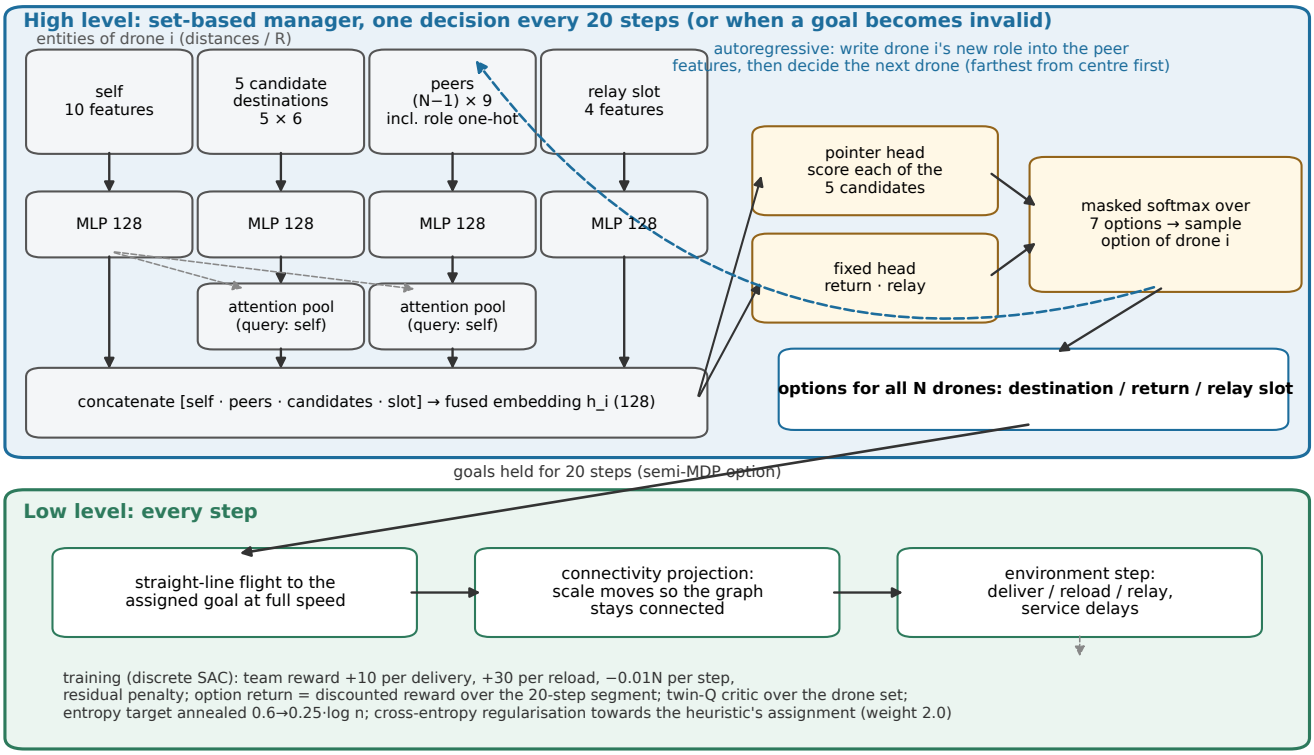


그림 3: 계층형 학습 제어기. 상위: 집합 기반 관리자가 각 드론을 네 종류의 엔티티로 부호화하고, 드론 자신의 임베딩을 질의로 동료 집합과 후보 집합을 어텐션 풀링하며, 포인터 헤드로 후보 다섯을, 고정 헤드로 복귀·중계를 점수 매긴다. 드론은 센터에서 먼 것부터 하나씩 결정되고 각 결정은 다음 드론이 보는 동료 특징에 써넣어진다. 하위, 매 스텝: 배정된 목표로의 직진 비행, 연결성 투영, 환경 스텝. 옵션은 20스텝 동안 유지된다.

절차 2. 결정 시점의 학습 관리자(추론).

1. 편대 상태로부터 모든 드론의 엔티티 관측을 만들고, 모든 드론의 일곱 옵션 유효성 마스크를 계산한다(4.1절).
2. 드론을 센터 거리 내림차순으로 정렬한다.
3. 그 순서로 각 드론 i에 대해: 현재 동료 역할로 모든 엔티티를 부호화하고, 드론 i의 마스크된 로짓 일곱을 계산하고, 소프트맥스에서 옵션을 표본하며(배치 추론은 argmax가 아니라 표본 추출), 선택된 역할(배송·복귀·중계)을 아직 결정되지 않은 드론들이 보는 드론 i의 동료 역할 원핫에 써넣는다.
4. N개 옵션을 반환; 환경이 이를 목표로 바꾸고 중계 슬롯을 배정한다.

사슬은 투영만으로 유지되어 편대가 정체한다. 고정 중계 한 대(두 대)는 편대의 처음 한(두) 대를 영구 중계로 배정하고 나머지에 탐욕 규칙을 돌린다. 중계 수가 선두의 거리에 적응하지 않고 미리 고정된다. 기하 규칙, 탈출 없음은 절차 1에서 6단계를 뺀 것이다. 학습 없는 제어기는 투영의 무작위 동점 처리를 제외하면 모두 결정론적이다.

참조 모형. 작은 인스턴스는 3.1절의 격자 모형을 Gurobi 13 [26], 스레드 6개로 푼다. 시간 제한은 6.2절의 결과와 함께 적는다. 돌려준 모든 계획은 연속 시뮬레이터에서 재생한다.

쌍별 규약. 각 방법이 완주한 에피소드만 평균하면 어려운 인스턴스를 포기하는 쪽이 유리해지고, 긴 정체 한 건이 40롤아웃 평균을 100스텝 넘게 움직인다. 따라서 두 제어기 사이의 모든 비교는 쌍별이다. 둘을 같은 인스턴스에서 돌리고 둘 다 완주한 인스턴스에서 차이를 취해, 쌍별 차이의 중앙값, 승–패 수, 윌콕슨 부호순위 p값을 보고한다. 추론은 정책에서 표본한다. 결정론적 argmax 추론은 중앙값이 같지만 꼬리가 훨씬 무겁다. 표준 구성은 480롤아웃(60시드, 8회 반복, 두 번의 독립 측정), $3/30$과 $5/50$은 200(40시드, 5회), 나머지는 80(40시드, 2회)이다. 투영의 동점 처리가 무작위라 반복마다 결과가 다르다. 40롤아웃은 꼬리에 관한 어떤 주장도 뒷받침하기에 부족했다.

6. 결과

6.1. RQ1: 하드 제약 아래의 완주

투영이 보장하는 대로 어떤 학습 에피소드와 평가 롤아웃에서도 연결성은 위반되지 않았다. 표 2은 10,000스텝 예산 안의 완주를 보고한다. 학습 정책은 모든 구성의 모든 인스턴스를 완주한다. 탈출 장치를 갖춘 휴리스틱은 98–100%를 완주하며, 놓치는 경우는 드론이 넉넉한 구성에 몰린다. 필요하지 않은 긴 사슬을 그대로 세워 두다가 정체하는 경우다. 탈출 장치가 없으면 규칙은 표준 인스턴스의 61.7%를 완주하고, 단순 베이스라인은 거의 완주하지 못한다. 탐욕 배정은 편대를 잡아당겨 찢고, 고정 중계 대수는 목적지가 필요로 하는 중계 수가 거리에 따라 달라 대부분의 인스턴스에서 틀린다.

6.2. RQ2: 격자 참조 계획과의 거리

표 3와 그림 4는 드론 3대의 34개 인스턴스에서 두 제어기를 격자 참조와 비교한다. $M \in \{4, 6, 8\}$ 각 10개와 $M = 10$ 4개이며 시간 제한은 $30 \cdot 60 \cdot 120 \cdot 120$분, 솔버 스레드는 6개다. 솔버가

표 2: 10,000스텝 예산 안의 완주. 무학습 베이스라인은 120(표준) 또는 40(미지) 롤아웃, 제안 제어기 둘은 5절의 쌍별 롤아웃 수.

방법	4/50 표준	3/30	5/50
탐욕, 중계 없음	0%	0%	25%
중계 1대 고정	0%	2.5%	40%
중계 2대 고정	3.3%	52.5%	65%
규칙, 탈출 없음	61.7%	95%	92.5%
규칙 + 탈출 (제안)	473/480	200/200	191/200
학습 (제안)	**480/480**	**200/200**	**200/200**
	3/20	4/80	6/80
규칙 + 탈출 (제안)	80/80	80/80	79/80
학습 (제안)	**80/80**	**80/80**	**80/80**
	8/150	10/300	
규칙 + 탈출 (제안)	80/80	80/80	
학습 (제안)	**80/80**	**80/80**	

각 인스턴스에서 이룬 것을 세 수로 적는다. 계획은 시간 제한 안에 돌려준 격자 모형의 실행 가능 해이고, 그 계획을 노드 열을 목표로 내려 연속 시뮬레이터에서 재생하되 재생이 모든 목적지를 배송할 때만 재생된 것으로 센다($M = 8$의 계획 하나는 연속 투영과 격자의 한 기간 이동이 정확히 일치하지 않아 재생에서 8곳 중 7곳만 배송했고, 계획은 있으나 재생되지 않은 것으로 센다). 최적은 솔버가 격자 모형의 최적성 갭을 닫은 계획이다. 재생된 makespan 이 비교 기준이다.

세 가지가 보인다. 첫째, 솔버의 범위는 목적지 6곳과 8곳 사이에서 끝난다. 4곳은 10건 중 9건의 계획을 돌려주고(그중 4건은 격자 최적이 증명됨), 6곳은 8건, 8곳은 3건, 10곳은 4건 중 0건을 두 시간 안에 돌려준다. 병목은 최적성이 아니라 실행 가능성이며, 돌려준 계획의 남은 갭은 12–36%다. 둘째, 재생된 계획이 있는 곳에서 두 제어기는 그에 가깝다. 휴리스틱의 makespan 은 4·6·8곳에서 계획의 평균 1.00, 1.07, 1.07배이고, 학습 정책의 인스턴스별 중앙값은 평균 0.94, 0.99, 0.91배다. 격자 최적이 증명된 인스턴스를 포함해 둘 다 계획보다 빠른 경우가 있는데 이는 모순이 아니다. 격자는 드론의 위치를 제한하므로 그 최적값은 연속 최적값의 상한이고 연속 제어기는 그것을 이길 수 있다. 셋째, 학습 정책의 표본은 넓다. 중앙값은 대부분의 인스턴스에서 휴리스틱 이하이지만 30회 표본의 범위는 한 인스턴스에서 5배까지 벌어진다($M = 8$의 한 인스턴스에서 중앙값 206에 최댓값 1,142). 이는 6.3절과 같은 꼬리 거동이다. 따라서 RQ3의 비교는 이 규모에서 정확 기법이 낼 수 있는 최선의 계획과 수 퍼센트 차이인 휴리스틱에 대한 것이고, 참조는 제어기가 필요한 바로 그 규모에서 더 이상 얻을 수 없다.

6.3. RQ3: 환경에 따른 성능

편대 크기가 구성 공간을 나눈다. 표 4와 그림 5이 아홉 구성의 쌍별 비교다. 드론 3대에서는 목적지 20곳과 30곳에서 휴리스틱이 각각 39와 30스텝 빠르다. 4대에서는 동률이다. 표준 구성에서 480롤아웃의 쌍별 중앙 차이는 $+2$스텝, 234승 239패($p = 0.52$)이고, $4/80$에서는 학습 정책이 38스텝 빠르다. 5대 이상에서는 학습 정책이 빠르다. 5대에서 62스텝, 10대에서 178스텝으로 커지고 12대에서는 76스텝이다(70승 10패). 따라서 경계는 드론 4대에 있고, 우위는 측정한 가장 큰 편대 너머까지 이어지되 단조 증가는 10대와 12대 사이에서 멈춘다. $12/400$에서 폭이 좁아지는 원인은 분리하지 못했으며 세 가지 추정을 적어 둔다. 첫째, 두 제어기 모두 선두 하나로의 사슬 하나를 유지하므로 12대에서는 편대 대부분이 제어기와 무관하게 센터 근처에서 배송하고, 둘 사이에 다른 결정은 점점 작은 몫의 일에만 관여한다. 둘째, 목적지 400곳에서는 드론의 후보 다섯이 모두 가까워 그 사이의 선택이 덜 중요해지고, 목표와 중계를 함께 고르는 데 있는 학습 정책의 강점이 작용할 여지가 줄어든다. 셋째, 관리자의 홉 깊이와 슬롯 특징은 상수 8로 정규화되어 큰 편대에서 1을 넘고, 열두 번의 순차 자기회귀 결정은 표본 잡음을 누적하므로 둘 다 정책을 학습 분포에서 더 멀리 떼어 놓는다. 어느 것이 지배적인지는 12대 너머의 편대가 있어야 가릴 수 있다. 휴리스틱의 튜닝 전 탈출 파라미터에 대한 이전 측정도 같은 그림이었으므로($3/30$, $4/50$, $5/50$, $10/300$에서 $+40$, $+0$, -54, -170) 경계는 튜닝에 의존하지 않는다.

그림 6는 세 주요 구성의 전체 분포다. 3대에서는 휴리스틱의 곡선이 왼쪽에 있고, 4대에서는 두 곡선이 겹치며, 5대에서는 학습 정책의 곡선이 왼쪽에 있고 더 일찍 완주에 닿는다.

작은 편대로부터의 일반화. 학습 정책은 학습에서 드론 4대, 목적지 80곳을 넘는 구성을 본 적이 없지만 드론 5–12대, 목적지 50–400곳의 모든 인스턴스를 완주하고 그 전부에서 휴리스틱보다 빠르다. 두 성질이 이를 떠받친다. 집합 기반 인코더에는 N이나 M에 의존하는 매개변수가 없어 큰 편대는 그저 큰 집합일 뿐이고, 학습은 에피소드마다 편대 크기와 거점을 새로 뽑는다. 표 5은 둘을 분리한다. 구성 무작위화 없이 고정 $4/50$ 구성만으로 학습한 절제 정책을 같은 큰 편대 인스턴스에서 재학습 없이 돌린 것이다. 그 정책도 5–10대의 모든 인스턴스를 완주하므로 완주는 구조만으로 일반화된다. 그러나 모든 구성에서 무작위화 정책보다 느리다($5/50$에서 휴리스틱과 동률 대 -62, 그 너머에서 -51에서 -174 대 -122에서 -178). 큰 편대에서의 속도는 작은 편대의 다양성에서 배운다. 같은 절제가 $3/30$에서는 646스텝을 잃으므로(표 9) 무작위화는 작은 편대 쪽을 쓸 만하게 만드는 조건이기도 하다. 두 정책 모두 최대 4대로 학습했고 홉 깊이와 슬롯 특징은 상수 8로 정규화되므로, 10대와 12대 편대는 인코더를 학습 특징값 범위 밖으로도 데려가는데 정책은 여전히 완주한다.

꼬리도 같은 방향으로 갈린다. 드론이 부족하면 학습 정책의 최악은 휴리스틱의 3–4배이고($3/30$에서 최댓값 5,395 대 1,447스텝), 넉넉하면 더 가볍다($5/50$에서 1,101 대 1,734, $10/300$에서 1,365 대 1,753). 튜닝 전 휴리스틱에 대한 표준 구성 480롤아웃에서 학습 정책은 1,500스텝을 다섯 번, 휴리스틱은 열네 번 넘었다.

기제. 두 제어기는 한 결정에서 다르다. $3/30$에서 휴리스틱은 평균 1.39대의 중계를 세우고 학습 정책은 0.78대를 세운다. 그 결과 학습 편대는 드론-스텝의 27%를 투영에 막혀 정체하고 휴리스틱은 8%다. 추론 시 학습 정책의 중계 배정만 휴리스틱의 것으로 덮으면 44스텝 격차 전부가 회복된다. 중계 대수만 맞추면 중앙값은 14스텝만 회복되지만 꼬리는 사라진다(최댓값 4,904에서 1,083). 중계하는 드론의 정체가 중앙값을 만들고 대수가 꼬리를 만든다. 휴리스틱의 선택에 필요한 정보는 학습 정책의 관측에 있다. 2층 분류기가 41개 관측 특징으로 휴리스틱의 중계 배정을 85% 정확도로 예측하고, 규칙 전체의 행동 복제는 중계 결정에서 95%에 이른다. 드론이 넉넉하면 반대 일이 일어난다. 휴리스틱은 기하가 더 이상 요구하지 않는 사슬을 계속 세우는 반면, 학습 정책은 여유를 활용하고

표 3: 드론 3대 인스턴스에서 격자 MILP 참조 대 제안 제어기(스텝 단위, 인스턴스 평균). “계획 / 재생 / 최적”은 솔버가 계획을 돌려준 수, 그 계획이 시뮬레이터에서 완주로 재생된 수, 격자 최적이 증명된 수(갭 0). “갭”은 돌려준 계획의 평균 잔여 최적성 갭, “분”은 평균 풀이 시간. 학습 열은 인스턴스별 30회 표본 중앙값의 평균과 전체 최소–최대. 비율 열은 재생된 인스턴스에서 휴리스틱과 학습 중앙값을 재생 계획으로 나눈 값의 평균.

M	인스턴스	계획 / 재생 / 최적	갭	분	MILP 재생	휴리스틱	학습 중앙값 (범위)	비율 h / l
4	10	9 / 9 / 4	12%	24	112	114	109 (67–250)	1.00 / 0.94
6	10	8 / 8 / 0	34%	60	149	159	150 (103–415)	1.07 / 0.99
8	10	3 / 2 / 0	36%	120	162	188	171 (119–1142)	1.07 / 0.91
10	4	0 / 0 / 0	—	120	—	224	236 (183–427)	—

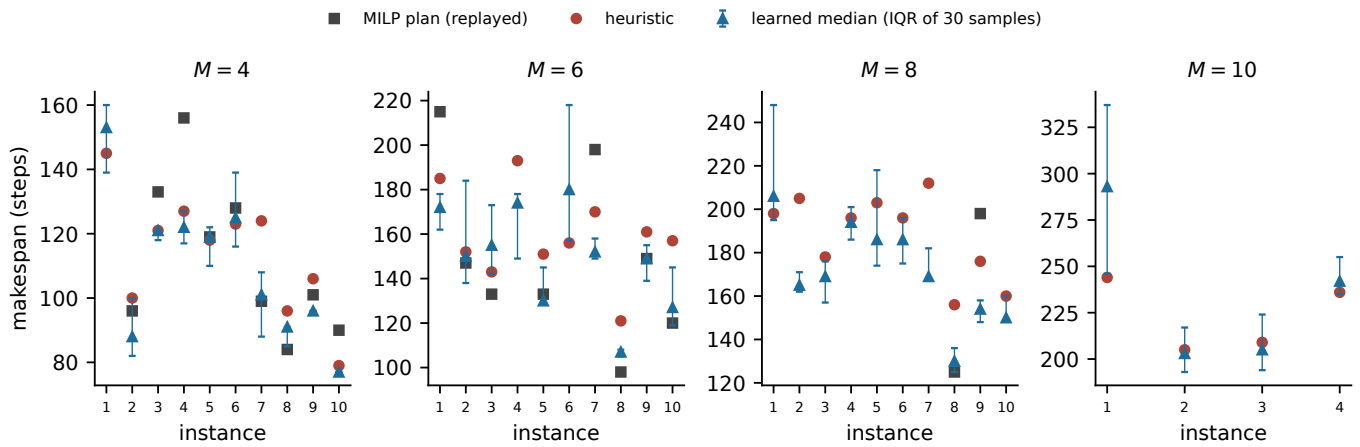


그림 4: 드론 3대 참조 인스턴스의 인스턴스별 makespan. 재생된 MILP 계획(네모, 계획이 없거나 재생이 완료되지 않은 곳은 비움), 휴리스틱(원), 학습 정책의 중앙값과 30회 표본의 사분위 범위(세모).

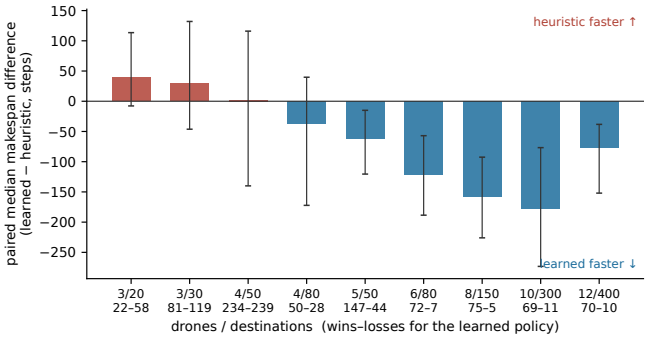


그림 5: 구성별 쌍별 중앙 makespan 차이(학습 – 휴리스틱). 오차 막대는 쌍별 차이의 사분위 범위, 각 라벨 아래는 학습 정책의 승–패. 음수가 학습 정책에 유리하며 경계는 드론 4대에 있다.

표본 추론으로 결정론적 규칙이 반복하는 정체를 빠져나간다. 휴리스틱이 몇 건의 완주를 잃는 곳도 여기다.

드론 부족 영역의 열세가 정책 쪽 처방에 저항하는 이유. 표 6는 드론이 부족할 때 학습 정책이 휴리스틱처럼 중계하게 만들려는 열한 가지 개입이다. 각각 명시한 변경을 제외하면 같은 조리법으로 시드 넷 또는 둘을 학습하고 같은 쌍별 규약으로 평가했다. 표의 번호로 변형은 다음과 같다. (V1) 휴리스틱 쪽 교차엔트로피 정규화를 휴리스틱 옵션이 중계인 드론에 세 배 가중; (V2) 배송하는 동료의 통신 경로 위에 있는 각 드론이 그 배송 때 개별 보상 (2.0 또는 6.0)을 받고 critic 을 드론별 수익으로 학습; (V3) 체크포인트 선택의 홀드아웃 절반을 $4/50$ 대신 $3/30$ 구성으로 채움, 시드 8; (V4) V2와 같되 제로섬으로, 배송 드론이 중계들이 얻는 만큼 잃음; (V5) critic 을 동료들의 선택 역할에 조건화(결합 행동 critic)하고 목표값의 동료 다음 역할은 actor 에서 표본; (V6) 자기회귀 순서를 뒤집어 센터에 가장 가까운 드론부터 결정; (V7) 연속 부분 교착 60스텝 뒤 모든 목표를 무효화해 관리자가 재결정하도록, 학습과 평가 모두에서; (V8) critic 의 드론별 행동가치 평균을 합이 1이고 하한이 $1/2$인 상태 의존 단조 가중치로 대체; (V9) 각 드론의 옵션을 결정 시점 안에서 할인 1로 사슬처럼 이은 단일 에이전트 전이로 저장해 팀 수익의 분해가 필요 없게 함; (V10) 40,000회 결정에 대한 휴리스틱의 행동 복제(정확도 92.5%, 중계 결정 95%)로 관리자를 초기화한 뒤 미세조정, 50 에피소드 critic 워밍업 유무 각각; (V11) 병목 목적지의 추정 도달 시각에 비례하는 스텝당 벌점, 추정값을 각 드론의 실현 이동 비율로 나누어 막힌 드론을 느린 것으로 셈. 어느 것도 $3/30$ 중앙값을 개선하지 못했고 여럿은 학습 정책이 이기는 구성을 해쳤다. 패턴이 시사적이다. 중계에 보상을 더하면 수단이 목적이 된다. 정책이 중계 자체를 위해 중계하고 $5/50$이 -54에서 $+60$으로 뒤집힌다. 드론별 크레딧으로 가는 길은 각기 다른 이유로 막힌다. 결합 행동 critic은 목표값에 표본된 동료 행동의 분산을 물려받고, 단조 혼합망은 가중치가 자유로우면 발산하고 하한을 두면 평균으로 무너지며, 순차 단일 에이전트 재정식화는 분해를 없애지만 수축이 없는 무할인 크레딧 사슬을 남긴다. 규칙의 행동 복제로 정책을 초기화하면(중계 정확도 95%) 400 에피소드 안에 지워진다. actor가 갱신되기 시작하면 50 에피소드 안에 중계 사용이 무작위 초기화 정책의 수준으로 떨어져 머문다. 병목 목적지의 추정 도달 시각에 대한 벌점은 정책이 최댓값이 아니라 평균을 줄이게 만든다. 이 정책 구조와

표 4: 동일 인스턴스에서의 쌍별 비교. 양수는 학습 정책이 휴리스틱보다 느림을 뜻한다. p는 둘 다 완주한 쌍에 대한 윌콕슨 부호순위 검정.

N/M	롤아웃	완주 h/l	중앙값 휴리스틱 / 학습	쌍별 중앙	승–패	p
3/20	80	80/80	364 / 420	+39	22–58	$< 10^{-4}$
3/30	200	200/200	572 / 618	+30	81–119	3.4e-04
4/50 (표준)	480	473/480	878 / 878	+2	234–239	0.521
4/80	80	80/80	1,120 / 1,036	−38	50–28	0.006
5/50	200	191/200	588 / 534	−62	147–44	$< 10^{-4}$
6/80	80	79/80	737 / 614	−122	72–7	$< 10^{-4}$
8/150	80	80/80	916 / 722	−158	75–5	$< 10^{-4}$
10/300	80	80/80	1,216 / 1,052	−178	69–11	$< 10^{-4}$
12/400	80	80/80	1,199 / 1,108	−76	70–10	$< 10^{-4}$

표 5: 학습에서 본 어떤 편대보다 큰 편대로의 재학습 없는 일반화. 셀은 학습 정책의 완주와 휴리스틱 대비 쌍별 중앙 차이. 제안 정책은 무작위 거점의 $N \in \{3, 4\}$로 학습했고, 비교 정책은 고정 $4/50$ 구성만으로 학습한 절제 정책(시드 2개)이다.

N/M	$N \in \{3,4\}$, $M \in [20, 80]$ 학습	$4/50$만 학습, 시드 1	시드 2
5/50	200/200 / −62	80/80 / +7	80/80 / +44
6/80	80/80 / −122	80/80 / −56	80/80 / −51
8/150	80/80 / −158	80/80 / −129	80/80 / −110
10/300	80/80 / −178	80/80 / −152	80/80 / −174

목적함수 안에서 중계 부족은 크레딧·정보·초기화의 인공물이 아니라 학습기의 고정점이라고 결론짓는다.

연결성 강제 모형에 대한 민감도. 4.1절의 투영은 막힌 변위를 같은 방향으로 축소하므로 사슬을 당기는 드론은 사실상 멈춘다. 목표 위치를 구속하는 이웃 주변 통신 원판의 가장 가까운 점으로 당기는 대안을 구현했다. 바깥 방향 성분만 제거하고 접선 성분은 남기므로 드론이 일정 거리를 유지한 채 돌 수 있다. 각 비교에서 두 제어기는 같은 투영을 쓰고 연결성은 여전히 위반되지 않는다. 이 측정은 6.4절의 휴리스틱 튜닝 이전에 두 투영 모두 $k_{\text{stall}} = 60$, $h_{\text{hold}} = 40$으로 한 것이라 내부적으로 일관된다. 같은 학습 가중치를 재학습 없이 접선 보존 투영에서 평가하면 $3/30$ 열세가 $+40$에서 $+21$로 줄고, 네 시드를 재학습하면 $+15$에서 $+48$(평균 $+28$)이 되며 학습 편대의 정체율은 0.27에서 0.17–0.22로 내려간다. 완주는 여전히 100%다. 휴리스틱은 3대에서는 거의 얻지 못하지만(중앙값 570에서 571) 4대에서는 학습 정책보다 더 얻어(866에서 812, 학습은 879에서 850) 표준 구성의 동률이 휴리스틱 쪽 $+26$으로 바뀐다. 따라서 같은 방향 투영을 기본 모형으로 유지하고 이것을 민감도 결과로 보고한다. 3대 열세의 약 절반은 학습기가 아니라 제약을 강제하는 방식의 성질이다.

통신 반경. 두 제어기를 재학습 없이 $R = 250\,\text{m}$와 $R = 350\,\text{m}$에서 돌렸다(표 7, 그림 7). 학습 정책은 거리를 R로 정규화하고 인스턴스 생성기는 도달 영역 $0.9NR$을 R에 맞춰 조정하므로 두 제어기는 각 반경에서 같은 인스턴스를 본다. 완주는 전이된다. 학습 정책은 두 반경 모두에서 모든 인스턴스를 완주하고, 휴리스틱은 짧은 반경의 $5/50$에서 200건 중 18건을 잃는다. 속도에는 두 효과가 나타난다. 첫째는 편대 크기에서 본 영역 이동이다. $R = 250\,\text{m}$에서는 목적지에 더 많은 홉이 필요해 편대가 사실상 부족해지고 모든 구성이 휴리스틱 쪽으로 움직인다($3/30$ $+77$, $4/50$ $+68$, $5/50$의 우위는 -16, $p = 0.33$으로 동률까지 줄어든다). $R = 350\,\text{m}$에서는 편대가 사실상 넉넉해져 학습 정책이 4대에서 이미 빠르다($4/50$ -40). 둘째는 학습 반경 효과다. $3/30$과 $5/50$에서 학습 정책의 격차는 학습한 반경에서 가장 좋고 양쪽에서 나빠진다(300 m의 $+30$ 대 $+77$과 $+52$, -62 대 -16과 -42). R 정규화는 완주를 전이시키지만 속도까지 온전히 전이시키지는 않는다. 따라서 영역 변수는 편대 크기만이 아니라 사슬 수요, 즉 목적지가 필요로 하는 홉 수 대 공급할 수 있는 드론 수이며, 학습 반경에서 먼 반경의 배치는 재학습하거나 적어도 경계를 재평가해야 한다.

6.4. RQ4: 구성 요소는 필수적인가

휴리스틱. 표 8은 $k_{\text{stall}} \in \{30, 60, 90, 120\}$, $h_{\text{hold}} \in \{20, 40, 80\}$, 두 탈출 모드, 그리고 탈출 없음을 $3/30$, $4/50$, $5/50$에서 각 40 튜닝 시드로 격자 탐색한 것이다. 설정은 완주 합 우선, 중앙 makespan 합 차선으로 순위를 매겼고 이 기준은 측정 전에 정했다. 탈출 장치는 필수다. 없으면 규칙은 표준 인스턴스 40건 중 26건을 완주한다. 시점보다 모드가 더 중요하다. 선두 교대 설정은 모두 120건 중 117–120건을 완주하는 반면 후퇴 설정은 100–117건을 완주하는데, 사슬을 느슨하게 해도 정체를 만든 배정이 바뀌지 않기 때문이다. 선두 교대 안에서는 세 구성 합산 중앙값이 최대 40스텝 차이로 40인스턴스의 잡음 안에 있다. 선택된 설정($k_{\text{stall}} = 120$, $h_{\text{hold}} = 20$)은 120건 전부를 완주한 유일한 설정이면서 중앙값 합도 가장 낮다. 적응적 중계 대수도 필수다. 한 대나 두 대로 고정하면 0–65%를 완주한다 (표 2).

학습 정책. 표 9은 요소를 하나씩 빼고 시드 둘을 재학습해 세 주요 구성에서 평가한 것으로, 값은 제안 조리법 대비 makespan 차이다. 같은 조리법을 네 번 독립 학습하면 표준 구성에서 919에서 979스텝까지 흩어지므로 시드 2개 평균은 70–80스텝을 넘을 때만 의미가 있다. 규칙 정규화와 구성 무작위화는 필수이고, 엔트로피 감쇠는 표준 구성에서 가장 큰 단일 기여이며, 자기회귀 결정은 4대 이상에서 돕고, 잔여 벌점은 중립이다. 초기 버전에서 표준 구성만으로 학습한 고정 크기 MLP 인코더의 상위 정책은 표준 인스턴스의 38%를 완주했고 다른 편대 크기에서는 아예 돌릴 수 없었다.

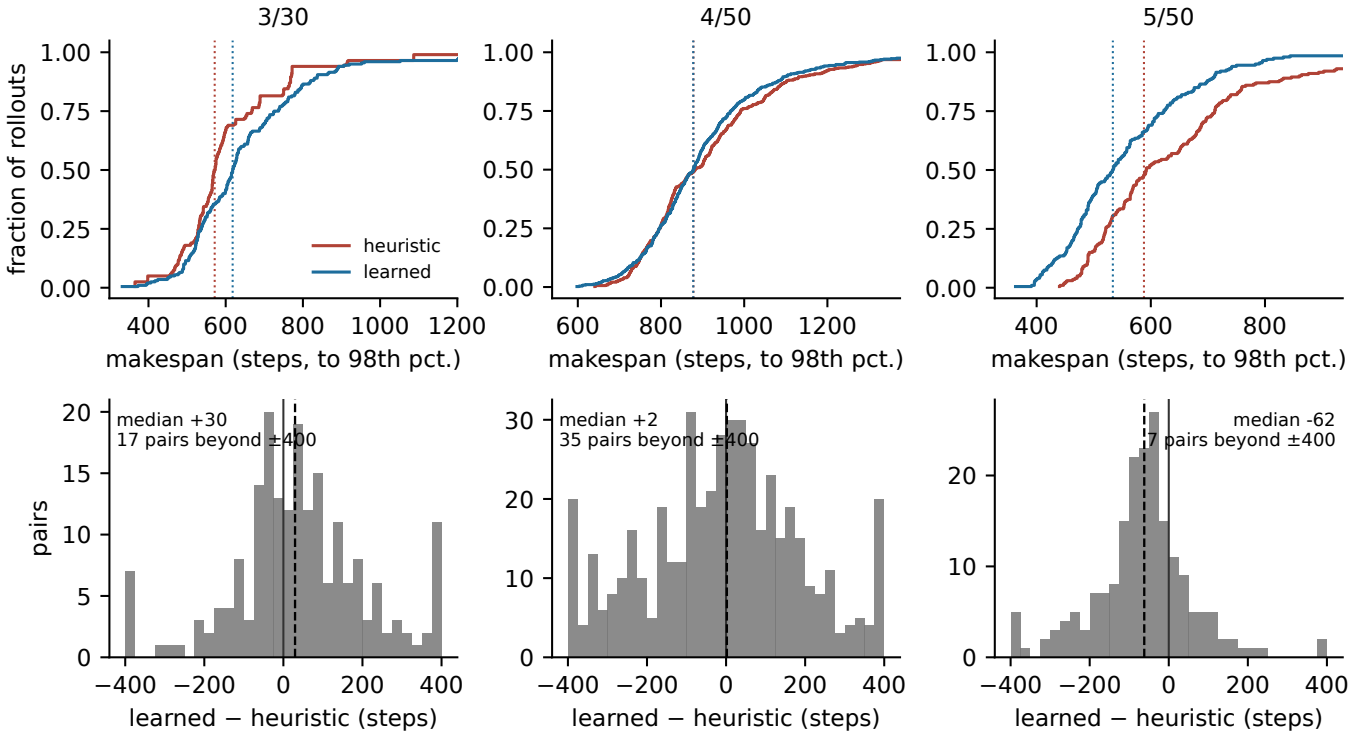


그림 6: 위: 3/30, 4/50, 5/50의 makespan 누적분포(점선은 중앙값, 축은 98 백분위에서 자름). 아래: 둘 다 완주한 인스턴스의 쌍별 차이 분포(±400스텝에서 잘랐으며 잘린 쌍 수를 표기).

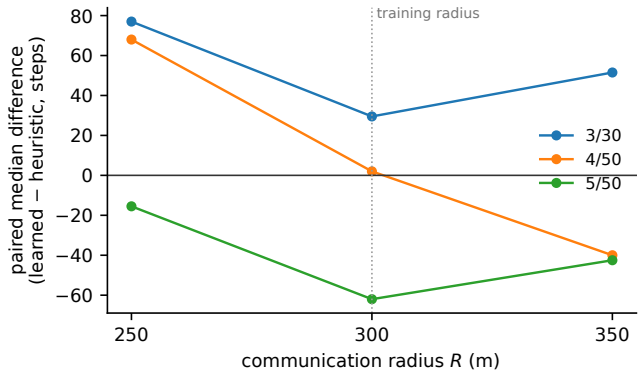


그림 7: 재학습 없는 통신 반경별 쌍별 중앙 차이(학습 반경 300 m, 점선). 짧은 반경은 모든 구성을 휴리스틱 쪽으로 옮기고, 긴 반경은 4/50에서 학습 정책을 돕지만 3/30과 5/50에서는 학습 반경의 격차를 넘지 못한다.

6.5. 추론 비용

표 10는 CPU에서 상위 결정 1회의 지연이다. 휴리스틱은 0.05–0.12 ms, 학습 정책은 자기회귀 없이 1.3–2.5 ms, 자기회귀로 2.7–7.4 ms이며 드론마다 순차 네트워크 호출이라 편대에 선형으로 커진다. 900스텝 에피소드에서 학습 정책의 누적 결정 시간은 0.16 s다. 격자 MILP는 목적지 4–10곳 인스턴스에서 600–5,400초가 걸리고 10곳에서는 계획을 내지 못한다.

7. 논의

배치. 두 제어기는 상보적이고 경계가 뚜렷하므로 운영자는 편대 크기로 고를 수 있다. 드론 3대면 휴리스틱, 5대 이상이면 더 빠르고 더 신뢰할 수 있는 학습 정책이며, 4대에서는 둘이 동률이고 학습 정책이 더 많이 완주한다. 둘 다 밀리초에 결정하고 둘 다 구조적으로 편대의 연결을 지킨다.

음성 결과의 의미. 학습기의 크레딧·정보·초기화·보상을 바꾸는 열 개입이 드론 부족 영역의 열세를 그대로 두었고, 환경의 강제 모형을 바꾸자 절반이 사라졌다. 따라서 이 열세는 더 학습하거나 더 나은 critic으로 고칠 결함이 아니라, 이 목적함수 아래 학습기의 고정점과 제약의 기하 사이의 상호작용으로 이해하는 것이 맞다. 실무자에게 실행 가능한 결론은 위의 것 하나다. 영역에 따라 제어기를 고르라.

한계. 학습 정책은 하나의 통신 반경에서 학습했다. 250과 350 m로 완주는 전이되지만 휴리스틱 대비 속도 순위는 반경에 따라 바뀌며(6.3절), 그 밖의 반경은 시험하지 않았다. 환경은 평면이고 바람·배터리·충돌을 무시하며 원판 통신 모형을 쓴다. 실제 링크는 원판이 아니다. MILP 참조는 최적성 갭이 남은 격자 제한이지 정확한 최적값이 아니다. 휴리스틱의 참신성은 사슬 기하 자체보다 탈출 장치와 적응적 중계 대수에 있다.

방법론적 주석. 결론에 중요했던 세 실천이 있다. 완주 에피소드 평균은 포기하는 제어기에 유리하므로 비교는 쌍별이어야 한다. 40롤아웃은 꼬리에 관한 주장을 뒷받침하지 못하며, 우리 자신의 중간 결론 여럿이 표본이 커지자 뒤집혔다.

표 6: 드론 부족 영역의 열세를 제거하지 못한 개입들, 본문의 번호와 같음. 휴리스틱 대비 쌍별 중앙값(양수가 느림), 제안 조리법이 기준 행, 값 둘은 시드 둘이고 범위는 시드 또는 가중치에 걸친 폭. 이 실행들은 튜닝 전 탈출 파라미터($k_{\text{stall}} = 60$, $h_{\text{hold}} = 40$)의 휴리스틱에 대해 평가되었으므로 이 표의 기준 행과는 비교 가능하지만 튜닝된 휴리스틱을 쓴 표 4와 수치가 같지는 않다.

#	개입 (무엇을 바꿨나)	3/30	5/50	4/50	실패 기제
—	제안 조리법 (기준)	+40	−54	+0	—
V1	중계 가중 규칙 정규화 (중계 ×3)	+54, +56	−44, −19	+41, +54	중계 특화 정규화는 해로움
V2	드론별 중계 크레딧 (2.0 / 6.0)	+36–+82	+60–+106	+39–+131	중계가 목적이 됨
V3	체크포인트 선택 절반을 3/30으로 (8시드)	+58	−42	+10	표준 구성만 개선
V4	제로섬 크레딧 재분배	+91, +126	+98, +172	+146, +180	같은 기제, 더 큼
V5	결합 행동 critic	+89	−27	+58	표본된 동료 행동의 목표값 분산
V6	가까운 드론부터 결정	+46, +100	−43, −38	+4, +106	순서는 원인이 아님
V7	정체 60스텝 뒤 재결정	+82, +95	−38, −34	+17, +55	불규칙한 옵션 길이
V8	단조 혼합 critic (하한 0.5)	+145	+5	+139	발산 방지와 크레딧이 한 축
V9	순차 단일 에이전트 크레딧	+142	+17	+116	결정 안에 수축 없음
V10	행동 복제 초기화 (워밍업 ±)	+42–+69	−42–−20	−4–+40	400 에피소드 안에 지워짐
V11	병목 도달 시각 벌점 (0.15 / 0.25)	+105	−8	+81	최댓값이 아닌 평균을 줄임

표 7: 재학습 없는 다른 통신 반경으로의 전이. 셀은 완주(휴리스틱/학습)와 쌍별 중앙 차이(승–패, p). $R = 300$ m가 학습 반경.

N/M	$R = 250$ m	$R = 300$ m	$R = 350$ m
3/30	200/200 / +77 (45–154, $< 10^{-4}$)	200/200 / +30 (81–119, 3.4e-04)	200/200 / +52 (58–141, $< 10^{-4}$)
4/50	118/120 / +68 (40–77, $< 10^{-4}$)	473/480 / +2 (234–239, 0.521)	119/120 / −40 (77–42, 1.1e-04)
5/50	182/200 / −16 (99–83, 0.327)	191/200 / −62 (147–44, $< 10^{-4}$)	200/200 / −42 (152–46, $< 10^{-4}$)

그리고 최종 판정과 다른 지표를 쓰는 사전 점검은 최종 판정이 기각할 개입을 통과시킨다.

8. 결론

연결성 제약 드론 배송을 위한 두 제어기, 교착 탈출을 갖춘 기하 사슬 중계 휴리스틱과 편대 크기 불변 학습 정책을 제안했다. 둘 다 매 스텝 편대를 연결 상태로 유지하는 투영을 통해 행동한다. 드론 3–12대 편대의 쌍별 규약에서 학습 정책은 모든 인스턴스를 완주하고, 3·4대로만 학습했는데도 4대를 넘는 드론이 있으면 38–178스텝 빠르며, 3대에서는 휴리스틱이 30–39스텝 빠르다. 드론 부족 영역의 열세는 어느 드론이 중계할지라는 한 결정이며, 열 가지 정책 쪽 개입에 저항하고 강제 모형을 바꾸면 절반으로 준다. 두 제어기는 목적지 10곳에서 계획을 내지 못하는 격자 정확 최적화보다 세 자릿수 빠르다. 자연스러운 다음 단계는 출력이 드론별 옵션 집합이 아니라 팀 배정인 정책으로, 중계 드론의 정체를 critic이 직접 평가할 수 있는 좌표로 만드는 것이다.

감사의 글

[추가 예정.]

데이터와 코드

코드, 학습 가중치, 인스턴스 생성기, 쌍별 비교 기록은 `https://github.com/koptimizer/relay_drone_network`에서 받을 수 있다.

References

[1] C. C. Murray, A. G. Chu, The flying sidekick traveling salesman problem: Optimization of drone-assisted parcel delivery, Transportation Research Part C: Emerging Technologies 54 (2015) 86–109. doi:10.1016/j.trc.2015.03.005.

[2] C. C. Murray, R. Raj, The multiple flying sidekicks traveling salesman problem: Parcel delivery with multiple drones, Transportation Research Part C: Emerging Technologies 110 (2020) 368–398. doi:10.1016/j.trc.2019.11.003.

[3] N. Agatz, P. Bouman, M. Schmidt, Optimization approaches for the traveling salesman problem with drone, Transportation Science 52 (4) (2018) 965–981. doi:10.1287/trsc.2017.0791.

[4] K. Dorling, J. Heinrichs, G. G. Messier, S. Magierowski, Vehicle routing problems for drone delivery, IEEE Transactions on Systems, Man, and Cybernetics: Systems 47 (1) (2017) 70–85.

[5] J. Park, C. Kwon, J. Park, Learn to solve the min-max multiple traveling salesmen problem with reinforcement learning, in: Proceedings of the 22nd International Conference on Autonomous Agents and Multiagent Systems, 2023, pp. 878–886.

[6] Y. Guo, Z. Ren, C. Wang, iMTSP: Solving min-max multiple traveling salesman problem with imperative learning, arXiv:2405.00285 (2024).

[7] Y. Zhu, H. Xu, A. A. Malikopoulos, N. Geroliminis, Dual-mission drone fleets: Delivery with secondary sensing tasks, arXiv:2604.02471 (2026).

[8] Y. Zeng, R. Zhang, T. J. Lim, Throughput maximization for UAV-enabled mobile relaying systems, IEEE Transactions on Communications 64 (12) (2016) 4983–4996. doi:10.1109/TCOMM.2016.2611512.

[9] E. Yanmaz, Positioning aerial relays to maintain connectivity during drone team missions, Ad Hoc Networks 128 (2022) 102800.

[10] R. Ding, J. Chen, W. Wu, J. Liu, F. Gao, X. Shen, Packet routing in dynamic multi-hop UAV relay network: A multi-agent learning approach, IEEE Transactions on Vehicular Technology 71 (9) (2022) 10059–10072.

[11] MUTTO: Multi-agent reinforcement learning for joint trajectory and transmit power optimisation of relay and mission UAVs, Vehicular Communications (2024).
URL https://www.sciencedirect.com/science/article/abs/pii/S1570870524002130

표 8: 평가 시드와 분리된 튜닝 시드(구성당 40 인스턴스)에서의 휴리스틱 절제. 셀은 완주 인스턴스 수와 완주 인스턴스의 중앙 makespan, 마지막 열은 세 구성 완주 합.

방식	k_{stall} / h_{hold}	3/30	4/50	5/50	완주 합
없음	—	39/40 / 561	26/40 / 805	36/40 / 613	101/120
선두 교대	30 / 20	40/40 / 566	38/40 / 827	40/40 / 630	118/120
선두 교대	30 / 40	40/40 / 560	39/40 / 847	40/40 / 625	119/120
선두 교대	30 / 80	40/40 / 565	39/40 / 892	38/40 / 628	117/120
선두 교대	60 / 20	40/40 / 562	40/40 / 879	39/40 / 631	119/120
선두 교대	60 / 40	40/40 / 561	39/40 / 852	40/40 / 624	119/120
선두 교대	60 / 80	40/40 / 561	38/40 / 838	40/40 / 636	118/120
선두 교대	90 / 20	40/40 / 562	39/40 / 865	40/40 / 624	119/120
선두 교대	90 / 40	40/40 / 565	39/40 / 887	38/40 / 594	117/120
선두 교대	90 / 80	40/40 / 560	39/40 / 891	40/40 / 637	119/120
선두 교대	**120 / 20**	40/40 / 568	40/40 / 826	40/40 / 603	**120/120**
선두 교대	120 / 40	40/40 / 565	39/40 / 869	39/40 / 614	118/120
선두 교대	120 / 80	40/40 / 558	38/40 / 834	40/40 / 621	118/120
후퇴	30 / 20	37/40 / 560	38/40 / 810	37/40 / 605	112/120
후퇴	30 / 40	38/40 / 558	33/40 / 824	38/40 / 637	109/120
후퇴	30 / 80	37/40 / 557	27/40 / 812	38/40 / 608	102/120
후퇴	60 / 20	39/40 / 566	36/40 / 796	40/40 / 622	115/120
후퇴	60 / 40	39/40 / 550	39/40 / 833	39/40 / 613	117/120
후퇴	60 / 80	39/40 / 560	25/40 / 823	36/40 / 634	100/120
후퇴	90 / 20	39/40 / 557	38/40 / 829	39/40 / 606	116/120
후퇴	90 / 40	39/40 / 563	39/40 / 855	39/40 / 616	117/120
후퇴	90 / 80	39/40 / 566	35/40 / 838	40/40 / 641	114/120
후퇴	120 / 20	39/40 / 556	39/40 / 869	38/40 / 626	116/120
후퇴	120 / 40	39/40 / 558	36/40 / 873	38/40 / 608	113/120
후퇴	120 / 80	39/40 / 556	37/40 / 863	40/40 / 616	116/120

표 9: 학습 정책의 절제: 완주 에피소드에서 제안 조리법 대비 makespan 차이, 시드 2개. 양수는 뺀 요소가 필요했다는 뜻. 70–80스텝 아래의 차이는 시드 분산 안이다.

제거한 요소	4/50	3/30	5/50
규칙 정규화	+320	+408	+92
구성 무작위화	−44	+646	+68
엔트로피 목표 감쇠	+128	+19	+61
자기회귀 결정	+94	−46	+33
잔여 벌점	−28	−37	+8

[12] MAEN: Multi-agent aerial relay networking, Proceedings of ACM MobiCom (2024). doi:10.1145/3636534.3694730.

[13] M. Li, Y. Jie, Y. Kong, H. Cheng, Decentralized global connectivity maintenance for multi-robot navigation: A reinforcement learning approach, arXiv:2109.08536 (2021).

[14] J. De Hoog, S. Cameron, A. Visser, Role-based autonomous multi-robot exploration, in: Proceedings of the International Conference on Advanced Cognitive Technologies and Applications, 2009.

[15] K. Cesare, R. Skeele, S.-H. Yoo, Y. Zhang, G. Hollinger, Multi-UAV exploration with limited communication and battery, in: Proceedings of the IEEE International Conference on Robotics and Automation, 2015, pp. 2230–2235. doi:10.1109/ICRA.2015.7139494.

[16] T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1861–1870.

[17] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, I. Mordatch, Multi-agent actor-critic for mixed cooperative-competitive environments, in: Advances in Neural Information Processing Systems 30, 2017, pp. 6379–6390.

[18] J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, S. Whiteson, Counterfactual multi-agent policy gradients, in: Proceedings of the 32nd AAAI Conference on Artificial Intelligence, 2018, pp. 2974–2982.

[19] P. Sunehag, G. Lever, A. Gruslys, W. M. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls, T. Graepel, Value-decomposition networks for cooperative multi-agent learning based on team reward, in: Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 2085–2087.

[20] T. Rashid, M. Samvelyan, C. Schroeder de Witt, G. Farquhar, J. Foerster, S. Whiteson, QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning, in: Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4295–4304.

[21] R. S. Sutton, D. Precup, S. Singh, Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning, Artificial Intelligence 112 (1–2) (1999) 181–211.

[22] S. Huang, S. Ontañón, A closer look at invalid action masking in policy gradient algorithms, in: Proceedings of the International FLAIRS Conference, Vol. 35, 2022.

[23] G. Dalal, K. Dvijotham, M. Vecerik, T. Hester, C. Paduraru, Y. Tassa, Safe exploration in continuous action spaces, arXiv:1801.08757 (2018).

[24] A. Y. Ng, D. Harada, S. Russell, Policy invariance under reward transformations: Theory and application to reward shaping, in: Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 278–287.

[25] L. R. Ford, D. R. Fulkerson, Flows in Networks, Princeton University Press, Princeton, NJ, 1962.

[26] Gurobi Optimization, LLC, Gurobi optimizer reference manual, version 13, https://www.gurobi.com (2026).

표 10: 상위 결정 1회의 지연(밀리초, CPU)과 900스텝 에피소드의 누적 결정 시간.

제어기	$N=3$	$N=4$	$N=6$	$N=8$	900스텝
기하 규칙 + 탈출	0.05	0.08	0.10	0.12	0.003 s
학습, 독립 결정	1.27	1.52	1.94	2.45	0.069 s
학습, 자기회귀 (제안)	2.70	3.52	5.32	7.35	0.158 s