재난 대응 상황의 연결성 제약 드론 배송을 위한 기하 및 학습 기반 중계 제어

고광종[a], 정태수[a,*]

[a]고려대학교 산업경영공학부, 서울특별시 성북구 안암로 145, 서울, 02841, 대한민국

Abstract

재난 구호에서 배송 드론은 편대 스스로 구성하는 다중 홉 중계 사슬을 통해 거점과 연결을 유지한 채, 제한된 적재량으로 물자를 나르고 재적재를 위해 복귀해야 한다. 본 연구는 이를 모든 드론이 배송과 중계를 겸할 수 있고 연결성이 매 스텝 강제되는 makespan 최소화 문제로 모형화한다. 같은 연결성 보존 투영을 공유하는 두 제어기를 제안한다. 교착 복구 장치를 갖춘 기하 사슬 중계 휴리스틱과, 집합 기반 자기회귀 상위 정책을 이산 soft actor-critic 으로 한 번 학습한 편대 크기 불변 정책이다. 두 제어기를 드론 3–12대, 수요지 20–400곳의 동일 인스턴스에서 쌍별로 비교하고, 무학습 베이스라인 넷과 작은 인스턴스의 시간 확장 혼합정수 참조 모형에 대조한다. 학습 정책은 모든 구성의 모든 인스턴스를 완주하고, 휴리스틱은 복구 장치가 있을 때 98–100%, 없을 때 62%를 완주한다. 두 제어기는 구성 공간을 나눈다. 드론 3대에서는 휴리스틱이 쌍별 중앙값으로 30–39스텝 빠르고, 4대에서는 480회의 쌍별 실행에서 둘이 통계적으로 구분되지 않으며, 5대 이상에서는 학습 정책이 38–178스텝 빠르다. 이 정책은 드론 3·4대로만 학습했고 재학습 없이 시험한 모든 더 큰 편대로 전이된다. 집합 기반 구조가 완주를, 무작위 구성에서의 학습이 속도를 떠받친다. 3대 구성의 열세는 어느 드론이 중계할지라는 한 결정에 국소화되며, 정보·크레딧 할당·결정 구조·초기화·보상 설계에 걸친 정책 쪽 개입 열한 가지가 모두 이를 제거하지 못한다. 연결성 투영을 같은 방향 축소에서 접선 보존으로 바꾸면 열세의 절반이 사라져, 이 열세가 학습기만이 아니라 제약을 강제하는 방식의 성질이기도 함을 보인다. 최적성이 증명되도록 푼 최적성이 증명되도록 푼 40개 인스턴스에서, 제어기의 중계를 모형과 같은 노드 집합으로 제한하고 재면 학습 정책은 최적값보다 평균 4.3%, 휴리스틱은 9.7% 위다. 두 제어기 모두 결정당 밀리초에 동작하며, 이는 재적재가 필요해지면 더는 최적을 증명하지 못하는 정확 최적화보다 세 자릿수에서 여섯 자릿수 빠르다.

Keywords: 드론 배송, 중계 네트워크, 연결성 제약, 다중 에이전트 강화학습, 휴리스틱, 재난 물류

1. 서론

통신·물류·도로 기반이 파괴되면 드론 편대가 임시 거점에서 여러 수요지로 긴급 물자를 나를 수 있다. 드론은 재난 구호의 라스트마일 배급 [1, 2, 3]과 의료 배송 [4, 5]에 대해 연구되어 왔고, 드론 편대의 경로 문제는 flying-sidekick 외판원 문제 이래 독자적인 문헌으로 성장했다 [6, 7, 8, 9]. 재난 상황이 택배 배송과 다른 점은 둘이다. 첫째, 상·하역이 원격으로 감독되고 배송 상태가 추적되어야 하므로 모든 드론이 항상 거점과 통신 가능해야 하며, 지상망이 사라진 상황에서 그 통신은 드론들이 스스로 다중 홉 사슬의 중계 노드가 되어야만 성립한다. 둘째, 편대는 작고 드론 한 대의 적재량은 몇 단위에 불과해 드론은 거점과 수요지 사이를 왕복하며, 중계로 서 있는 드론은 그만큼 배송하지 않는 드론이다. 따라서 운영상의 질문은, 사슬을 한 번도 끊지 않으면서 마지막 수요지를 가능한 한 빨리 배송하도록 배송 역할과 중계 역할을 시간에 따라 어떻게 배정하느냐다. 공중 중계는 통신 문헌에서 충분히 연구되어 있고 [10, 11, 12] 연결성 유지는 다중 로봇 제어의 고전적 주제이지만 [13, 14], 두 경우 모두 중계 자체가 임무다. 본 문제에서는 중계가 같은 기체를 두고 배송 임무와 경쟁한다.

이 문제가 어려운 이유는 세 가지다. 하드 연결성 제약은 교착을 만든다. 모든 드론을 가장 가까운 수요지로 보내는 탐욕 배정은 본 연구의 표준 인스턴스를 한 건도 완주하지 못하는데, 편대가 스스로를 잡아당기다가 어떤 드론도 움직일 수 없게 되기 때문이다. 중계는 처리량과 직접 경쟁하므로 적정한 중계 대수와 중계 드론은 남은 수요지의 기하와 적재가 남은 드론 수에 따라 달라진다. 그리고 정확 최적화는 규모가 커지지 않는다. 98 m 격자 위의 시공간 네트워크 모형 [15, 16]은 재적재가 필요 없는 동안은 수 초 안에 최적성이 증명되도록 풀리지만, 드론이 재적재해야 하면 혼합정수 솔버는 1시간 안에 최적을 증명하는 인스턴스가 드물고 일부에서는 실행 가능해도 내지 못하는 반면, 연결성 제약이 없는 드론 경로 모형은 수십 고객 규모까지 정확하게 풀린다 [17].

제안. 이 문제에 대해 두 제어기를 제안하고 나란히 연구한다.

1. 기하 사슬 중계 휴리스틱. 적재가 남은 드론 중 거점에서 가장 먼 드론이 선두이고, 중계 대수는 선두의 목표가 필요로 하는 통신 홉 수이며, 중계 드론은 그 다음으로 먼 드론들로서 거점에서 선두까지의 선분 위에 $0.9R$ 간격으로 선다. 규칙이 결정론적이라 교착된 배정을 무한히 반복할 수 있으므로, 편대가 정해진 스텝 수만큼 정체하면 선두를 교대하는 교착 복구 장치를 더했다. 복구 장치만으로 표준 구성 완주율이 62%에서 98%로 오른다.
2. 편대 크기에 불변인 학습 정책. 상위 정책이 20스텝마다 드론별로 일곱 개 이산 옵션 중 하나를 배정한다. 드론·후보 수요지·중계 슬롯을 집합으로 부호화하고 어텐션으로 풀링하며, 선두 하나와 중계 k대의 대형을 의도적으로 구성할 수 있도록 자기회귀로 결정한다. 드론 3·4대 편대로 이산 soft actor-critic [18]으로 한 번 학습한 뒤 재학습 없이 최대 12대 편대에서 돌린다.

*교신저자.
Email addresses: koptimizer@korea.ac.kr (고광종), tcheong@korea.ac.kr (정태수)

이는 경로 문제의 크기 불변 학습 해법 [19, 20]과 같은 정신이다.

두 제어기 모두 같은 연결성 보존 투영을 거쳐 행동한다. 명령된 이동은 편대의 연결이 유지되는 최대 비율로 축소된다. 따라서 연결성은 두 제어기 모두에 구조적으로 보장되며, 실험의 질문은 제약을 위반하는가가 아니라 제약 아래에서 진척을 내는가다.

연구 질문. 연구를 다섯 질문으로 조직한다.

RQ1 제안 제어기들은 매 스텝 연결성이 강제된 채 항상 완주하는가, 못 한다면 왜인가?

RQ2 작은 인스턴스에서 제안 제어기들은 격자 모형의 정확 최적화로 얻은 참조 계획에 얼마나 가까운가?

RQ3 두 제어기의 성능은 운용 조건, 특히 편대 크기·수요지 수·거점 위치·통신 반경에 따라 어떻게 비교되며, 그 차이는 어디서 오는가?

RQ4 드론 3·4대로 학습한 정책이 재학습 없이 더 큰 편대와 더 큰 인스턴스로 상향 전이되는가, 그 전이를 떠받치는 것은 무엇인가?

RQ5 각 제어기의 구성 요소는 필수적인가?

발견. 학습 정책은 시험한 모든 구성의 모든 인스턴스를 완주하고, 휴리스틱은 복구 장치와 함께 98–100%를 완주한다(RQ1). 최적성이 증명되도록 풀 만큼 작은 인스턴스에서 학습 정책은 가장 촘촘한 격자의 최적성이 증명되도록 푼 40개 인스턴스에서, 두 제어기의 중계를 모형의 노드 집합으로 제한하고 재면 학습 정책은 최적값보다 평균 4.3%, 휴리스틱은 9.7% 위이며, 그 최적값 자체가 연속 최적값의 상한이다(RQ2). 두 제어기는 편대 크기로 구성 공간을 나눈다. 3대에서는 휴리스틱이 빠르고, 4대에서는 둘이 통계적으로 구분되지 않으며, 5대 이상에서는 학습 정책이 10대까지 62–178스텝, 12대에서 76스텝 빠르다. 3대 열세는 어느 드론이 중계할지라는 한 결정이며, 정책 쪽 개입 열한 가지에 저항하지만 연결성 투영을 바꾸면 절반으로 줄어든다(RQ3). 학습 정책은 학습에서 드론 4대, 수요지 80곳을 넘는 구성을 본 적이 없지만 드론 12대, 수요지 400곳까지의 모든 인스턴스를 완주한다. 집합 기반 구조가 완주를, 학습 시의 구성 무작위화가 속도를 떠받친다(RQ4). 학습 정책에서 규칙 정규화·구성 무작위화·엔트로피 감쇠를 빼면 수백 스텝 또는 완주를 잃고, 휴리스틱에서 복구 장치를 빼면 완주의 3분의 1을 잃는다(RQ5).

기여. (i) 제약이 구조적으로 성립하는 투영 위에 세운, 교착 복구를 갖춘 기하 사슬 중계 휴리스틱과 편대 크기 불변 학습 정책. (ii) 두 제어기가 상보적임을 보이는 편대 크기별 쌍별 평가와 그 경계의 기제, 그리고 학습 정책이 학습한 어떤 편대보다 세 배 큰 편대로 상향 전이된다는 증거. (iii) 학습기를 바꿔 드론 부족 영역의 열세를 좁히려는 열한 가지 기록된 음성 결과와, 열세의 절반이 강제 모형에 귀속됨을 보이는 민감도 결과. (iv) 작은 인스턴스에서 정확하게 푼 본 문제의 시공간 네트워크 모형과, 그 최적값이 무엇을 제한하고 무엇을 제한하지 못하는지에 대한 명시적 설명.

2. 관련 연구

2.1. 드론을 이용한 차량 경로 문제

본 문제는 차량 경로 문제 [21, 22]의 한 갈래로, 동질의 용량 제약 편대, 단일 거점, 단위 수요, makespan 목적함수를 갖는다. 총 이동 거리가 아닌 makespan(min-max) 목적은 서비스를 가능한 한 일찍 끝내는 것이 목표일 때 표준적인 선택이다 [20, 23]. 드론 경로 문제는 트럭과 드론이 협력하는 flying-sidekick 외판원 문제 [6]에서 출발해 다중 드론 [24], 정확해법과 근사해법 [25, 26, 17, 27], 드론을 포함한 차량 경로 문제 [28, 29, 30], 에너지와 적재 제약이 있는 드론 전용 편대 [31]로 확장되어 왔다. Otto 등 [7], Macrina 등 [8], Chung 등 [9]의 조사 논문이 이 문헌을 정리한다. 이 모든 연구에서 통신은 비용이 없다. 드론이 거점에서 도달 가능해야 한다는 요구가 없고, 어떤 차량도 중계를 위해 배송 역할을 내려놓지 않는다. 본 문제는 바로 그 요구를 더하며, 모형화 측면의 주된 귀결은 제약이 매 순간 모든 차량의 위치에 관한 것이므로 경로만으로는 결정 변수로 충분하지 않다는 점이다 (3.1절). 동적 차량 경로 문제 [32]는 상태가 전개됨에 따라 온라인으로 결정해야 한다는 점을 공유하며, 이는 본 연구의 두 제어기가 동작하는 방식이다.

2.2. 재난·인도적 물류에서의 드론

지상 기반이 손상되었을 때의 라스트마일 배급에 드론이 제안되어 왔다. Chowdhury 등 [1]은 연속 근사 모형으로 드론 기반 구호 물자 배급망을 설계하고, Rabta 등 [2]은 적재량과 항속 거리 제한 아래 라스트마일 배송용 드론 편대를 최적화하며, Kim 등 [4]과 Ghelichi 등 [5]은 농촌과 도시 환경의 의료 배송을 위한 드론 편대를 계획하고, Erdelj 등 [3]은 임시 통신 노드 역할을 포함해 재난 관리에서 드론이 맡을 수 있는 역할을 조사한다. 이 연구들은 전략 또는 전술 수준(편대 규모, 거점 위치, 경로 배정)에서 계획하며 제어 링크가 존재한다고 가정한다. 본 연구의 기여는 운용 수준에 있다. 편대와 거점이 주어졌을 때, 배송하는 동안 편대 스스로 링크를 유지하도록 드론이 어떻게 움직여야 하는가이다.

2.3. 공중 중계와 연결성 유지

UAV를 통신 중계로 쓰는 것은 무선 네트워킹에서 성숙한 주제다. 비행 애드혹 네트워크 [33], UAV 통신 문제 [34], UAV 기반 무선 네트워크 [11]에 대한 조사 논문이 있고, 처리량 최적 중계 궤적이 [10]에서 유도되며, 감시 UAV와의 링크를 유지하기 위한 중계 배치가 [12]에서 정확하게 풀린다. 이동 중계의 다중 홉 사슬은 로보틱스 문헌에서 통신 사슬 [14], 로봇 라우터 [35], 팀 임무를 위한 중계 위치 결정 [36]으로 연구된다. 이동 로봇 팀의 연결성 유지에는 통신 그래프의 대수적 연결성에 기반한 제어 이론 문헌이 있으며 [37, 13], 학습된 연결성 보존 제어기도 있다 [38]. 학습 기반 중계 제어는 UAV 네트워크의 패킷 라우팅 [39], 중계 UAV와 임무 UAV의 궤적·전력 공동 제어 [40], 공중 중계 네트워킹 [41]에 적용되었다. 이들 모두에서 중계는 임무 그 자체이거나 자체 보상을 가진 전용 하위 편대이며, 화물을 싣지 않고 재적재하지 않으며 배송 makespan을 최소화하지 않는다. 임무 역할과 중계 역할 사이의 전환은 다중 로봇 탐사 [42, 43]에서 확립된 아이디어로, 그곳에서는 중계 로봇이 착륙해 고정 노드가 된다. 본 연구의 드론은 역할을 반복해서 전환하며 중계 위치가 선두 드론과 함께 움직인다.

2.4. 시간 확장 네트워크 모형과 대칭

본 연구의 정확 모형은 시공간 네트워크 위의 시간 색인 정식화다. 시간 확장 네트워크는 Ford와 Fulkerson의 시간에 따른 흐름 [15]에서 비롯했고, Skutella [16]가 그 이론을 정리한다. 이런 모형이 시간 이산화에 의존한다는 점은 잘 알려져 있으며, 동적 이산화 발견 [44]은 필요한 곳에서 시간 격자를 세분한다. 본 연구는 공간도 이산화하는데, 이는 항공기의 MILP 궤적 계획 [45]에서 통상적으로 쓰이는 장치다. 연결성은 기간마다 단일 상품 흐름으로 부호화되며, 그 실행 가능성은 다중 홉 사슬의 존재와 동치다(3.1절). 드론이 동일하므로 모형은 통상적인 색인 대칭을 가지며, 이를 Sherali와 Smith [46]의 순서 제약으로 깨뜨린다. 정수계획법의 대칭 처리는 Margot [47]이 정리한다.

2.5. 경로 문제와 협력 제어를 위한 학습

포인터 네트워크 [48]에서 어텐션 기반 구성적 정책 [49, 19]에 이르는 경로 문제의 신경망 해법은 어텐션을 갖춘 집합 기반 인코더가 인스턴스 크기에 걸쳐 일반화함을 보인다. Bengio 등 [50]과 Mazyavkina 등 [51]은 조합 최적화를 위한 기계학습을 조사한다. min-max 다중 외판원 문제의 학습 해법 [20, 52]이 목적함수 면에서 본 연구와 가장 가까우며, 크기 불변 집합 부호화를 여기서 빌려 온다. 그러나 어느 것도 연결성 제약이 없고 온라인으로 결정하지 않는다. 같은 드론이 배송과 감지를 겸하는 이중 임무 편대 [53]는 배송당 우회 예산을 정식화하지만, 그곳의 부차 임무는 통신이 아니라 감지이며 차량들의 위치를 결합하지 않는다. 학습 측면에서는 soft actor-critic [18], 분산 실행을 위한 중앙 critic [54, 55], 가치 분해 [56, 57], 협력 다중 에이전트 정책 최적화 [58](개관은 [59] 참조), 옵션을 통한 시간적 추상화 [60, 61, 62], 무효 행동 마스킹 [63], 안전 행동 투영 [64]에 기반한다. 6.3절의 음성 결과는 이 아이디어 중 여럿을 직접 시험한다. 드론별 크레딧, 결합 행동 critic, 단조 가치 혼합, 잠재 함수형 보상 설계 [65]를 드론 부족 영역의 열세에 대한 처방으로 모두 시도했고 어느 것도 열세를 제거하지 못했다.

2.6. 본 연구의 위치

저자들이 아는 범위에서 (i) 적재와 재적재가 있는 동질 편대가 물리적 화물을 다수 수요지로 나르고, (ii) 모든 드론이 매 스텝 다중 홉 사슬로 거점에 연결되어야 하며, (iii) makespan을 목적으로 하는 설정을 함께 다룬 선행 연구는 없다. 이 설정에서는 중계 의무가 화물 처리량과 경쟁하고 편대가 거점으로 반복 복귀해야 하므로, 역할 배정이 일회성 배치가 아니라 순차 결정이 된다. 본 연구는 이 문제의 정확한 시공간 네트워크 모형, 교착 복구 장치를 갖춘 구성적 온라인 휴리스틱, 크기 불변 학습 정책을 제시하고, 각각이 어디서 더 나은지 보고한다.

3. 문제 정의

거점은 $c \in [0, 1000]^2$ m에 있고 M개 수요지 $d_1, \dots, d_M$는 거점으로부터 $0.9\,NR$ 안에 놓인다. N은 드론 수, $R = 300$ m는 통신 반경이다. 각 드론은 $v = 13.89$ m/s로 비행하고 $Q = 5$단위를 싣는다. 모든 배송과 재적재에는 서비스 시간이 따른다. 수요지에서 한 단위를 내리는 데 $S = 10$스텝, 거점에서 Q까지 재적재하는 데 S스텝이 들며 그동안 드론은 정지한다. 수요지나 거점은 25 m 안에 들어오면 도달한 것으로 보며 한 스텝은 1초다. 서비스 시간은 아래의 연결성 제약과 맞물린다. 정지한 드론은 링크를 지키려 움직일 수 없으므로 동료들이 그 주위에서 사슬을 유지해야 한다. 모든 수요지는 정확히 한 단위를 필요로 한다. 드론 간 충돌·바람·배터리는 모형화하지 않는다.

연결성. G_t를 거점과 N대 드론을 정점으로, 서로 R 안에 있는 정점 쌍을 간선으로 하는 그래프라 하자. G_t가 연결되어 있으면 스텝 t에 편대가 연결된 것이고, 이는 모든 드론이 거점까지 다중 홉 경로를 가진다는 말과 같다. 제약은 모든 t에서 G_t가 연결되는 것이며, 벌점이 아니라 강제로 지킨다(4.1절).

목적. makespan 은 마지막 수요지가 배송되는 스텝이다. 제어기가 10,000스텝 예산 안에 모든 수요지를 배송하면 그 인스턴스를 완주한 것으로 본다. 완주율과, 완주한 인스턴스에서의 makespan 을 보고한다.

구성. 구성은 편대 크기 N, 수요지 수 M, 거점 배치(지도 중앙 고정 또는 균일 무작위)의 세 쌍이다. 표준 구성은 고정 거점의 $N = 4$, $M = 50$이다. 학습 정책은 $N \in \{3, 4\}$, $M \in [20, 80]$, 무작위 거점으로 학습하며 그 외 구성은 본 적이 없다. 휴리스틱에는 학습이 없다.

3.1. 이산화 위에서 정확한 시공간 네트워크 모형

두 제어기 외에 제안하는 세 번째 요소는 이 문제의 최적화 모형이다. 모형은 두 역할을 한다. 문제를 모호함 없이 서술하고, 작은 인스턴스에서는 정확 최적화로 얻은 계획을 제공해 두 제어기를 그에 재게 한다.

모형이 이 형태를 취하는 이유. 드론 배송의 차량 경로 정식화 [6, 25]는 차량에 경로를 배정할 뿐 특정 순간에 차량이 어디 있는지 알 필요가 없다. 3절의 연결성 요구는 종류가 다르다. 통신 그래프 G_t가 드론 위치로부터 만들어지므로 이는 매 스텝 모든 드론의 위치에 대한 제약이다. 따라서 모형은 모든 드론의 위치를 시간에 따라 실어야 하고, 그에 자연스러운 대상이 시간 확장 네트워크 [15]다. 위치 집합을 기간마다 복제하고 한 기간의 위치에서 다음 기간에 도달 가능한 위치로 호를 잇는다. 평면 위의 위치는 비가산이므로 공간도 격자로 이산화하며, 그 결과가 드론을 단위 흐름으로 다루는 시공간 네트워크이고 이 위의 시간 색인 MILP는 이산화된 문제에 대해 정확하다. 연결성은 매 기간 어느 격자 노드가 점유되었는지의 성질이 되고, 점유 노드들이 거점까지 다중 홉 사슬을 이룰 때 그리고 그때만 실행 가능한 기간별 단일 상품 흐름으로 부호화한다. 모형이 정확하다는 것은 그 최적값이 이산화된 문제의 참 최적값이라는 뜻이며, 연속 문제와의 관계는 이 절 끝에 적는다.

이산화. 한 기간은 $\kappa = S = 10$스텝이다. 따라서 서비스 한 번이 정확히 한 기간이고 학습 정책의 상위 결정 한 번은 두 기간이며, 기간당 비행 거리는 $\ell = v\kappa = 138.9$ m다. 공간은 인스턴스의 경계 상자 위에 간격 $h = \ell/\sqrt{2} = 98.2$ m로 놓은 정사각 격자 G에서 거점으로부터 $0.9NR$보다 먼 노드(어떤 사슬도 닿을 수 없는 노드)를 지운 것이고, 거점과 모든 수요지는 정확한 노드로 추가해 그곳의 상호작용 판정이 정확하도록 한다. 그림 1가 참조 인스턴스의 노드 집합이다. 이 간격에서 여덟 방향 이동이 모두 한 기간에 가능하다. 이동 집합과 통신 집합은

$$A(i) = \{j \in N_{\mathrm{v}} : \|p_i - p_j\| \le \ell\} \ni i, \tag{1}$$

$$E = \{(i, j) \in N_{\mathrm{v}}^2 : i \neq j,\ \|p_i - p_j\| \le R\} \tag{2}$$

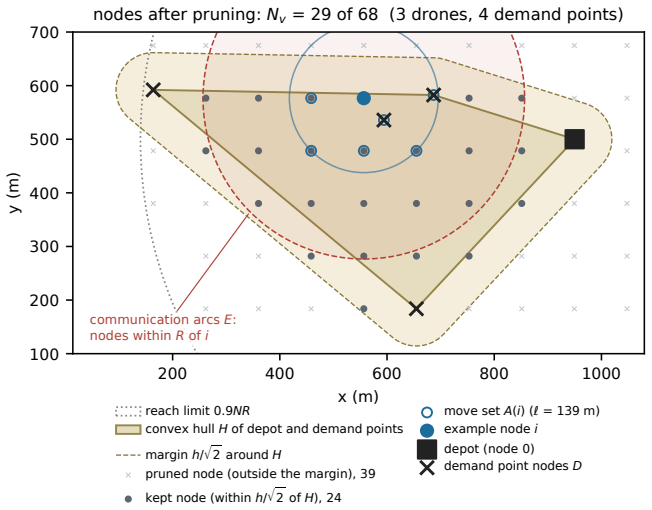


그림 1: 드론 3대, 수요지 4곳의 참조 인스턴스에 대한 시공간 네트워크의 노드. 거점(노드 0), 수요지 노드 D, 도달 한계 $0.9NR$(점선)로 자른 간격 $h = 98.2$ m의 격자 G. 음영 다각형은 거점과 수요지의 볼록 껍질 H이고 연한 띠는 그 둘레 너비 $h/\sqrt{2}$의 여유 영역이다. 껍질이나 띠 안의 격자 노드는 남기고(점) 밖의 노드는 가지쳐(가위표) 68개 중 29개 노드가 남는다. 예시 노드 i 하나에 대해 이동 집합 $A(i)$(한 기간에 닿는 노드, $\ell = 138.9$ m)와 E의 호를 정하는 반경 R의 통신 원판을 표시했다.

이다. 축 방향 이동은 기간당 ℓ이 아니라 h만 가므로 격자는 그 방향에서 드론을 최대 29% 늦추며, 이 이산화 오차는 항상 모형에 불리하게 작용한다. 격자는 중계 사슬을 담을 만큼 촘촘해야 한다. 거리 d의 수요지를 배송하려면 중간 드론들이 사슬의 여유 $NR - d$ 안에 놓여야 하므로 대략 $h \lesssim (NR - d_{\max})/(N-1)$이 필요하다. 196 m 격자는 평면에서 실행 가능한 참조 인스턴스를 실행 불가능하게 만들고 98 m는 그렇지 않다.

볼록 껍질에 의한 노드 가지치기. 도달 한계 안의 격자 노드 대부분은 쓸 일이 없다. H를 거점과 수요지들의 볼록 껍질이라 하자. 편대의 어떤 배치에서든 H 밖에 있는 모든 드론을 H 위로 사영해도 쌍별 거리는 늘어나지 않는다. 볼록 집합으로의 사영은 비확장적이기 때문이다. 따라서 사영은 모든 통신 링크, 한 기간 이동, 서비스를 보존하고 사영된 계획의 makespan 은 같다. 그러므로 연속 문제에는 항상 H 안의 최적 계획이 있고, 껍질 밖의 중계 위치는 손실 없이 버릴 수 있다. 격자에서는 H에서 칸의 반대각선 $h/\sqrt{2}$ 안에 있는 노드만 남겨, H의 모든 점이 격자 한 칸 안에 남은 노드를 갖도록 한다. 이 여유는 격자 노드의 사영이 격자 노드가 아닌 경우를 막는다. 가지치기는 참조 인스턴스 34개에서 노드를 평균 45% 줄이고(합계 2,881에서 1,594), 확인할 수 있는 인스턴스에서 격자 최적값을 바꾸지 않는다 (6.2절). 그림 1에 가지친 노드와 남긴 노드를 표시했다.

기호. 표 1에 집합·파라미터·결정변수를 정리했다. 드론은 동일하므로 드론 첨자는 개체를 구별할 뿐이며, 모형 끝의 대칭 제거 절단이 이를 이용한다. 모형은 (3)–(16)이다.

모형 읽기. 목적함수 (3)는 makespan C를 최소화한다. 둘째 항은 가중치 $\varepsilon \bar{T} N \ll 1$의 동점 처리 항으로, 놀고 있는 드론을 거점에 두는 계획을 선호하되 최적 makespan 을 바꾸지 못한다.

위치와 이동, (4)–(6). 모든 드론은 매 기간 경계에 정확히 한 노드에 있고 거점에서 출발한다. 드론이 경계 $t+1$에 노드 i에 있으려면 경계 t에 i 자신 또는 한 기간 안에 i에 닿는 노드에 있어야 한다. 모든 이동이 정확히 한 기간이므로 모든 드론의 위치가 모든 경계에서 정의되며, 아래 연결성 제약이 바로 그것을 필요로 한다.

배송, 적재, 재적재, (7)–(12). 각 수요지는 정확히 한 번 배송된다 (7). 기간 t의 배송은 드론이 그 기간의 양 끝 경계에서 수요지에 있을 것을 요구한다 (8). 이것이 3절의 서비스 시간으로, 드론은 한 기간 동안 정지한다. 재적재도 마찬가지로 거점에서 한 기간을 통째로 쓴다 (9). 드론은 기간당 서비스를 최대 하나만 하고 실은 것만 배송할 수 있으며 (10), 적재량은 가득 찬 상태에서 시작해 (11)로 추적되고, 재적재는 드론을 완전히 채운다 (12). ρ_{kt}는 재적재 기간에만 양수일 수 있고 그 다음 적재량은 Q여야 하기 때문이다.

다중 홉 연결성, (13)–(14). 이 두 제약족이 이 모형을 드론 경로 모형과 구별하는 부분이다. 매 기간 점유된 모든 노드가 한 단위의 흐름을 내보내고, 거점이 유일한 흡수원이며, 호는 점유된 노드에서 나갈 때만 흐름을 실을 수 있다. 이 체계는 모든 점유 노드가, 중간 노드가 모두 점유되고 연속 거리가 R 이하인 경로로 거점과 이어질 때 그리고 그때만 실행 가능하다. 즉 그 기간 경계에서 시뮬레이터의 다중 홉 연결성 판정이 통과할 때와 정확히 같다. 증명은 짧다. 그런 경로가 있으면 각 노드의 단위를 그 경로로 보내면 두 제약족이 만족된다. 거꾸로 점유되지 않은 노드 $i \neq 0$은 (14)에 의해 나가는 모든 호에서 $g_{ijt} = 0$이고 따라서 (13)에 의해 들어오는 흐름도 없으므로, 모든 흐름은 점유 집합 안에서만 움직이고, 보존 행이 없는 노드가 거점뿐이므로 흐름 분해가 필요한 경로를 준다. 거울상 용량 행 $g_{ijt} \le N u_{jt}$는 함의되므로 생략해 지배적인 행 수를 절반으로 줄였다. 이 제약이 문제에 무엇을 하는지 보자. 배송할 것이 없는 드론도 동료가 홉으로 필요로 하면 거점에서 그냥 기다릴 수 없고, 어떤 드론도 모든 점유 노드로부터 R보다 멀어지는 수요지로 날 수 없다. 따라서 중계는 별도의 임무가 아니라 편대가 어디 있는지의 귀결이다.

makespan 과 대칭, (15)–(16). makespan 은 모든 배송의 기간 이상이다. 드론이 동일하므로 어떤 계획이든 드론 k가 번호 k 미만의 수요지를 배송하지 않도록 재명명할 수 있다. (16)은 이 순서를 강제하며 어떤 목적값도 잃지 않는다.

최적값의 뜻. 모형의 최적값은 이산화된 문제에 대해 정확하다. 3절의 연속 문제에 대해서는 상한이다. 드론이 격자 노드에 묶이고 축 방향 이동이 짧아지므로 모든 격자 계획은 실행 가능한 연속 계획이지만 그 역은 아니며, 연속 제어기는 격자 최적값보다 빠를 수 있다. 솔버의 쌍대 하한은 격자 문제에 대한 하한일 뿐이다. 격자 노드를 칸으로 보고 칸 사이 최소 거리로 통신을 판정하는 칸 완화를 통한 증명된 하한은 시도했다가 포기했다. 3홉 사슬의 도달 거리를 900 m에서 1,317 m로 부풀려 자명한 해석적 하한보다 낮은 값을 내기 때문이다.

표 1: 시공간 네트워크 모형의 기호.

기호	정의역	뜻
집합		
$N_{\mathrm{v}} = \{0\} \cup D \cup G$		노드: 거점(첨자 0), 수요지 노드 D, 격자 노드 G
K	$\lvert K\rvert = N$	드론
$T = \{0, 1, \dots, \bar{T}\}$		기간 경계; 기간 t는 경계 t에서 $t+1$까지
$A(i) \subseteq N_{\mathrm{v}}$		i에서 한 기간 안에 닿는 노드, i 자신 포함(이동 집합)
$E \subseteq N_{\mathrm{v}}^2$		통신 반경 R 안의 서로 다른 노드 순서쌍(통신 호)
파라미터		
Q	5	적재 용량(단위)
R	300 m	통신 반경
κ, ℓ, h	10스텝, 138.9 m, 98.2 m	기간 길이, 기간당 비행 거리, 격자 간격
$\bar{T}$		기간 단위 지평, 휴리스틱 makespan 의 1.15배
ε	10^{-5}	동점 처리 가중치
$\mathrm{idx}(j)$		D의 고정 순서에서 수요지 j의 번호
결정변수		
y_{ikt}	$\{0, 1\}$	드론 k가 경계 t에 노드 i에 있으면 1
s_{jkt}	$\{0, 1\}$	드론 k가 기간 t에 수요지 j에 배송하면 1
r_{kt}	$\{0, 1\}$	드론 k가 기간 t에 거점에서 재적재하면 1
q_{kt}	$\{0, \dots, Q\}$	경계 t에 드론 k의 적재량
ρ_{kt}	$[0, Q]$	기간 t에 드론 k가 실은 양
g_{ijt}	$[0, N]$	기간 t에 호 (i, j) 위의 연결성 흐름
u_{it}	$\{0, \dots, N\}$	경계 t에 노드 i의 점유, $u_{it} = \sum_k y_{ikt}$, 단 $u_{0t} := 1$
C	$[0, \bar{T}]$	기간 단위 makespan

$$\min \; C + \varepsilon \sum_{i \in N_{\mathrm{v}} \setminus \{0\}} \sum_{k \in K} \sum_{t \in T} y_{ikt} \tag{3}$$

$$\text{s.t.} \quad \sum_{i \in N_{\mathrm{v}}} y_{ikt} = 1 \qquad \forall k \in K,\ t \in T \tag{4}$$

$$y_{0k0} = 1 \qquad \forall k \in K \tag{5}$$

$$y_{i,k,t+1} \le \sum_{j \in A(i)} y_{jkt} \qquad \forall i \in N_{\mathrm{v}},\ k \in K,\ t < \bar{T} \tag{6}$$

$$\sum_{k \in K} \sum_{t < \bar{T}} s_{jkt} = 1 \qquad \forall j \in D \tag{7}$$

$$s_{jkt} \le y_{jkt}, \qquad s_{jkt} \le y_{j,k,t+1} \qquad \forall j \in D,\ k \in K,\ t < \bar{T} \tag{8}$$

$$r_{kt} \le y_{0kt}, \qquad r_{kt} \le y_{0,k,t+1} \qquad \forall k \in K,\ t < \bar{T} \tag{9}$$

$$\sum_{j \in D} s_{jkt} + r_{kt} \le 1, \qquad \sum_{j \in D} s_{jkt} \le q_{kt} \qquad \forall k \in K,\ t < \bar{T} \tag{10}$$

$$q_{k,t+1} = q_{kt} - \sum_{j \in D} s_{jkt} + \rho_{kt}, \qquad q_{k0} = Q \qquad \forall k \in K,\ t < \bar{T} \tag{11}$$

$$\rho_{kt} \le Q\, r_{kt}, \qquad q_{k,t+1} \ge Q\, r_{kt} \qquad \forall k \in K,\ t < \bar{T} \tag{12}$$

$$\sum_{j:(i,j) \in E} g_{ijt} \;-\; \sum_{j:(j,i) \in E} g_{jit} = u_{it} \qquad \forall i \in N_{\mathrm{v}} \setminus \{0\},\ t \in T \tag{13}$$

$$g_{ijt} \le N\, u_{it} \qquad \forall (i, j) \in E,\ t \in T \tag{14}$$

$$C \ge t\, s_{jkt} \qquad \forall j \in D,\ k \in K,\ t < \bar{T} \tag{15}$$

$$s_{jkt} = 0 \qquad \forall k \in K,\ j \in D \text{ with } \mathrm{idx}(j) < k,\ t < \bar{T} \tag{16}$$

따라서 솔버의 값을 참조 계획이라 부르고, 모든 계획을 연속 시뮬레이터에서 재생해 재생된 makespan 을 보고한다.

4. 제안 제어기

그림 2에 설정과 두 제어기를 요약했다. 두 제어기는 목표 수준에서 결정한다. 매 결정 시점에 각 드론은 목표(수요지, 거점, 또는 중계 슬롯)를 받고 다음 결정 시점까지 그곳으로 전속

직진한다. 두 제어기는 목표를 고르는 방식만 다르다. 옵션 집합, 하위 비행, 중계 슬롯의 기하, 연결성 투영은 공유하며 이를 먼저 설명한다.

4.1. 공유 인터페이스: 옵션, 중계 슬롯, 투영

결정 시점과 옵션. 결정 시점은 20스텝마다 오고, 어떤 드론의 목표가 무효해지는 즉시도 온다. 목표가 무효해지는 경우는 다른 드론이 그 수요지를 배송했을 때, 수요지로 가는 중 적재가 떨어졌을 때, 거점으로 가는 중 가득 찼을 때, 속한 사슬이 짧아져 중계 슬롯이 사라졌을 때다. 결정 시점에 모든 드론은 $K = 7$개 옵션 중 하나를 받는다. 다섯 후보 수요지(그 드론에서 가장 가까운 미배송 수요지 다섯 곳) 중 하나, 거점으로 복귀, 또는 중계. 옵션은 그 순간 말이 될 때만 유효하다. 수요지 옵션은 적재와 후보가 있어야 하고, 복귀는 가득 차지 않았어야 하며, 중계는 빈 중계 슬롯(다음에 정의)과 자신이 중계 중이 아닌 동료가 적어도 하나 있어야 한다. 무효 옵션은 학습 정책에서는 마스크되고 휴리스틱은 애초에 내지 않으며, 유효 옵션이 없는 드론은 거점으로 복귀한다.

중계 슬롯. 중계 드론이 서는 자리는 제어기가 아니라 환경이 정한다. 드론 i의 전선 f_i는 다른 드론들의 배송 목표와 중계 중이 아닌 다른 드론들의 현재 위치 중 거점에서 가장 먼 점이다(없으면 가장 먼 미배송 수요지). 거리 d의 f_i까지 사슬에는 $n = \min(\lceil d/(0.9R) \rceil - 1,\ N - 1)$개의 중계 슬롯이 필요하고, 슬롯은 거점에서 f_i까지의 선분 위 길이의 $1/(n+1), \ldots, n/(n+1)$ 지점에 놓인다. 계수 0.9는 슬롯에서 약간 벗어나 선 드론이 링크를 끊지 않도록 여유를 둔 것이다. 드론 i는 자신에게 가장 가까운 빈 슬롯을 차지한다. 슬롯이 사라진 드론은 다음 결정 시점까지 제자리에 머문다. 따라서 제어기는 드론이 중계할지 여부만 결정하며 슬롯은 편대의 기하에서 따라 나온다.

하위 비행과 연결성 투영. 매 스텝 각 드론은 목표 방향으로 길이 v의 변위를 명령한다(서비스 중에는 0). 연결성을 보상 벌점으로 강제하면 어떤 행동으로도 막을 수 없는 상황을 벌하게 된다. 예컨대 하역 중 정지한 드론은 동료가 떠나면 고립된다. 따라서 연결성은 투영으로 강제한다. 명령된 위치가 G_t를 연결 상태로 두면 그대로 적용한다. 아니면 투영은 움직이는 드론 하나를 고르고, 그 변위를 편대가 연결되는 $[0, 1]$ 안의 최대 배율로 줄이며(다른 드론들의 현재 배율을 고정한 채 이분 탐색), 편대가 연결되는 즉시 멈추는 과정을 반복한다. 매 회차 제한했을 때 연결된 드론이 가장 많이 남는 드론을 고르고, 특정 앵커 드론이 굶지 않도록 동점은 무작위로 깬다. 직전 위치는 항상 연결 상태이므로 배율 0은 유효한 대안이고 제약은 구조적으로 성립한다. 변위가 10% 아래로 축소된 드론은 그 스텝에 정체한 것이고, 움직이는 드론 중 최대 한 대를 뺀 나머지가 정체한 스텝을 부분 교착이라 하며, 연속 부분 교착 스텝 수 δ_t가 휴리스틱의 복구 장치가 감시하는 양이다. 이 투영은 변위를 그 자체의 방향으로 줄인다. 접선 성분을 남기는 변형은 6.3절에서 다룬다.

4.2. 교착 복구을 갖춘 기하 사슬 중계 휴리스틱

휴리스틱은 매 결정 시점에 평가되는 결정론적 규칙이다(절차 1). 먼저 모든 드론에 기본값을 준다. 적재가 있는 드론은 가장 가까운 미배송 수요지로, 없는 드론은 거점으로. 그 다음 선두, 즉 적재가 있는 드론 중 거점에서 가장 먼 드론을 고르고, 선두의 목표에 몇 홉이 필요한지 계산한 뒤 나머지 드론 중 먼 것부터 그 수만큼을 중계로 돌린다. 중계 수는 적응적이고 중계는 사슬이 서야 할 곳에 이미 가장 가까운 드론들이라 규칙이 싸다. 결정당 비용은 $O(N \log N)$이고 구현에서 0.05–0.12 ms다.

교착 복구. 규칙은 결정론적이라 어떤 기하가 편대를 정체시키면 매 결정 시점에 같은 배정을 다시 내고 정체가 지속된다. 복구 장치가 없으면 규칙은 표준 인스턴스의 62%만 완주한다. 복구 장치는 시간제 덮어쓰기다. 편대가 k_{stall}스텝 이상 연속 부분 교착이고 진행 중인 복구이 없는 첫 결정 시점에 시작한다. h_{hold}회의 결정 시점, 즉 대략 $20\,h_{\text{hold}}$스텝(목표가 일찍 무효해지면 더 짧게) 동안 지속되며, 그 결정 시점들에서 규칙은 평소처럼 평가된 뒤 6단계처럼 덮어써진다. 횟수 e가 0이 되면 끝나고 평범한 규칙이 재개되며, 교착이 계속되면 다음 결정 시점에 다시 시작할 수 있다. 두 모드를 구현했다. 선두 교대에서는 현재 선두를 거점으로 돌려보내고 선두 역할이 다른 드론에게 넘어간다. 한 에피소드의 m번째 복구에서는 m번째로 먼 드론이 선두가 되어 반복 복구이 같은 두 드론을 맞바꾸는 대신 편대를 순환한다. 후퇴에서는 선두를 제외한 전원이 거점 쪽으로 복귀해 사슬이 느슨해진다. 모드와 두 파라미터는 6.5절에서 튜닝 시드로 고르며, 모든 비교에 $k_{\text{stall}} = 120, h_{\text{hold}} = 20$의 선두 교대를 쓴다.

4.3. 계층형 학습 정책

학습 제어기는 계층형이다(그림 3). 상위 관리자는 결정 시점에만 행동해 드론마다 옵션 하나를 내고, 하위는 4.1절의 공유 직진 비행이다. 따라서 관리자의 선택은 20스텝 동안 유지되고 관리자가 푸는 문제는 옵션 위의 반 마르코프 결정 과정이다 [60]. 학습되는 것은 관리자뿐이다. 두 층의 분리는 나머지 설계가 기대는 두 귀결을 낳는다. 관리자는 대형을 유지할 수 있는 거친 시간 척도로 편대를 보고, 하위는 고정 규칙이라 학습 없이 추론하고 연결성에 대해 투영할 수 있다.

집합 기반 인코더. 관리자는 드론 i를 네 종류의 엔티티로 부호화하며 모든 거리는 R로 나눈다. 자기 상태, 10개 특징: 적재 비율; 거점 거리; 홉 깊이를 8로 나눈 값; 미배송 비율; 경과 시간을 예산으로 나눈 값; 실현 이동 비율(명령 변위 대비 실제 변위의 지수 평균); 혼자 목표 쪽으로 한 스텝 전진해도 편대가 끊기지 않는지; 편대 전체의 실현 이동 비율; 서비스 타이머; G_t의 절단점 여부. 후보 수요지, 다섯 엔티티에 각 6개 특징: 거리; 단위 방향 벡터의 두 성분; 동료가 이미 겨냥했는지; 거점 거리; 그 사슬에 필요한 홉 수를 8로 나눈 값. 동료, $N - 1$개 엔티티에 각 9개 특징: 거리; 상대 위치 벡터의 두 성분; 적재 비율; 홉 깊이를 8로 나눈 값; 동료의 현재 목표 종류(배송, 복귀, 대기, 중계)의 4원 원핫. 중계 슬롯, 4개 특징: 거리; 단위 방향 벡터의 두 성분; 현재 사슬의 슬롯 수를 8로 나눈 값. 엔티티 종류별로 폭 128의 2층 MLP를 통과시킨다. 드론 자신의 임베딩을 질의로 두 다중 헤드 어텐션 층(헤드 4)이 동료 집합과 후보 집합을 벡터 하나씩으로 풀링하고, 네 벡터를 이어 붙여 MLP로 융합해 드론 임베딩 h_i를 만든다. 포인터 헤드는 $[h_i;\ e_{\text{cand}}]$로 후보 각각을 점수 매기고 고정 헤드는 h_i로 복귀와 중계를 점수 매기며, 일곱 점수는 마스크 후 소프트맥스로 정규화한다. 네트워크 어디에도 N이나 M에 의존하는 것이 없어 한 가중치가 본 적 없는 편대에서 돈다.

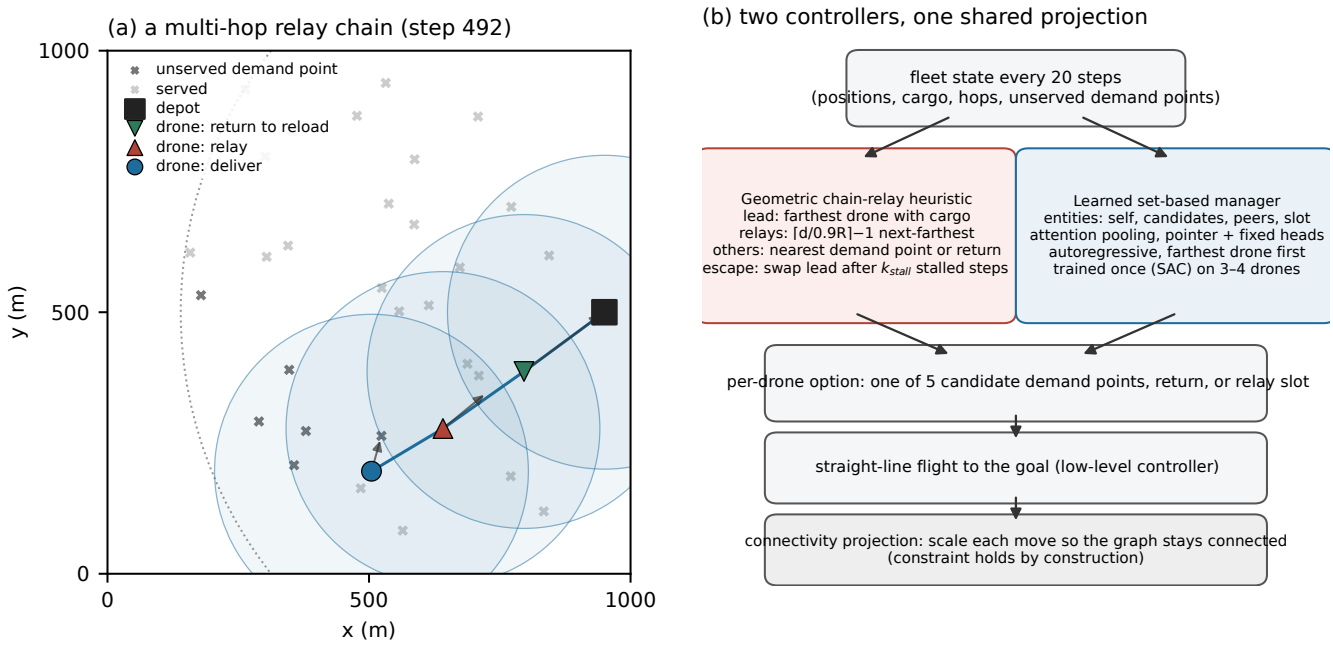


그림 2: (a) 드론 3대 인스턴스에서 휴리스틱으로 499스텝 진행한 상태. 선두 드론(파란 원)이 먼 수요지로 향하고, 한 대가 거점까지의 선분 위에서 중계하며(빨간 삼각형), 한 대는 재적재를 위해 거점으로 복귀한다(초록 삼각형). 음영 원판은 통신 반경, 점선 원은 도달 영역 $0.9NR$이다. (b) 두 제어기는 같은 드론별 옵션을 내고 직진 하위 제어기와 연결성 투영을 공유한다.

절차 1. 교착 복구을 갖춘 기하 사슬 중계 휴리스틱. 매 결정 시점에 실행한다. 호출 사이에 유지하는 상태: 남은 복구 길이 e(초기 0)와 복구 횟수 m(초기 0), 둘 다 에피소드 시작에 초기화. 파라미터: $k_{\text{stall}} = 120$, $h_{\text{hold}} = 20$, 모드 $\in$ {선두 교대, 후퇴}.

1. **복구 발동.** 편대가 $\delta_t \geq k_{\text{stall}}$스텝 연속 부분 교착이고 $e = 0$이면 $e \leftarrow h_{\text{hold}}$, $m \leftarrow m + 1$.
2. **기본 배정.** 각 드론 i에 대해: 적재가 없으면 옵션 $\leftarrow$ 복귀; 미배송 후보가 없으면 옵션 $\leftarrow$ 중계; 아니면 옵션 $\leftarrow$ 가장 가까운 미배송 수요지.
3. **선두.** 미배송 수요지가 없으면 종료. 아니면 $r_i = \|p_i - c\|$라 하고, 적재가 있는 드론 중 r_i를 최대화하는 드론을 선두로(적재가 있는 드론이 없으면 r_i 최대 드론).
4. **중계 수.** d_{goal}을 선두의 가장 가까운 미배송 수요지라 하고 $d = \max(r_{\text{lead}}, \|d_{\text{goal}} - c\|)$, $n = \min(\max(1, \lceil d/(0.9R) \rceil) - 1,\ N - 1)$.
5. **중계 선정.** 선두 외 드론을 r_i 내림차순으로 정렬해 앞의 n대의 옵션을 중계로.
6. **복구 기동**($e > 0$일 때만; 그러면 $e \leftarrow e - 1$). 선두 교대: 전체 드론을 r_i 내림차순으로 정렬해 그 순서의 $\min(m, N-1)$번째(0부터 셈) 드론을 새 선두로 하고, 이전 선두의 옵션을 복귀로, 새 선두가 적재와 미배송 후보가 있으면 그 옵션을 가장 가까운 미배송 수요지로. 후퇴: 선두를 제외한 모든 드론의 옵션을 복귀로.
7. 옵션을 반환; 환경이 이를 목표로 바꾸고 중계 슬롯을 배정.

자기회귀 결정. N개 옵션은 독립적으로 표본하지 않는다. 드론을 거점 거리 내림차순으로 정렬해 먼 드론부터, 관리자가 첫 드론의 옵션을 표본하고 그 새 역할을 남은 드론들이 보는 동료 특징의 역할 원핫에 써넣은 뒤 다시 부호화해 다음 드론을 표본하는 식으로 진행한다(절차 2). 선두 하나와 중계 k대의 대형은 독립 표본으로는 우연히만 나오지만 순차 결정에서는 의도적으로 구성할 수 있다. 대가는 결정 1회에 N번의 순차 네트워크 호출이다.

학습. 관리자는 옵션 전이에 대해 이산 soft actor-critic [18]으로 학습한다. 전이 하나는 결정 시점의 편대 관측, N개 옵션, 다음 결정 시점까지의 스텝에 걸쳐 누적한 옵션 수익 $\sum_\tau \gamma^\tau r_\tau$, 그 시점의 관측, 그리고 스텝당 $\gamma = 0.997$의 할인 $\gamma^{\Delta t}$를 저장한다. 팀 보상은 배송당 $+10$, 재적재당 $+30$, 스텝당 $-0.01N$, 미배송 비율에 비례하는 잔여 벌점 $-0.1N$이다. 드론 임베딩 사이에 어텐션을 둔 twin-Q critic이 드론별 행동가치를 내고 그 드론 평균을 옵션 수익에 회귀하며, actor는 드론별로 표준 기대값 형태 $\mathbb{E}_{a\sim\pi}[\alpha \log \pi(a) - Q(a)]$를 자기회귀 순서의 교사 강제로 최소화한다. 학습 구성의 세 요소가 중요하며 6.5절에서 절제한다. (i) 엔트로피 목표를 처음 400 에피소드 동안 $0.6 \log n_{\text{valid}}$에서 $0.25 \log n_{\text{valid}}$로 선형 감쇠시킨다. 높은 목표는 학습 초기에 정책을 교착에서 벗어날 만큼 무작위하게 유지하고 낮은 목표는 후기에 여러 스텝의 대형을 지키게 한다. (ii) 가중치 2.0의 교차엔트로피 항이 휴리스틱의 배정 규칙(절차 1의 2–5단계, 복구 없이)이 택할 옵션 쪽으로, 그 옵션이 유효한 곳에서, 정책을 당긴다. (iii) 모든 학습 에피소드는 $N \in \{3, 4\}$, $M \in [20, 80]$, 무작위 거점을 뽑는다. 최적화는 Adam 3×10^{-4}, 재생 버퍼 60,000에서 전이 256개 배치, 400개 전이의 워밍업 후 환경 4스텝마다 경사 1회, $\tau = 0.005$의 목표 critic Polyak 평균을 쓴다. 체크포인트는 50 에피소드마다 3,000스텝 예산의 검증 인스턴스 80개에서 $100f + 40(1 - \bar{t}/3000)$으로 고른다($f$는 완주율, $\bar{t}$는 평균 스텝). 학습은 8회 연속 평가에서 갱신이 없거나 1,000 에피소드에서 멈춘다. RTX 5080 하나를 네 실행이 나눠 쓸 때 한 실행에 약 13시간이 든다.

5. 실험 설계

인스턴스와 구성. 인스턴스는 정수 시드로 생성되며 시드·N·M·거점 모드가 인스턴스를 정확히 결정하므로 두 제어기를 동일 인스턴스에서 돌릴 수 있다. 평가 시드는 학습·체크포인트 선택·휴리스틱 튜닝에 쓴 시드와 겹치지 않는다. 표준 구성($N = 4$, $M = 50$,

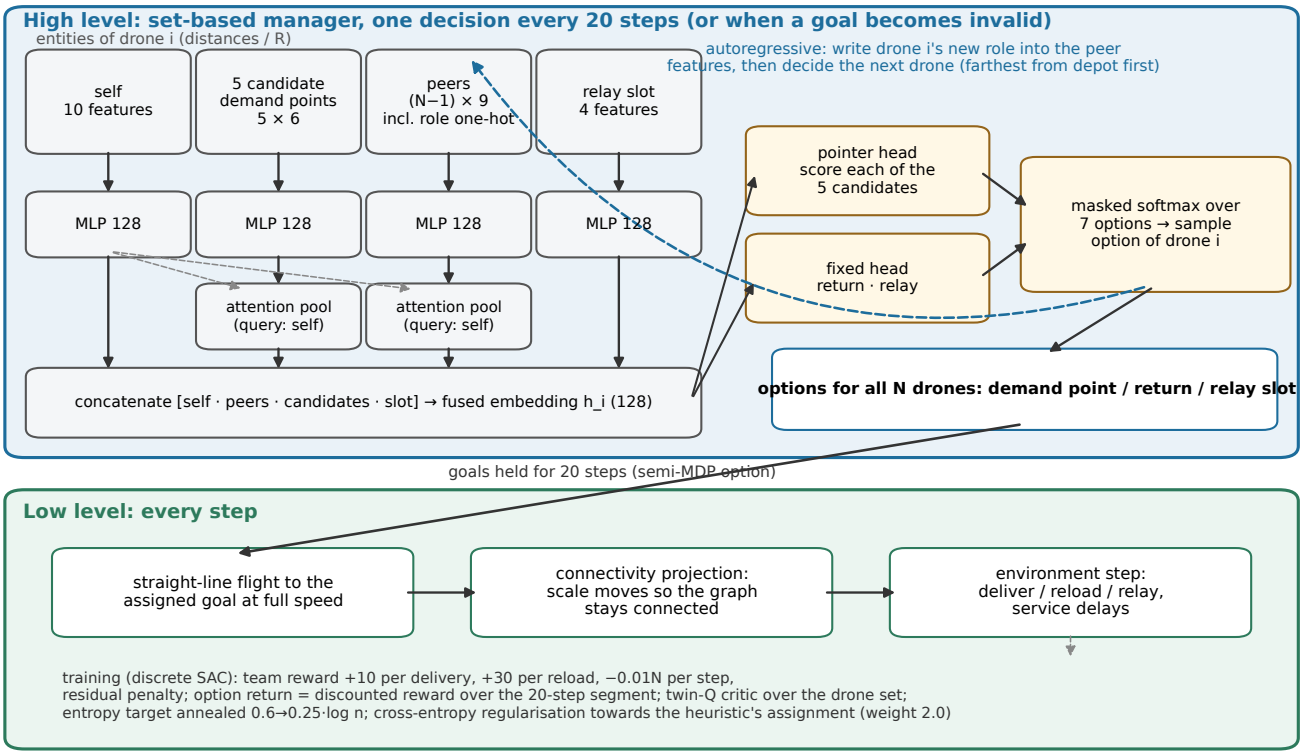


그림 3: 계층형 학습 제어기. 상위: 집합 기반 관리자가 각 드론을 네 종류의 엔티티로 부호화하고, 드론 자신의 임베딩을 질의로 동료 집합과 후보 집합을 어텐션 풀링하며, 포인터 헤드로 후보 다섯을, 고정 헤드로 복귀·중계를 점수 매긴다. 드론은 거점에서 먼 것부터 하나씩 결정되고 각 결정은 다음 드론이 보는 동료 특징에 써넣어진다. 하위, 매 스텝: 배정된 목표로의 직진 비행, 연결성 투영, 환경 스텝. 옵션은 20스텝 동안 유지된다.

절차 2. 결정 시점의 학습 관리자(추론).

1. 편대 상태로부터 모든 드론의 엔티티 관측을 만들고, 모든 드론의 일곱 옵션 유효성 마스크를 계산한다(4.1절).
2. 드론을 거점 거리 내림차순으로 정렬한다.
3. 그 순서로 각 드론 i에 대해: 현재 동료 역할로 모든 엔티티를 부호화하고, 드론 i의 마스크된 로짓 일곱을 계산하고, 소프트맥스에서 옵션을 표본하며(배치 추론은 argmax가 아니라 표본 추출), 선택된 역할(배송·복귀·중계)을 아직 결정되지 않은 드론들이 보는 드론 i의 동료 역할 원핫에 써넣는다.
4. N개 옵션을 반환; 환경이 이를 목표로 바꾸고 중계 슬롯을 배정한다.

고정 거점)과 무작위 거점의 미지 구성 여덟 개 $N/M \in \{3/20, 3/30, 4/80, 5/50, 6/80, 8/150, 10/300, 12/400\}$에서 평가한다.

베이스라인. 학습 없는 베이스라인 넷이 문제가 단순 배정으로 풀리지 않음을 보인다. 모두 4.1절의 공유 인터페이스를 쓰고 같은 결정 시점에 평가된다. 탐욕, 중계 없음은 절차 1의 2단계만이다. 적재가 있는 모든 드론은 가장 가까운 미배송 수요지로 날고 빈 드론은 복귀하며 아무도 중계하지 않으므로 사슬은 투영만으로 유지되어 편대가 정체한다. 고정 중계 한 대(두 대)는 편대의 처음 한(두) 대를 영구 중계로 배정하고 나머지에 탐욕 규칙을 돌린다. 중계 수가 선두의 거리에 적응하지 않고 미리 고정된다. 기하 규칙, 복구 없음은 절차 1에서 6단계를 뺀 것이다. 학습 없는 제어기는 투영의 무작위 동점 처리를 제외하면 모두 결정론적이다.

참조 모형. 수요지 $M \leq 5$곳의 인스턴스는 6.2절의 너비 우선 탐색으로 껍질 가지치기 격자에서 최적성이 증명되도록 풀고, $M \geq 6$곳은 시공간 MILP를 Gurobi 13 [66], 스레드 4개, 인스턴스당 1시간으로 푼다. 최적해 또는 찾은 최선의 계획은 모두 연속 시뮬레이터에서 재생한다.

쌍별 규약. 각 방법이 완주한 에피소드만 평균하면 어려운 인스턴스를 포기하는 쪽이 유리해지고, 긴 정체 한 건이 40회 실행 평균을 100스텝 넘게 움직인다. 따라서 두 제어기 사이의 모든 비교는 쌍별이다. 둘을 같은 인스턴스에서 돌리고 둘 다 완주한 인스턴스에서 차이를 취해, 쌍별 차이의 중앙값, 승–패 수, 윌콕슨 부호순위 p값을 보고한다. 추론은 정책에서 표본한다. 결정론적 argmax 추론은 중앙값이 같지만 꼬리가 훨씬 무겁다. 표준 구성은 480회 실행(60시드, 8회 반복, 두 번의 독립 측정), $3/30$과 $5/50$은 200(40시드, 5회), 나머지는 80(40시드, 2회)이다. 투영의 동점 처리가 무작위라 반복마다 결과가 다르다. 40회 실행은 꼬리에 관한 어떤 주장도 뒷받침하기에 부족했다.

6. 결과

6.1. RQ1: 하드 제약 아래의 완주

투영이 보장하는 대로 어떤 학습 에피소드와 평가 실행에서도 연결성은 위반되지 않았다. 표 2은 10,000스텝 예산 안의 완주를 보고한다. 학습 정책은 모든 구성의 모든 인스턴스를 완주한다. 복구 장치를 갖춘 휴리스틱은 98–100%를 완주하며,

표 2: 10,000스텝 예산 안의 완주. 무학습 베이스라인은 120회(표준) 또는 40회(미지) 실행, 제안 제어기 둘은 5절의 쌍별 실행 수. p는 같은 구성에서 각 방법의 완주 수를 학습 정책과 비교한 피셔 정확검정(양측)이다.

방법	4/50 표준	p	3/30	p	5/50	p
탐욕, 중계 없음	0%	$<10^{-4}$	0%	$<10^{-4}$	25%	$<10^{-4}$
중계 1대 고정	0%	$<10^{-4}$	2.5%	$<10^{-4}$	40%	$<10^{-4}$
중계 2대 고정	3.3%	$<10^{-4}$	52.5%	$<10^{-4}$	65%	$<10^{-4}$
규칙, 복구 없음	61.7%	$<10^{-4}$	95%	0.027	92.5%	0.004
규칙 + 복구 (제안)	473/480	0.015	200/200	1	191/200	0.004
학습 (제안)	**480/480**	—	**200/200**	—	**200/200**	—
	3/20		4/80		6/80	
규칙 + 복구 (제안)	80/80	1	80/80	1	79/80	1
학습 (제안)	**80/80**		**80/80**		**80/80**	
	8/150		10/300		12/400	
규칙 + 복구 (제안)	80/80	1	80/80	1	80/80	1
학습 (제안)	**80/80**		**80/80**		**80/80**	

놓치는 경우는 드론이 넉넉한 구성에 몰린다. 필요하지 않은 긴 사슬을 그대로 세워 두다가 정체하는 경우다. 복구 장치가 없으면 규칙은 표준 인스턴스의 61.7%를 완주하고, 단순 베이스라인은 거의 완주하지 못한다. 탐욕 배정은 편대를 잡아당겨 찢고, 고정 중계 대수는 수요지가 필요로 하는 중계 수가 거리에 따라 달라 대부분의 인스턴스에서 틀린다.

6.2. RQ2: 시공간 모형의 정확한 최적값과의 거리

정확해. 격자는 3.1절에서 유도한 간격 $h = 98$ m로 고정하고, 그 위의 시공간 모형을 상태 공간 너비 우선 탐색으로 최적성이 증명되도록 푼다. 상태는 드론 3대의 노드 다중집합과 배송 완료 수요지 집합이고, 드론이 동일하므로 상태는 순열을 무시해 보관하며, 탐색은 다중 홉 연결성 판정을 만족하면서 한 기간에 닿을 수 있는 모든 노드 삼중을 기간마다 확장해 모든 수요지가 배송될 때까지 진행한다. 모든 전이가 정확히 MILP의 실행 가능한 열이므로, 완전 집합이 처음 나타나는 기간이 모형의 최적 makespan 이다. 탐색은 적재량을 싣지 않아 용량 제약을 완화하므로, 최적 계획을 복원해 확인했고 40개 인스턴스 모두에서 어떤 드론도 $Q = 5$단위를 넘겨 배송하지 않아 완화가 조여 있음을, 즉 값이 원래 모형의 최적값임을 확인했다. 구현은 두 가지로 검증했다. Gurobi 가 $M = 4$에서 최적을 증명한 인스턴스에서 탐색은 같은 최적값을 1,242초 대신 1초에 돌려주고(시드 902, 10기간), MILP 가 한 시간 안에 최적을 증명한 $M = 6$의 세 인스턴스에서 둘은 정확히 일치한다(130, 100, 120스텝). 인스턴스당 0–11초가 걸리므로 $M = 3, 4, 5, 6$ 각각 10개 인스턴스를 푼다.

제어기를 모형과 같은 노드 집합 위에 두기. 연속 공간에서 도는 제어기와 격자에 묶인 계획은 중계를 같은 자리에 두지 않으므로, 둘 사이 차이의 일부는 결정 품질이 아니라 이산화의 산물이 된다. 그래서 두 제어기의 중계 슬롯을 같은 격자의 노드 집합으로 제한한다. 4.1절에서 계산한 슬롯 좌표를 가장 가까운 격자 노드로 바꾸어, 중계 드론이 모형이 놓을 수 있는 자리에만 설 수 있게 한다. 배송과 거점 목표는 구조상 이미 격자의 정확한 노드이므로 손댈 필요가 없다. 이 제한으로 휴리스틱은 40건 중 한 건의 완주를 잃는데, 최적 계획에서 한 드론이 수요지 6곳 중 5곳을 맡는 $M = 6$ 인스턴스다. 학습 정책은 제한이 있든 없든 40건을 모두 완주한다.

결과. 표 3와 그림 4에 40개 인스턴스 전부에 대한 제어기의 모형 최적값 대비 격차를 적었다. 두 제어기가 모두 완주한 39건 평균으로 휴리스틱은 최적값보다 9.7% 위, 학습 정책은 4.3% 위, 복구 덮어쓰기를 씌운 학습 정책은 3.2% 위이고, 학습 정책이 39건 중 27건에서 더 가깝다(윌콕슨 $p = 0.001$). 격차는 둘 다 수요지 수에 따라 커진다. $M = 3$의 2.3%와 −3.6%에서 $M = 6$의 17.8%와 10.7%로 커지는데, 수요지가 많을수록 사슬을 다시 세워야 하는 서비스 구간이 많아지고 그 순서를 잘못 정할 기회도 많아지기 때문이다.

이 수치를 읽는 데에는 두 가지 단서가 있고 둘 다 같은 방향이다. 첫째, 모형 최적값 자체가 연속 최적값의 상한이다. 모형의 드론은 격자 노드 사이를 이동하므로 축 방향 구간은 기간당 $\ell = 138.9$가 아니라 $h = 98$ m만 가고, 서비스는 기간 중간에 도착해도 10스텝 기간을 통째로 쓴다. M별 격차 중 셋이 음수인 이유가 이것이며, 연속으로 움직이는 제어기가 최선의 격자 계획보다 먼저 끝내는 $M = 3$에서 가장 뚜렷하다. 둘째, 격자를 촘촘히 하면 그 상한이 줄어든다. $M \le 5$ 인스턴스를 $h = 69$와 $h = 49$ m에서 풀면 평균 최적값이 7–9% 내려가지만($M = 3, 4, 5$에서 89에서 82, 110에서 103, 121에서 110스텝), 비용이 수 초에서 인스턴스당 25분으로 올라 모든 인스턴스에 치를 수는 없다. 따라서 표 3의 수치는 $h = 98$ m에서 모형이 표현할 수 있는 최선의 계획에 대한 격차이며 각 제어기의 참 최적 격차의 하한이다. RQ3이 기대는 두 제어기 사이의 순위는 영향을 받지 않는다. 둘을 같은 인스턴스에서 같은 참조에 대해, 같은 중계 자리를 쓸 수 있는 조건에서 쟀기 때문이다.

참조가 끊기는 지점. 탐색은 상태 공간에 묶이는데, 상태 공간은 수요지 수에 대해 2^M으로 커지고 재적재가 필요해지면 드론마다 적재 차원이 더 붙는다. 수요지 6곳을 넘으면 껍질 가지치기 격자의 MILP로 돌아가 인스턴스당 1시간, 솔버 스레드 4개로 푸는데, 여기서 참조 생산이 멈춘다. 8곳에서는 10건 중 5건의 실행 가능해를 돌려주고 최적 증명은 없으며(평균 잔여 갭 31%), 10곳에서는 4건 중 1건만 돌려준다(갭 37%). 그 인스턴스 대부분에서 두 제어기가 그 잠정해보다 빠른데, 이는 제어기보다 그 규모에서 한 시간의 분지한정이 무엇을 못 하는지를 말해 준다. 따라서 정확한 참조는 수요지 6곳 부근에서 끊기며, 이는 제어기가 돌아야 할 규모보다 두 자릿수 작다.

6.3. RQ3: 운용 조건에 따른 성능 비교

편대 크기가 구성 공간을 나눈다. 표 4와 그림 5이 아홉 구성의 쌍별 비교다. 드론 3대에서는 수요지 20곳과 30곳에서 휴리스틱이 쌍별 중앙값으로 각각 39와 30스텝 빠르다. 4대에서는 두 제어기가 통계적으로 구분되지 않는다. 표준 구성에서 480회 실행의 쌍별 중앙 차이는 +2스텝, 234승 239패($p = 0.52$)이고, 4/80에서는 학습 정책이 38스텝 빠르다. 5대 이상에서는 학습 정책이 빠르다. 5대에서 62스텝, 10대에서 178스텝으로 커지고 12대에서는 76스텝이다(70승 10패). 따라서 경계는 드론 4대에 있고, 우위는 측정한 가장 큰 편대 너머까지 이어지되 단조 증가는 10대와 12대 사이에서 멈춘다(6.4절에서 다시 다룬다). 휴리스틱의 튜닝 전 복구 파라미터에 대한 이전 측정도 같은 그림이었으므로(3/30, 4/50, 5/50, 10/300에서 +40, +0, −54, −170) 경계는 튜닝에 의존하지 않는다.

그림 6는 세 주요 구성의 전체 분포다. 3대에서는 휴리스틱의 곡선이 왼쪽에 있고, 4대에서는 두 곡선이 겹치며, 5대에서는 학습 정책의 곡선이 왼쪽에 있고 더 일찍 완주에 닿는다.

표 3: $h = 98$ m 시공간 모형의 최적값 대 제안 제어기, 드론 3대, M당 10 인스턴스. 최적값은 6.2절의 탐색으로 증명한 값이고, makespan 은 중계 위치를 모형의 노드 집합으로 제한한 연속 시뮬레이터의 값이다(휴리스틱은 결정론, 학습과 학습 + 복구는 30회 실행의 중앙값). 격차 열은 두 제어기가 모두 완주한 인스턴스에서 최적값 대비 비율을 평균한 것이고, p는 휴리스틱의 격차와 학습 정책의 격차에 대한 윌콕슨 부호순위 검정이다. 음수는 모형의 격자 이동과 10스텝 기간 때문이며, 이 때문에 모형 최적값은 연속 최적값의 상한으로 남는다.

M	건수	최적값	완주		최적값 대비 격차			p
		(평균)	휴리	학습	휴리스틱	학습	학습+복구	
3	10	89	10/10	10/10	+2.3%	-3.6%	-6.8%	0.109
4	10	110	10/10	10/10	+5.4%	-0.3%	-1.7%	0.051
5	10	121	10/10	10/10	+14.0%	+8.7%	+8.1%	0.186
6	10	136	9/10	10/10	+17.8%	+10.7%	+11.7%	0.129
전체	39	—	—	—	+9.7%	+4.3%	+3.2%	0.001

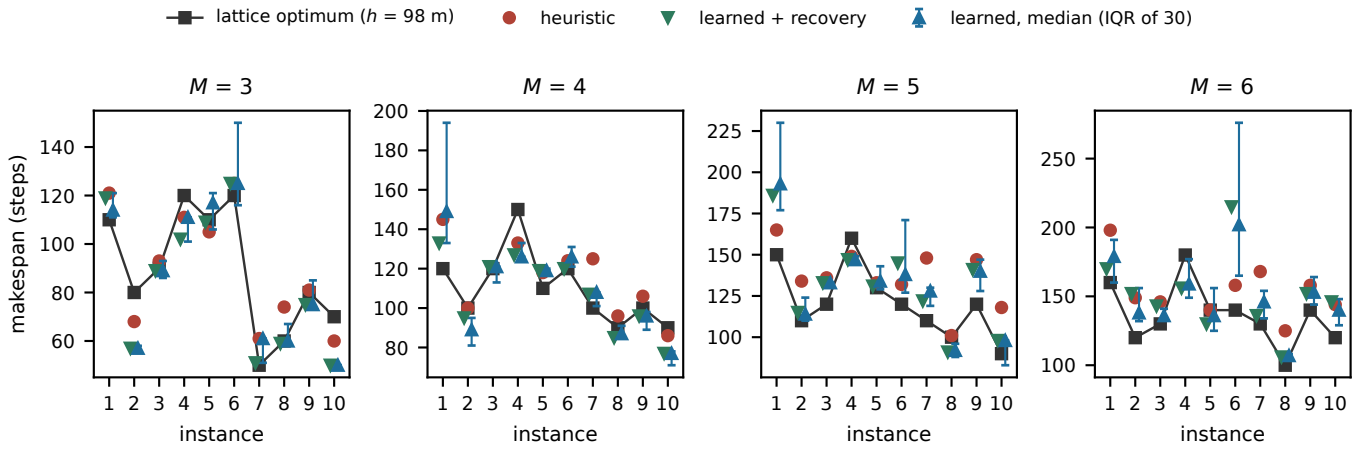


그림 4: 정확히 푼 드론 3대 인스턴스의 인스턴스별 makespan. $h = 98$ m 시공간 모형의 최적값(네모), 휴리스틱(원), 학습 정책의 중앙값과 30회 실행의 사분위 범위(위 세모), 복구 덮어쓰기를 씌운 학습 정책(아래 세모). 두 제어기의 중계 위치는 모형의 노드 집합으로 제한했다.

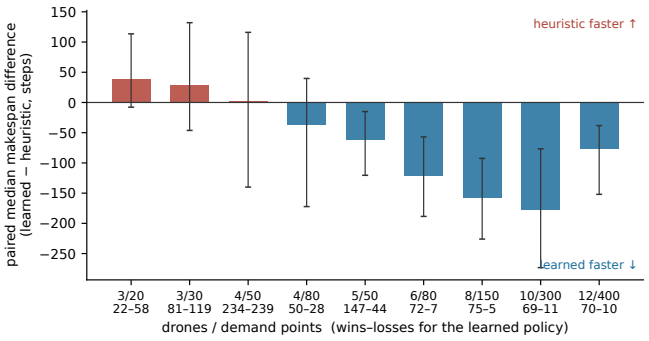


그림 5: 구성별 쌍별 중앙 makespan 차이(학습 − 휴리스틱). 오차 막대는 쌍별 차이의 사분위 범위, 각 라벨 아래는 학습 정책의 승–패. 음수가 학습 정책에 유리하며 경계는 드론 4대에 있다.

꼬리도 같은 방향으로 갈린다. 드론이 부족하면 학습 정책의 최악은 휴리스틱의 3–4배이고($3/30$에서 최댓값 5,395 대 1,447스텝), 넉넉하면 더 가볍다($5/50$에서 1,101 대 1,734, $10/300$에서 1,365 대 1,753). 튜닝 전 휴리스틱에 대한 표준 구성 480회 실행에서 학습 정책은 1,500스텝을 다섯 번, 휴리스틱은 열네 번 넘었다.

꼬리 안정화. 구호 작전에서는 중앙값보다 최악이 중요하므로 이 꼬리는 부담이다. 그래서 양쪽에서 없애 보았다. 학습 쪽에서는 제안 학습 구성으로 네 실행을 더 학습시켰다. 둘은 교착 복구 덮어쓰기를 롤아웃 루프 안에 넣어 정책이 배치될 때의 행동에 맞춰 배우게 했고, 둘은 엔트로피 목표를 0.25 대신 $0.10 \log n_{\text{valid}}$까지 감쇠시켜 학습 후반에 정책을 덜 무작위하게 했다. 둘 다 통하지 않았다. 낮은 엔트로피 목표는 $3/30$의 폭을 두 배로 키웠다(표준편차 629와 1,001 대 제안 정책 328, 최댓값 6,283과 9,049). 복구를 루프에 넣은 두 실행 중 하나는 $3/30$에서 제안 정책과 같았고 ($+36$ 대 $+30$) 다른 하나는 중앙값 110스텝을 잃었으며, 앞의 가중치를 추론에서 덮어쓰기 없이 평가하자 원래의 폭이 돌아왔다(표준편차 338, 최댓값 3,634). 학습 쪽 변경은 한 일이 없고 추론 시점의 덮어쓰기가 일을 한 것이다.

추론 쪽에서는 편대가 k_{stall}스텝 동안 부분 교착일 때 휴리스틱의 복구 단계 (절차 1의 6단계)를 제안 정책의 옵션에 덮어씌웠다. 재학습 없이 이것만으로 모든 구성에서 꼬리가 사라진다(표 5). 최악은 $3/30$에서 4,614에서 1,210스텝으로, 표준 구성에서 3,061에서 1,436으로 내려가고, 표준편차는 3분의 1에서 2분의 1로 줄며, 이전에 열두 번 있던 1,500스텝 초과가 한 번도 없다. 중앙값의 대가는 학습 정책이 이미 뒤처진 구성에만 머문다. $3/30$에서 $+30$ 대신 $+64$이고, 표준 구성은 오히려 조금 좋아지며(-13 대 $+2$, 둘 다 유의하지 않음) $5/50$은 그대로다 (-54 대 -62). 따라서 중앙값이 더 빠른 쪽인 맨 정책을 제안으로 보고하고, 최악을 보장해야 하는 곳에서는 덮어쓰기를 권한다.

표 4: 동일 인스턴스에서의 쌍별 비교. 양수는 학습 정책이 휴리스틱보다 느림을 뜻한다. p는 둘 다 완주한 쌍에 대한 윌콕슨 부호순위 검정.

N/M	롤아웃	완주 h/l	중앙값 휴리스틱 / 학습	쌍별 중앙	승–패	p
3/20	80	80/80	364 / 420	+39	22–58	$< 10^{-4}$
3/30	200	200/200	572 / 618	+30	81–119	3.4e-04
4/50 (표준)	480	473/480	878 / 878	+2	234–239	0.521
4/80	80	80/80	1,120 / 1,036	−38	50–28	0.006
5/50	200	191/200	588 / 534	−62	147–44	$< 10^{-4}$
6/80	80	79/80	737 / 614	−122	72–7	$< 10^{-4}$
8/150	80	80/80	916 / 722	−158	75–5	$< 10^{-4}$
10/300	80	80/80	1,216 / 1,052	−178	69–11	$< 10^{-4}$
12/400	80	80/80	1,199 / 1,108	−76	70–10	$< 10^{-4}$

표 5: 제안 정책에 추론 시점에서 교착 복구 덮어쓰기를 씌운 효과, 재학습 없음. 쌍별 중앙값과 승–패, p는 같은 인스턴스에서 튜닝된 휴리스틱에 대한 것이고, 표준편차·90분위·최대·1,500스텝 초과 횟수는 학습 정책 자신의 makespan 분포다.

구성	추론	실행	쌍별 중앙	승–패	p	표준편차	90분위	최대	>1,500
3/30	제안	200	+30	81–119	3.4e-04	328	837	4614	2
	+ 복구	200	+64	66–134	$< 10^{-4}$	149	858	1210	0
4/50	제안	480	+2	234–239	0.521	208	1104	3061	7
	+ 복구	240	−13	125–110	0.249	132	1052	1436	0
5/50	제안	200	−62	147–44	$< 10^{-4}$	125	712	1302	0
	+ 복구	200	−54	145–44	$< 10^{-4}$	131	734	1075	0

기제. 두 제어기는 한 결정에서 다르다. 3/30에서 휴리스틱은 평균 1.39대의 중계를 세우고 학습 정책은 0.78대를 세운다. 그 결과 학습 편대는 드론-스텝의 27%를 투영에 막혀 정체하고 휴리스틱은 8%다. 추론 시 학습 정책의 중계 배정만 휴리스틱의 것으로 덮으면 44스텝 격차 전부가 회복된다. 중계 대수만 맞추면 중앙값은 14스텝만 회복되지만 꼬리는 사라진다(최댓값 4,904에서 1,083). 중계하는 드론의 정체가 중앙값을 만들고 대수가 꼬리를 만든다. 휴리스틱의 선택에 필요한 정보는 학습 정책의 관측에 있다. 2층 분류기가 41개 관측 특징으로 휴리스틱의 중계 배정을 85% 정확도로 예측하고, 규칙 전체의 행동 복제는 중계 결정에서 95%에 이른다. 드론이 넉넉하면 반대 일이 일어난다. 휴리스틱은 기하가 더 이상 요구하지 않는 사슬을 계속 세우는 반면, 학습 정책은 여유를 활용하고 표본 추론으로 결정론적 규칙이 반복하는 정체를 빠져나간다. 휴리스틱이 몇 건의 완주를 잃는 곳도 여기다.

드론 부족 영역의 열세가 정책 쪽 처방에 저항하는 이유. 표 6는 드론이 부족할 때 학습 정책이 휴리스틱처럼 중계하게 만들려는 열한 가지 개입이다. 각각 명시한 변경을 제외하면 같은 학습 구성으로 시드 넷 또는 둘을 학습하고 같은 쌍별 규약으로 평가했다. 표의 번호로 변형은 다음과 같다. (V1) 휴리스틱 쪽 교차엔트로피 정규화를 휴리스틱 옵션이 중계인 드론에 세 배 가중; (V2) 배송하는 동료의 통신 경로 위에 있는 각 드론이 그 배송 때 개별 보상 (2.0 또는 6.0)을 받고 critic 을 드론별 수익으로 학습; (V3) 체크포인트 선택의 검증 집합 절반을 4/50 대신 3/30 구성으로 채움, 시드 8; (V4) V2와 같되 제로섬으로, 배송 드론이 중계들이 얻는 만큼 잃음; (V5) critic 을 동료들의 선택 역할에 조건화(결합 행동 critic)하고 목표값의 동료 다음 역할은 actor 에서 표본; (V6) 자기회귀 순서를 뒤집어 거점에 가장 가까운 드론부터 결정; (V7) 연속 부분 교착 60스텝 뒤 모든 목표를 무효화해 관리자가 재결정하도록, 학습과 평가 모두에서; (V8) critic 의 드론별 행동가치 평균을 합이 1이고 하한이 1/2인 상태 의존 단조 가중치로 대체; (V9) 각 드론의 옵션을 결정 시점 안에서 할인 1로 사슬처럼 이은 단일 에이전트 전이로 저장해 팀 수익의 분해가 필요 없게 함; (V10) 40,000회 결정에 대한 휴리스틱의 행동 복제(정확도 92.5%, 중계 결정 95%)로 관리자를 초기화한 뒤 미세조정, 50 에피소드 critic 워밍업 유무 각각; (V11) 병목 수요지의 추정 도달 시각에 비례하는 스텝당 벌점, 추정값을 각 드론의 실현 이동 비율로 나누어 막힌 드론을 느린 것으로 셈. 어느 것도 3/30 중앙값을 개선하지 못했고 여럿은 학습 정책이 이기는 구성을 해쳤다. 패턴이 시사적이다. 중계에 보상을 더하면 수단이 목적이 된다. 정책이 중계 자체를 위해 중계하고 5/50이 −54에서 +60으로 뒤집힌다. 드론별 크레딧으로 가는 길은 각기 다른 이유로 막힌다. 결합 행동 critic은 목표값에 표본된 동료 행동의 분산을 물려받고, 단조 혼합망은 가중치가 자유로우면 발산하고 하한을 두면 평균으로 무너지며, 순차 단일 에이전트 재정식화는 분해를 없애지만 수축이 없는 무할인 크레딧 사슬을 남긴다. 규칙의 행동 복제로 정책을 초기화하면(중계 정확도 95%) 400 에피소드 안에 지워진다. actor가 갱신되기 시작하면 50 에피소드 안에 중계 사용이 무작위 초기화 정책의 수준으로 떨어져 머문다. 병목 수요지의 추정 도달 시각에 대한 벌점은 정책이 최댓값이 아니라 평균을 줄이게 만든다. 이 정책 구조와 목적함수 안에서 중계 부족은 크레딧·정보·초기화의 인공물이 아니라 학습기의 고정점이라고 결론짓는다.

연결성 강제 모형에 대한 민감도. 4.1절의 투영은 막힌 변위를 같은 방향으로 축소하므로 사슬을 당기는 드론은 사실상 멈춘다. 목표 위치를 구속하는 이웃 주변 통신 원판의 가장 가까운 점으로 당기는 대안을 구현했다. 바깥 방향 성분만 제거하고 접선 성분은 남기므로 드론이 일정 거리를 유지한 채 돌 수 있다. 각 비교에서 두 제어기는 같은 투영을 쓰고 연결성은 여전히 위반되지 않는다. 이 측정은 6.5절의 휴리스틱 튜닝 이전에 두 투영 모두 $k_{\mathrm{stall}} = 60$, $h_{\mathrm{hold}} = 40$으로 한 것이라

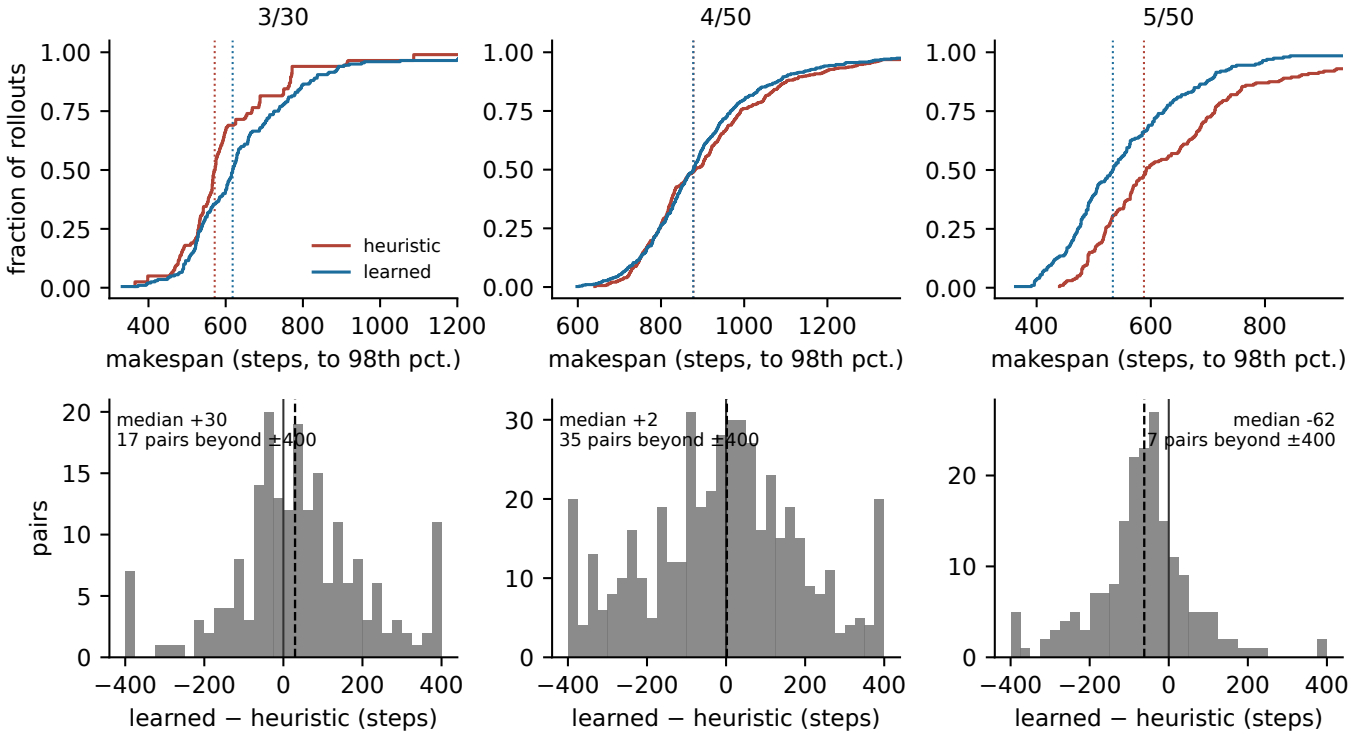


그림 6: 위: 3/30, 4/50, 5/50의 makespan 누적분포(점선은 중앙값, 축은 98 백분위에서 자름). 아래: 둘 다 완주한 인스턴스의 쌍별 차이 분포(±400스텝에서 잘랐으며 잘린 쌍 수를 표기).

내부적으로 일관된다. 같은 학습 가중치를 재학습 없이 접선 보존 투영에서 평가하면 3/30 열세가 +40에서 +21로 줄고, 네 시드를 재학습하면 +15에서 +48(평균 +28)이 되며 학습 편대의 정체율은 0.27에서 0.17–0.22로 내려간다. 완주는 여전히 100%다. 휴리스틱은 3대에서는 거의 얻지 못하지만(중앙값 570에서 571) 4대에서는 학습 정책보다 더 얻어(866에서 812, 학습은 879에서 850) 표준 구성에서 구분되지 않던 둘의 차이가 휴리스틱 쪽 +26으로 바뀐다. 따라서 같은 방향 투영을 기본 모형으로 유지하고 이것을 민감도 결과로 보고한다. 3대 열세의 약 절반은 학습기가 아니라 제약을 강제하는 방식의 성질이다.

통신 반경. 두 제어기를 재학습 없이 $R = 250$ m와 $R = 350$ m에서 돌렸다(표 7, 그림 7). 학습 정책은 거리를 R로 정규화하고 인스턴스 생성기는 도달 영역 $0.9NR$을 R에 맞춰 조정하므로 두 제어기는 각 반경에서 같은 인스턴스를 본다. 완주는 전이된다. 학습 정책은 두 반경 모두에서 모든 인스턴스를 완주하고, 휴리스틱은 짧은 반경의 5/50에서 200건 중 18건을 잃는다. 속도에는 두 효과가 나타난다. 첫째는 편대 크기에서 본 영역 이동이다. $R = 250$ m에서는 수요지에 더 많은 홉이 필요해 편대가 사실상 부족해지고 모든 구성이 휴리스틱 쪽으로 움직인다(3/30 +77, 4/50 +68, 5/50의 우위는 −16, $p = 0.33$으로 통계적으로 구분되지 않는 수준까지 줄어든다). $R = 350$ m에서는 편대가 사실상 넉넉해져 학습 정책이 4대에서 이미 빠르다(4/50 −40). 둘째는 학습 반경 효과다. 3/30과 5/50에서 학습 정책의 격차는 학습한 반경에서 가장 좋고 양쪽에서 나빠진다(300 m의 +30 대 +77과 +52, −62 대 −16과 −42). R 정규화는 완주를 전이시키지만 속도까지 온전히 전이시키지는 않는다. 따라서 영역 변수는

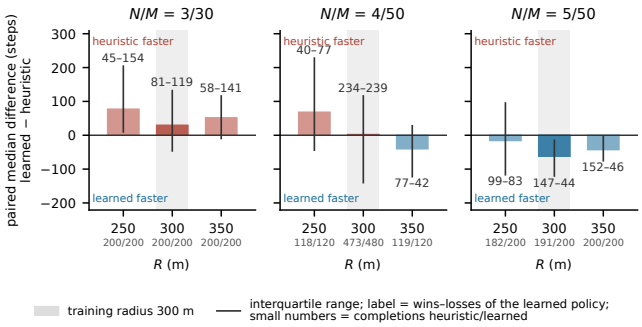


그림 7: 재학습 없이 다른 통신 반경으로 전이한 결과, 구성마다 한 패널. 막대는 쌍별 중앙 차이(학습 − 휴리스틱, 스텝)로, 0 위(빨강)는 휴리스틱이 빨랐다는 뜻이고 0 아래(파랑)는 학습 정책이 빨랐다는 뜻이다. 수염은 쌍별 차이의 사분위 범위, 막대 옆 숫자는 학습 정책의 승–패, 반경 아래 숫자는 완주 수(휴리스틱/학습)다. 음영 열이 학습 반경이다. 패널 안에서 왼쪽부터 읽으면, 반경이 짧아지면 모든 구성이 휴리스틱 쪽으로 움직이고, 3/30과 5/50에서는 학습 정책의 여유가 학습한 반경에서 가장 좋다.

편대 크기만이 아니라 사슬 수요, 즉 수요지가 필요로 하는 홉 수대 공급할 수 있는 드론 수이며, 학습 반경에서 먼 반경의 배치는 재학습하거나 적어도 경계를 재평가해야 한다.

6.4. RQ4: 학습 정책의 상향 전이

학습 정책은 학습에서 드론 4대, 수요지 80곳을 넘는 구성을 본 적이 없지만 드론 5–12대, 수요지 50–400곳의 모든 인스턴스를 완주하고 그 전부에서 휴리스틱보다 빠르다. 두 성질이 이를 떠받친다. 집합 기반 인코더에는 N이나

표 6: 드론 부족 영역의 열세를 제거하지 못한 개입들, 본문의 번호와 같음. 셀은 휴리스틱 대비 쌍별 중앙 차이의 시드 간 범위(양수: 학습이 느림)와, 괄호 안에 차이가 $p < 0.05$(윌콕슨 부호순위)로 유의한 시드 수 / 학습한 시드 수다. 기준 행은 튜닝된 휴리스틱에 대한 제안 정책(표 4)이고, 변형 행들은 튜닝 전 복구 파라미터($k_{\text{stall}} = 60$, $h_{\text{hold}} = 40$)의 휴리스틱에 대해 평가되었으며 그 휴리스틱에 대한 제안 정책은 +40, −54, +0이었으므로, 기준 행과 변형 행 사이의 수십 스텝 차이는 의미가 없다.

#	개입 (무엇을 바꿨나)	3/30	5/50	4/50	실패 기제
—	제안 학습 구성 (기준)	+30 (1/1)	−62 (1/1)	+0 (0/1)	—
V1	중계 가중 규칙 정규화 (×3)	+18, +58 (1/2)	−29, +13 (0/2)	+13, +41 (1/2)	중계 특화 정규화는 해로움
V2	드론별 중계 크레딧 (2.0 / 6.0)	+36 to +82 (4/4)	+60 to +106 (4/4)	+39 to +131 (4/4)	중계가 목적이 됨
V3	체크포인트 선택 절반을 3/30으로	+37 to +105 (8/8)	−58 to −22 (7/8)	−37 to +108 (3/8)	표준 구성만 개선
V4	제로섬 크레딧 재분배	+91, +126 (2/2)	+98, +172 (2/2)	+146, +180 (2/2)	같은 기제, 더 큼
V5	결합 행동 critic	+71 to +124 (4/4)	−46 to −16 (3/4)	+8 to +100 (2/4)	표본된 동료 행동의 목표값 분산
V6	가까운 드론부터 결정	+46, +100 (2/2)	−43, −38 (2/2)	+4, +106 (1/2)	순서는 원인이 아님
V7	정체 60스텝 뒤 재결정	+82, +95 (2/2)	−38, −34 (2/2)	+17, +55 (0/2)	불규칙한 옵션 길이
V8	단조 혼합 critic (하한 0.5)	+54 to +230 (4/4)	−28 to +38 (2/4)	+55 to +258 (4/4)	발산 방지와 크레딧이 한 축
V9	순차 단일 에이전트 크레딧	+81 to +213 (4/4)	+8 to +27 (2/4)	+62 to +170 (4/4)	결정 안에 수축 없음
V10	행동 복제 초기화 (워밍업 ±)	+6 to +69 (3/4)	−42 to −20 (3/4)	−16 to +40 (0/4)	400 에피소드 안에 지워짐
V11	병목 도달 시각 벌점 (0.15 / 0.25)	+85 to +144 (4/4)	−32 to +13 (2/4)	+7 to +156 (3/4)	최댓값이 아닌 평균을 줄임

표 7: 재학습 없는 다른 통신 반경으로의 전이. 셀은 완주(휴리스틱/학습)와 쌍별 중앙 차이(승–패, p). $R = 300$ m가 학습 반경.

N/M	$R = 250$ m	$R = 300$ m	$R = 350$ m
3/30	200/200 / +77 (45–154, $< 10^{-4}$)	200/200 / +30 (81–119, 3.4e-04)	200/200 / +52 (58–141, $< 10^{-4}$)
4/50	118/120 / +68 (40–77, $< 10^{-4}$)	473/480 / +2 (234–239, 0.521)	119/120 / −40 (77–42, 1.1e-04)
5/50	182/200 / −16 (99–83, 0.327)	191/200 / −62 (147–44, $< 10^{-4}$)	200/200 / −42 (152–46, $< 10^{-4}$)

M에 의존하는 매개변수가 없어 큰 편대는 그저 큰 집합일 뿐이고, 학습은 에피소드마다 편대 크기와 거점을 새로 뽑는다. 표 8은 둘을 분리한다. 구성 무작위화 없이 고정 4/50 구성만으로 학습한 절제 정책을 같은 큰 편대 인스턴스에서 재학습 없이 돌린 것이다. 그 정책도 5–10대의 모든 인스턴스를 완주하므로 완주는 구조만으로 일반화된다. 그러나 모든 구성에서 무작위화 정책보다 느리다(5/50에서 휴리스틱과 유의한 차이 없음 대 −62, 그 너머에서 −51에서 −174 대 −122에서 −178). 큰 편대에서의 속도는 작은 편대의 다양성에서 배운다. 같은 절제가 3/30에서는 114–296스텝을 잃으므로(표 10) 무작위화는 작은 편대 쪽을 쓸 만하게 만드는 조건이기도 하다. 두 정책 모두 최대 4대로 학습했고 홉 깊이와 슬롯 특징은 상수 8로 정규화되므로, 10대와 12대 편대는 인코더를 학습 특징값 범위 밖으로도 데려가는데 정책은 여전히 완주한다.

전이가 약해지는 곳. 12/400에서 폭이 좁아지는 원인은 분리하지 못했으며 세 가지 추정을 적어 둔다. 첫째, 두 제어기 모두 선두 하나로의 사슬 하나를 유지하므로 12대에서는 편대 대부분이 제어기와 무관하게 거점 근처에서 배송하고, 둘 사이에 다른 결정은 점점 작은 몫의 일에만 관여한다. 둘째, 수요지 400곳에서는 드론의 후보 다섯이 모두 가까워 그 사이의 선택이 덜 중요해지고, 목표와 중계를 함께 고르는 데 있는 학습 정책의 강점이 작용할 여지가 줄어든다. 셋째, 관리자의 홉 깊이와 슬롯 특징은 상수 8로 정규화되어 큰 편대에서 1을 넘고, 열두 번의 순차 자기회귀 결정은 표본 잡음을 누적하므로 둘 다 정책을 학습 분포에서 더 멀리 떼어 놓는다. 어느 것이 지배적인지는 12대 너머의 편대가 있어야 가릴 수 있다.

6.5. RQ5: 구성 요소는 필수적인가

휴리스틱. 표 9은 $k_{\text{stall}} \in \{30, 60, 90, 120\}$, $h_{\text{hold}} \in \{20, 40, 80\}$, 두 복구 모드, 그리고 복구 없음을 3/30, 4/50, 5/50에서 각 40 튜닝 시드로 격자 탐색한 것이다. 설정은 완주 합 우선, 중앙 makespan 합 차선으로 순위를 매겼고 이 기준은 측정 전에 정했다. 복구 장치는 필수다. 없으면 규칙은 표준 인스턴스 40건 중 25–26건을 완주한다(두 번 측정). 시점보다 모드가 더 중요하다. 선두 교대 설정은 모두 120건 중 117–120건을 완주하는 반면 후퇴 설정은 101–117건을 완주하는데, 사슬을 느슨하게 해도 정체를 만든 배정이 바뀌지 않기 때문이다. 선두 교대 안의 차이는 통계적으로 의미가 없다. 격자를 다시 측정하고 같은 40 인스턴스에서 모든 설정을 선택 설정과 쌍별 윌콕슨 검정으로 비교한 결과를 표에 함께 적었는데, 어떤 구성에서도 선택 설정과 $p < 0.05$로 다른 설정은 없고(모두 $p \geq 0.09$), 다른 설정 하나(30/40)도 120건을 모두 완주하며 중앙값 합이 13스텝 낮지만 이는 동점 처리 잡음이다. 선택 설정($k_{\text{stall}} = 120$, $h_{\text{hold}} = 20$)은 첫 측정에서 정했고 전체에 그대로 쓴다. 적응적 중계 대수도 필수다. 한 대나 두 대로 고정하면 0–65%를 완주한다 (표 2).

학습 정책. 표 10은 요소를 하나씩 빼고 같은 예산으로 시드 둘을 재학습한 뒤, 각 절제 정책을 제안 정책과 같은 인스턴스(6.3절 쌍별 실행의 앞 120·80·80회)에서 돌린 것이다. 셀은 인스턴스별 makespan 차이의 중앙값과 윌콕슨 부호순위 p를 시드별로 적었다. 규칙 정규화와 엔트로피 목표 감쇠는 어디서나 필수다. 어느 쪽을 빼도 모든 구성과 시드에서 52–189스텝을 잃고 $p < 10^{-4}$다. 구성 무작위화는 학습 분포 밖에서 필수다. 빼면 절제 정책이 학습한 표준 구성에서는 중립이지만(−19와 −34, $p \geq 0.12$) 3/30에서 114–296스텝, 5/50에서 53–76스텝을 잃는다. 자기회귀 결정은 모든 구성에서 32–88스텝을 돕는다($p \leq 0.007$). 잔여 벌점은 중립이다. 어떤 구성의 어떤 시드도 제안 정책과 $p < 0.05$로 다르지 않다. 초기 버전에서 표준 구성만으로 학습한 고정 크기 MLP 인코더의 상위 정책은 표준 인스턴스의 38%를 완주했고 다른 편대 크기에서는 아예 돌릴 수 없었다.

6.6. 추론 비용

표 11는 CPU에서 상위 결정 1회의 지연이다. 휴리스틱은 0.05–0.12 ms, 학습 정책은 자기회귀 없이 1.3–2.5 ms,

표 8: 학습에서 본 어떤 편대보다 큰 편대로의 재학습 없는 전이. 셀은 학습 정책의 완주, 휴리스틱 대비 쌍별 중앙 차이(음수: 학습 정책이 빠름), 괄호 안은 학습 정책의 승–패와 윌콕슨 부호순위 p. 제안 정책은 무작위 거점의 $N \in \{3,4\}$로 학습했고, 비교 정책은 고정 $4/50$ 구성만으로 학습한 절제 정책(시드 2개)이다.

N/M	$N \in \{3,4\}$, $M \in [20,80]$ 학습	$4/50$만 학습, 시드 1	시드 2
5/50	200/200 / -62 (147–44, $< 10^{-4}$)	80/80 / $+7$ (35–39, 0.840)	80/80 / $+44$ (28–50, 0.002)
6/80	80/80 / -122 (72–7, $< 10^{-4}$)	80/80 / -56 (57–20, $< 10^{-4}$)	80/80 / -51 (51–27, 0.010)
8/150	80/80 / -158 (75–5, $< 10^{-4}$)	80/80 / -129 (68–11, $< 10^{-4}$)	80/80 / -110 (60–20, $< 10^{-4}$)
10/300	80/80 / -178 (69–11, $< 10^{-4}$)	80/80 / -152 (69–11, $< 10^{-4}$)	80/80 / -174 (68–12, $< 10^{-4}$)

표 9: 평가 시드와 분리된 튜닝 시드(구성당 40 인스턴스)에서의 휴리스틱 절제. 셀은 완주 인스턴스 수, 완주 인스턴스의 중앙 makespan, 그리고 괄호 안에 둘 다 완주한 인스턴스에서 그 설정을 선택 설정(굵게)과 비교한 윌콕슨 부호순위 검정의 p값이다. 마지막 열은 세 구성의 완주 합이다.

방식	k_{stall} / h_{hold}	3/30	4/50	5/50	완주 합
없음	—	39/40 / 559 (0.228)	25/40 / 817 (0.258)	38/40 / 602 (0.093)	102/120
선두 교대	30 / 20	40/40 / 557 (0.121)	39/40 / 853 (0.130)	40/40 / 625 (0.928)	119/120
선두 교대	30 / 40	40/40 / 562 (0.673)	40/40 / 867 (0.775)	40/40 / 606 (0.247)	120/120
선두 교대	30 / 80	40/40 / 567 (0.158)	39/40 / 844 (0.754)	39/40 / 614 (0.404)	118/120
선두 교대	60 / 20	40/40 / 557 (0.599)	39/40 / 849 (0.780)	40/40 / 600 (0.791)	119/120
선두 교대	60 / 40	40/40 / 554 (0.497)	39/40 / 852 (0.807)	40/40 / 625 (0.944)	119/120
선두 교대	60 / 80	40/40 / 556 (0.359)	39/40 / 863 (0.788)	39/40 / 632 (0.675)	118/120
선두 교대	90 / 20	40/40 / 566 (0.206)	39/40 / 871 (0.908)	40/40 / 599 (0.375)	119/120
선두 교대	90 / 40	40/40 / 559 (0.473)	40/40 / 856 (0.674)	37/40 / 634 (0.844)	117/120
선두 교대	90 / 80	40/40 / 563 (0.786)	39/40 / 858 (0.149)	39/40 / 629 (0.615)	118/120
선두 교대	**120 / 20**	40/40 / 561	40/40 / 867	40/40 / 620	**120/120**
선두 교대	120 / 40	40/40 / 557 (0.757)	39/40 / 878 (0.685)	40/40 / 624 (0.979)	119/120
선두 교대	120 / 80	40/40 / 562 (0.687)	38/40 / 829 (0.546)	39/40 / 626 (0.850)	117/120
후퇴	30 / 20	37/40 / 559 (0.350)	35/40 / 836 (0.185)	40/40 / 632 (0.528)	112/120
후퇴	30 / 40	39/40 / 556 (0.079)	29/40 / 832 (0.284)	39/40 / 621 (0.157)	107/120
후퇴	30 / 80	38/40 / 561 (0.754)	26/40 / 804 (0.443)	37/40 / 584 (0.368)	101/120
후퇴	60 / 20	39/40 / 556 (0.866)	38/40 / 847 (0.215)	38/40 / 603 (0.759)	115/120
후퇴	60 / 40	39/40 / 559 (0.875)	39/40 / 823 (0.485)	39/40 / 624 (0.459)	117/120
후퇴	60 / 80	39/40 / 563 (0.991)	26/40 / 795 (0.236)	40/40 / 635 (0.490)	105/120
후퇴	90 / 20	39/40 / 566 (0.512)	38/40 / 822 (0.058)	40/40 / 642 (0.773)	117/120
후퇴	90 / 40	39/40 / 566 (0.180)	39/40 / 852 (0.634)	39/40 / 618 (0.615)	117/120
후퇴	90 / 80	39/40 / 562 (0.665)	36/40 / 830 (0.578)	37/40 / 598 (0.354)	112/120
후퇴	120 / 20	39/40 / 556 (0.645)	37/40 / 863 (0.327)	38/40 / 614 (0.460)	114/120
후퇴	120 / 40	39/40 / 560 (0.757)	37/40 / 831 (0.451)	38/40 / 628 (0.602)	114/120
후퇴	120 / 80	39/40 / 561 (0.191)	38/40 / 854 (0.815)	37/40 / 627 (0.308)	114/120

자기회귀로 2.7–7.4 ms이며 드론마다 순차 네트워크 호출이라 편대에 선형으로 커진다. 900스텝 에피소드에서 학습 정책의 누적 결정 시간은 0.16 s다. 정확 탐색은 $h = 98$ m에서 수요지 3–6곳 인스턴스에 0–11초가 걸리고, 더 큰 인스턴스의 MILP는 1시간을 다 쓴다.

7. 논의

배치. 두 제어기는 상보적이고 경계가 뚜렷하므로 운영자는 편대 크기로 고를 수 있다. 드론 3대면 휴리스틱, 5대 이상이면 더 빠르고 더 신뢰할 수 있는 학습 정책이며, 4대에서는 둘의 속도가 통계적으로 구분되지 않고 학습 정책이 더 많이 완주한다. 둘 다 밀리초에 결정하고 둘 다 구조적으로 편대의 연결을 지킨다.

음성 결과의 의미. 학습기의 크레딧·정보·초기화·보상을 바꾸는 열한 가지 개입이 드론 부족 영역의 열세를 그대로 두었고, 환경의 강제 모형을 바꾸자 절반이 사라졌다. 따라서 이 열세는 더 학습하거나 더 나은 critic으로 고칠 결함이 아니라, 이 목적함수 아래 학습기의 고정점과 제약의 기하 사이의 상호작용으로 이해하는 것이 맞다. 실무자에게 실행 가능한 결론은 위의 것 하나다. 영역에 따라 제어기를 고르라.

한계. 학습 정책은 하나의 통신 반경에서 학습했다. 250과 350 m로 완주는 전이되지만 휴리스틱 대비 속도 순위는 반경에 따라 바뀌며(6.3절), 그 밖의 반경은 시험하지 않았다. 환경은 평면이고 바람·배터리·충돌을 무시하며 원판 통신 모형을 쓴다. 실제 링크는 원판이 아니다. 정확한 최적값은 격자 간격 하나에서 이산화된 모형의 것이다. 98 m 격자와 10스텝 기간의 양자화는 49 m로 촘촘히 하면 7–9% 줄지만 모든 인스턴스에 치를 수 없는 비용이라 측정된 격차는 참 격차를 과소평가하며, 수요지 6곳을 넘으면 최적성 갭이 남은 솔버 잠정해만 있다. 휴리스틱의 참신성은 사슬 기하 자체보다 복구 장치와 적응적 중계 대수에 있다.

방법론적 주석. 결론에 중요했던 세 실천이 있다. 완주 에피소드 평균은 포기하는 제어기에 유리하므로 비교는 쌍별이어야 한다. 40회 실행은 꼬리에 관한 주장을 뒷받침하지

표 10: 학습 정책의 절제. 각 셀은 독립 학습한 시드 둘에 대해, 절제 정책과 제안 정책을 같은 인스턴스에서 비교한 인스턴스별 makespan 차이의 중앙값(양수: 뺀 요소가 필요했음)과 윌콕슨 부호순위 p다.

제거한 요소	4/50 (120회)	3/30 (80회)	5/50 (80회)
규칙 정규화	+121 ($< 10^{-4}$) / +189 ($< 10^{-4}$)	+171 ($< 10^{-4}$) / +160 ($< 10^{-4}$)	+52 ($< 10^{-4}$) / +152 ($< 10^{-4}$)
구성 무작위화	−19 (0.260) / −34 (0.119)	+114 ($< 10^{-4}$) / +296 ($< 10^{-4}$)	+53 (2.7e-04) / +76 ($< 10^{-4}$)
엔트로피 목표 감쇠	+136 ($< 10^{-4}$) / +138 ($< 10^{-4}$)	+138 ($< 10^{-4}$) / +130 ($< 10^{-4}$)	+58 ($< 10^{-4}$) / +76 ($< 10^{-4}$)
자기회귀 결정	+32 (0.007) / +84 ($< 10^{-4}$)	+88 (3.2e-04) / +56 (0.002)	+42 (2.7e-04) / +60 (9.1e-04)
잔여 벌점	−4 (0.746) / −32 (0.204)	+16 (0.625) / −28 (0.291)	+24 (0.120) / +12 (0.374)

표 11: 상위 결정 1회의 지연(밀리초, CPU)과 900스텝 에피소드의 누적 결정 시간.

제어기	$N = 3$	$N = 4$	$N = 6$	$N = 8$	900스텝
기하 규칙 + 복구	0.05	0.08	0.10	0.12	0.003 s
학습, 독립 결정	1.27	1.52	1.94	2.45	0.069 s
학습, 자기회귀 (제안)	2.70	3.52	5.32	7.35	0.158 s

못하며, 우리 자신의 중간 결론 여럿이 표본이 커지자 뒤집혔다. 그리고 최종 판정과 다른 지표를 쓰는 사전 점검은 최종 판정이 기각할 개입을 통과시킨다.

8. 결론

연결성 제약 드론 배송을 위한 두 제어기, 교착 복구을 갖춘 기하 사슬 중계 휴리스틱과 편대 크기 불변 학습 정책을 제안했다. 둘 다 매 스텝 편대를 연결 상태로 유지하는 투영을 통해 행동한다. 드론 3–12대 편대의 쌍별 규약에서 학습 정책은 모든 인스턴스를 완주하고, 3·4대로만 학습했는데도 4대를 넘는 드론이 있으면 38–178스텝 빠르며, 3대에서는 휴리스틱이 30–39스텝 빠르다. 드론 부족 영역의 열세는 어느 드론이 중계할지라는 한 결정이며, 열한 가지 정책 쪽 개입에 저항하고 강제 모형을 바꾸면 절반으로 준다. 시공간 모형의 정확한 최적값이 있는 곳에서 학습 정책은 그보다 평균 4.3%, 휴리스틱은 9.7% 위이며, 두 제어기는 재적재가 필요해지면 최적 증명을 멈추는 정확 기법보다 세 자릿수에서 여섯 자릿수 빠르게 결정한다. 자연스러운 다음 단계는 출력이 드론별 옵션 집합이 아니라 팀 배정인 정책으로, 중계 드론의 정체를 critic이 직접 평가할 수 있는 좌표로 만드는 것이다.

감사의 글

[추가 예정.]

데이터와 코드

코드, 학습 가중치, 인스턴스 생성기, 쌍별 비교 기록은 `https://github.com/koptimizer/relay_drone_network`에서 받을 수 있다.

References

[1] S. Chowdhury, A. Emelogu, M. Marufuzzaman, S. G. Nurre, L. Bian, Drones for disaster response and relief operations: A continuous approximation model, International Journal of Production Economics 188 (2017) 167–184.

[2] B. Rabta, C. Wankmüller, G. Reiner, A drone fleet model for last-mile distribution in disaster relief operations, International Journal of Disaster Risk Reduction 28 (2018) 107–112.

[3] M. Erdelj, E. Natalizio, K. R. Chowdhury, I. F. Akyildiz, Help from the sky: Leveraging UAVs for disaster management, IEEE Pervasive Computing 16 (1) (2017) 24–32.

[4] S. J. Kim, G. J. Lim, J. Cho, M. J. Côté, Drone-aided healthcare services for patients with chronic diseases in rural areas, Journal of Intelligent & Robotic Systems 88 (2017) 163–180.

[5] Z. Ghelichi, M. Gentili, P. B. Mirchandani, Logistics for a fleet of drones for medical item delivery: A case study for Louisville, KY, Computers & Operations Research 135 (2021) 105443.

[6] C. C. Murray, A. G. Chu, The flying sidekick traveling salesman problem: Optimization of drone-assisted parcel delivery, Transportation Research Part C: Emerging Technologies 54 (2015) 86–109. doi:10.1016/j.trc.2015.03.005.

[7] A. Otto, N. Agatz, J. Campbell, B. Golden, E. Pesch, Optimization approaches for civil applications of unmanned aerial vehicles (UAVs) or aerial drones: A survey, Networks 72 (4) (2018) 411–458.

[8] G. Macrina, L. Di Puglia Pugliese, F. Guerriero, G. Laporte, Drone-aided routing: A literature review, Transportation Research Part C: Emerging Technologies 120 (2020) 102762.

[9] S. H. Chung, B. Sah, J. Lee, Optimization for drone and drone-truck combined operations: A review of the state of the art and future directions, Computers & Operations Research 123 (2020) 105004.

[10] Y. Zeng, R. Zhang, T. J. Lim, Throughput maximization for UAV-enabled mobile relaying systems, IEEE Transactions on Communications 64 (12) (2016) 4983–4996. doi:10.1109/TCOMM.2016.2611512.

[11] M. Mozaffari, W. Saad, M. Bennis, Y.-H. Nam, M. Debbah, A tutorial on UAVs for wireless networks: Applications, challenges, and open problems, IEEE Communications Surveys & Tutorials 21 (3) (2019) 2334–2360.

[12] O. Burdakov, P. Doherty, K. Holmberg, J. Kvarnström, P.-M. Olsson, Relay positioning for unmanned aerial vehicle surveillance, The International Journal of Robotics Research 29 (8) (2010) 1069–1087.

[13] M. M. Zavlanos, M. B. Egerstedt, G. J. Pappas, Graph-theoretic connectivity control of mobile robot networks, Proceedings of the IEEE 99 (9) (2011) 1525–1540.

[14] C. Dixon, E. W. Frew, Maintaining optimal communication chains in robotic sensor networks using mobility control, Mobile Networks and Applications 14 (3) (2009) 281–291.

[15] L. R. Ford, D. R. Fulkerson, Flows in Networks, Princeton University Press, Princeton, NJ, 1962.

[16] M. Skutella, An introduction to network flows over time, in: Research Trends in Combinatorial Optimization, Springer, Berlin,

2009, pp. 451–482.
[17] R. Roberti, M. Ruthmair, Exact methods for the traveling salesman problem with drone, Transportation Science 55 (2) (2021) 315–335.
[18] T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1861–1870.
[19] W. Kool, H. van Hoof, M. Welling, Attention, learn to solve routing problems!, in: Proceedings of the 7th International Conference on Learning Representations, 2019.
[20] J. Park, C. Kwon, J. Park, Learn to solve the min-max multiple traveling salesmen problem with reinforcement learning, in: Proceedings of the 22nd International Conference on Autonomous Agents and Multiagent Systems, 2023, pp. 878–886.
[21] G. B. Dantzig, J. H. Ramser, The truck dispatching problem, Management Science 6 (1) (1959) 80–91.
[22] P. Toth, D. Vigo (Eds.), Vehicle Routing: Problems, Methods, and Applications, 2nd Edition, SIAM, Philadelphia, PA, 2014.
[23] P. Kitjacharoenchai, M. Ventresca, M. Moshref-Javadi, S. Lee, J. M. A. Tanchoco, P. A. Brunese, Multiple traveling salesman problem with drones: Mathematical model and heuristic approach, Computers & Industrial Engineering 129 (2019) 14–30.
[24] C. C. Murray, R. Raj, The multiple flying sidekicks traveling salesman problem: Parcel delivery with multiple drones, Transportation Research Part C: Emerging Technologies 110 (2020) 368–398. doi:10.1016/j.trc.2019.11.003.
[25] N. Agatz, P. Bouman, M. Schmidt, Optimization approaches for the traveling salesman problem with drone, Transportation Science 52 (4) (2018) 965–981. doi:10.1287/trsc.2017.0791.
[26] Q. M. Ha, Y. Deville, Q. D. Pham, M. H. Hà, On the min-cost traveling salesman problem with drone, Transportation Research Part C: Emerging Technologies 86 (2018) 597–621.
[27] M. Dell'Amico, R. Montemanni, S. Novellani, Drone-assisted deliveries: New formulations for the flying sidekick traveling salesman problem, Optimization Letters 15 (2021) 1617–1648.
[28] S. Poikonen, X. Wang, B. Golden, The vehicle routing problem with drones: Extended models and connections, Networks 70 (1) (2017) 34–43.
[29] D. Sacramento, D. Pisinger, S. Ropke, An adaptive large neighborhood search metaheuristic for the vehicle routing problem with drones, Transportation Research Part C: Emerging Technologies 102 (2019) 289–315.
[30] D. Schermer, M. Moeini, O. Wendt, A matheuristic for the vehicle routing problem with drones and its variants, Transportation Research Part C: Emerging Technologies 106 (2019) 166–204.
[31] K. Dorling, J. Heinrichs, G. G. Messier, S. Magierowski, Vehicle routing problems for drone delivery, IEEE Transactions on Systems, Man, and Cybernetics: Systems 47 (1) (2017) 70–85.
[32] V. Pillac, M. Gendreau, C. Guéret, A. L. Medaglia, A review of dynamic vehicle routing problems, European Journal of Operational Research 225 (1) (2013) 1–11.
[33] I. Bekmezci, O. K. Sahingoz, S. Temel, Flying ad-hoc networks (FANETs): A survey, Ad Hoc Networks 11 (3) (2013) 1254–1270.
[34] L. Gupta, R. Jain, G. Vaszkun, Survey of important issues in UAV communication networks, IEEE Communications Surveys & Tutorials 18 (2) (2016) 1123–1152.
[35] O. Tekdas, W. Yang, V. Isler, Robotic routers: Algorithms and implementation, The International Journal of Robotics Research 29 (1) (2010) 110–126.
[36] E. Yanmaz, Positioning aerial relays to maintain connectivity during drone team missions, Ad Hoc Networks 128 (2022) 102800.
[37] M. M. Zavlanos, G. J. Pappas, Potential fields for maintaining connectivity of mobile networks, IEEE Transactions on Robotics 23 (4) (2007) 812–816.
[38] M. Li, Y. Jie, Y. Kong, H. Cheng, Decentralized global connectivity maintenance for multi-robot navigation: A reinforcement learning approach, arXiv:2109.08536 (2021).
[39] R. Ding, J. Chen, W. Wu, J. Liu, F. Gao, X. Shen, Packet routing in dynamic multi-hop UAV relay network: A multi-agent learning approach, IEEE Transactions on Vehicular Technology 71 (9) (2022) 10059–10072.
[40] MUTTO: Multi-agent reinforcement learning for joint trajectory and transmit power optimisation of relay and mission UAVs, Vehicular Communications (2024).
URL https://www.sciencedirect.com/science/article/abs/pii/S1570870524002130
[41] MAEN: Multi-agent aerial relay networking, Proceedings of ACM MobiCom (2024). doi:10.1145/3636534.3694730.
[42] J. De Hoog, S. Cameron, A. Visser, Role-based autonomous multi-robot exploration, in: Proceedings of the International Conference on Advanced Cognitive Technologies and Applications, 2009.
[43] K. Cesare, R. Skeele, S.-H. Yoo, Y. Zhang, G. Hollinger, Multi-UAV exploration with limited communication and battery, in: Proceedings of the IEEE International Conference on Robotics and Automation, 2015, pp. 2230–2235. doi:10.1109/ICRA.2015.7139494.
[44] N. Boland, M. Hewitt, L. Marshall, M. Savelsbergh, The continuous-time service network design problem, Operations Research 65 (5) (2017) 1303–1321.
[45] A. Richards, J. P. How, Aircraft trajectory planning with collision avoidance using mixed integer linear programming, in: Proceedings of the American Control Conference, 2002, pp. 1936–1941.
[46] H. D. Sherali, J. C. Smith, Improving discrete model representations via symmetry considerations, Management Science 47 (10) (2001) 1396–1407.
[47] F. Margot, Symmetry in integer linear programming, in: 50 Years of Integer Programming 1958–2008, Springer, Berlin, 2010, pp. 647–686.
[48] O. Vinyals, M. Fortunato, N. Jaitly, Pointer networks, in: Advances in Neural Information Processing Systems 28, 2015, pp. 2692–2700.
[49] M. Nazari, A. Oroojlooy, L. V. Snyder, M. Takáč, Reinforcement learning for solving the vehicle routing problem, in: Advances in Neural Information Processing Systems 31, 2018, pp. 9839–9849.
[50] Y. Bengio, A. Lodi, A. Prouvost, Machine learning for combinatorial optimization: A methodological tour d'horizon, European Journal of Operational Research 290 (2) (2021) 405–421.
[51] N. Mazyavkina, S. Sviridov, S. Ivanov, E. Burnaev, Reinforcement learning for combinatorial optimization: A survey, Computers & Operations Research 134 (2021) 105400.
[52] Y. Guo, Z. Ren, C. Wang, iMTSP: Solving min-max multiple traveling salesman problem with imperative learning, arXiv:2405.00285 (2024).
[53] Y. Zhu, H. Xu, A. A. Malikopoulos, N. Geroliminis, Dual-mission drone fleets: Delivery with secondary sensing tasks, arXiv:2604.02471 (2026).
[54] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, I. Mordatch, Multi-agent actor-critic for mixed cooperative-competitive environments, in: Advances in Neural Information Processing Systems 30, 2017, pp. 6379–6390.
[55] J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, S. Whiteson, Counterfactual multi-agent policy gradients, in: Proceedings of the 32nd AAAI Conference on Artificial Intelligence, 2018, pp. 2974–2982.
[56] P. Sunehag, G. Lever, A. Gruslys, W. M. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls, T. Graepel, Value-decomposition networks for cooperative multi-agent learning based on team reward, in: Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems, 2018, pp. 2085–2087.
[57] T. Rashid, M. Samvelyan, C. Schroeder de Witt, G. Farquhar, J. Foerster, S. Whiteson, QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning, in: Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4295–4304.
[58] C. Yu, A. Velu, E. Vinitsky, J. Gao, Y. Wang, A. Bayen, Y. Wu, The surprising effectiveness of PPO in cooperative multi-agent

games, arXiv:2103.01955 (2022).
[59] A. Oroojlooy, D. Hajinezhad, A review of cooperative multi-agent deep reinforcement learning, Applied Intelligence 53 (2023) 13677–13722.
[60] R. S. Sutton, D. Precup, S. Singh, Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning, Artificial Intelligence 112 (1–2) (1999) 181–211.
[61] P.-L. Bacon, J. Harb, D. Precup, The option-critic architecture, in: Proceedings of the 31st AAAI Conference on Artificial Intelligence, 2017, pp. 1726–1734.
[62] A. S. Vezhnevets, S. Osindero, T. Schaul, N. Heess, M. Jaderberg, D. Silver, K. Kavukcuoglu, FeUdal networks for hierarchical reinforcement learning, in: Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 3540–3549.
[63] S. Huang, S. Ontañón, A closer look at invalid action masking in policy gradient algorithms, in: Proceedings of the International FLAIRS Conference, Vol. 35, 2022.
[64] G. Dalal, K. Dvijotham, M. Vecerik, T. Hester, C. Paduraru, Y. Tassa, Safe exploration in continuous action spaces, arXiv:1801.08757 (2018).
[65] A. Y. Ng, D. Harada, S. Russell, Policy invariance under reward transformations: Theory and application to reward shaping, in: Proceedings of the 16th International Conference on Machine Learning, 1999, pp. 278–287.
[66] Gurobi Optimization, LLC, Gurobi optimizer reference manual, version 13, `https://www.gurobi.com` (2026).